Notas de Clase: Análisis Multivariante

Componentes Principales, Análisis Factorial, Índices Compuestos y Conglomerados

Benjamín Oliva[1]

Draft Noviembre 2026

[1] benjov@ciencias.unam.mx y https://github.com/benjov

Documento siempre proceso de mejora.
Comentarios siempre serán bienvenidos...
Este documento servirá para el curso de Análisis Multivariante de la Licenciatura en Economía.

Índice general

Introducción **1**

1. Fundamentos del análisis multivariante **9**
1.1. Técnicas de interdependencia y de dependencia 10
1.2. Escalas de medición 10
1.3. La matriz de datos 13
1.3.1. Vector de medias y matriz de centrado 14
1.3.2. Matrices de covarianzas y de correlaciones 15
1.3.3. Combinaciones lineales 16
1.3.4. Medidas escalares de dispersión 17
1.4. Vectores aleatorios 18
1.5. Distancias 19
1.6. La distribución normal multivariada 20
1.6.1. Evaluación de la normalidad multivariada 23
1.7. Filosofía de trabajo de una técnica multivariada 24
1.8. Etapas en el desarrollo de una técnica multivariada 25
1.9. Implementación en Python 26
1.10. Ejercicios 27

2. Análisis de Componentes Principales **29**
2.1. Componentes principales poblacionales 30
2.2. ¿Covarianzas o correlaciones? 32
2.3. Componentes principales muestrales 33
2.4. Optimalidad: la mejor aproximación de dimensión baja 35
2.5. ¿Cuántos componentes retener? 37
2.6. Interpretación 39
2.6.1. El biplot 39
2.6.2. Aplicación: 167 países, 9 indicadores 40

2.7. Inferencia sobre los eigenvalores 42
2.8. Alcances y limitaciones 43
2.9. Implementación en Python 44
2.10. Ejercicios 45

3. Análisis Factorial **47**
3.1. El modelo factorial ortogonal 48
3.1.1. Conteo de parámetros e identificación 49
3.1.2. Análisis factorial y componentes principales 50
3.2. Adecuación de los datos 51
3.3. Estimación 52
3.3.1. Método de componentes principales 52
3.3.2. Método de ejes principales 53
3.3.3. Máxima verosimilitud 53
3.4. Rotación 55
3.4.1. Rotación ortogonal: varimax 56
3.4.2. Rotación oblicua: promax 57
3.5. Interpretación 58
3.6. Puntuaciones factoriales 58
3.7. Confiabilidad de una escala 60
3.8. Un ejemplo de advertencia 61
3.9. El análisis factorial en las etapas de Hair 62
3.10. Implementación en Python 62
3.11. Ejercicios 63

4. Construcción de índices compuestos **65**
4.1. Marco conceptual y selección de indicadores 66
4.2. Normalización 67
4.3. Ponderación 68
4.3.1. Pesos nominales e importancia efectiva 69
4.4. Agregación 70
4.4.1. Agregación lineal y compensación 70
4.4.2. Agregación geométrica 71
4.5. Robustez: análisis de incertidumbre y sensibilidad 72
4.6. Validación 74
4.7. El índice resultante 75
4.8. Lista de verificación 75
4.9. Implementación en Python 76

4.10. Ejercicios 77

5. Análisis de Conglomerados **79**
5.1. Medidas de distancia y de similitud 80
5.2. La descomposición de la dispersión 82
5.3. Agrupamiento jerárquico 83
5.3.1. Criterios de enlace 84
5.3.2. La fórmula de Lance y Williams 85
5.3.3. El dendrograma y la correlación cofenética 87
5.4. Agrupamiento no jerárquico: k-medias 87
5.4.1. k-medoides 89
5.5. Agrupamiento basado en modelos: mezclas gaussianas 89
5.6. ¿Cuántos grupos? Validación 91
5.7. Aplicación: una tipología de las entidades federativas 92
5.7.1. Elección del número de grupos 92
5.7.2. Los grupos y su perfil 93
5.7.3. Validación 95
5.8. k-medias con datos epidemiológicos 96
5.9. Agrupamiento de series de tiempo 97
5.10. El análisis de conglomerados en las etapas de Hair 98
5.11. Implementación en Python 99
5.12. Ejercicios 100

Bibliografía **101**

A. Resultados de álgebra matricial **107**
A.1. Traza, determinante y rango 107
A.2. Formas cuadráticas y definitud 108
A.3. Eigenvalores y teorema espectral 108
A.4. Cociente de Rayleigh 109
A.5. Descomposición en valores singulares 110
A.6. Derivadas matriciales 111
A.7. Ejercicios 111

Índice de figuras

2.1. Gráfica de sedimentación y análisis paralelo (167 países, 9 indicadores, 5 000 réplicas). Elaboración propia con datos de Kokkula (2020). 41

2.2. Biplot ($\alpha = 1$) de los dos primeros componentes. Puntos: puntuaciones de los 167 países (se etiquetan algunos). Flechas: cargas, reescaladas para hacerlas visibles. Elaboración propia con datos de Kokkula (2020). 42

3.1. Eigenvalores de $\mathbf{R}$ y percentil 95 del análisis paralelo (32 entidades, 6 indicadores, 5 000 réplicas). Elaboración propia con datos de la ENIGH 2024 (INEGI 2025). 55

3.2. Cargas de máxima verosimilitud sin rotar (ejes sólidos) y ejes varimax $F1^*$, $F2^*$ (punteados), rotados 14.9°. Las cargas rotadas son las proyecciones de cada punto sobre los ejes punteados. Elaboración propia con datos de la ENIGH 2024. . . . 57

4.1. Lugar de cada entidad en el índice base (rombos) y distribución de su lugar en 10 000 combinaciones aleatorias de normalización, pesos y agregación: mediana (puntos) e intervalo del 5 % al 95 % (barras). Elaboración propia con datos de la ENIGH 2024. 73

5.1. El algoritmo aglomerativo con enlace simple en el ejemplo de las cinco entidades (Ejemplo 5.2). Izquierda: orden de las fusiones en el plano. Derecha: dendrograma, con la altura de cada fusión. Elaboración propia. 84

5.2. Criterios para elegir k con k-medias sobre las puntuaciones factoriales de las 32 entidades. El estadístico gap se muestra con barras de $\pm s_k$ (500 conjuntos de referencia). Elaboración propia con datos de la ENIGH 2024. 93
5.3. Tipología de las entidades con k-medias ($k = 4$) en el plano de los factores del Capítulo 3. Elaboración propia con datos de la ENIGH 2024. 94
5.4. Dendrograma del método de Ward sobre las puntuaciones factoriales de las 32 entidades. Elaboración propia con datos de la ENIGH 2024. 96

Índice de cuadros

1. Correspondencia entre el temario oficial y las notas 2

1.1. Clasificación de técnicas multivariantes 11
1.2. Escalas de medición y operaciones permitidas 12

2.1. Datos de trabajo del capítulo: seis países 30

4.1. Variantes del índice: correlación de Spearman con el índice base (estandarización, pesos iguales, agregación lineal) y cambio absoluto medio de lugar 72
4.2. Índice de condiciones socioeconómicas de los hogares por entidad federativa, ENIGH 2024 75

5.1. Coeficientes de la fórmula de Lance y Williams ($n_{ij} = n_i + n_j$, $n_{ijk} = n_i + n_j + n_k$) 86

Introducción

Casi todos los fenómenos que interesan a un economista son multidimensionales. El bienestar de un hogar no se reduce a su ingreso: depende también de su educación, su vivienda, su acceso a la salud y su composición demográfica. La competitividad de una región, el perfil de un consumidor o el comportamiento de los precios de la electricidad en los nodos del Sistema Eléctrico Nacional son, igualmente, el resultado de muchas variables que se mueven juntas. El **análisis multivariante** es el conjunto de técnicas estadísticas que estudian esas variables de manera *simultánea*, aprovechando la estructura de sus correlaciones en lugar de analizarlas una por una.

Estas notas sirven como guía para el curso de Análisis Multivariante de la Licenciatura en Economía del Tecnológico de Monterrey. Se concentran en las técnicas de **interdependencia**, aquellas en las que ninguna variable tiene un papel privilegiado, que responden a dos preguntas:

- ¿Qué dimensiones latentes comparten las variables? Esa es la pregunta del análisis de componentes principales y del análisis factorial, y su aplicación más visible es la construcción de **índices compuestos**.
- ¿Qué individuos u objetos se parecen entre sí? Esa es la pregunta del **análisis de conglomerados**, cuya aplicación típica es la segmentación.

El temario oficial del curso es breve y está pensado para ejecutarse con un paquete de menús. Estas notas lo amplían en dos direcciones. Hacia la *teoría*: cada técnica se presenta con sus fundamentos matemáticos y con demostraciones completas, porque sólo así se entiende cuándo funciona, cuándo falla y qué significan sus resultados. Hacia la *práctica*: cada resultado se acompaña de ejemplos numéricos que pueden verificarse a mano y de aplicaciones con datos reales de México, desarrolladas en Python, un lenguaje abierto y reproducible.

Organización y correspondencia con el temario

Las notas tienen cinco capítulos y un apéndice. El Cuadro 1 muestra cómo se corresponden con los módulos y subtemas del temario oficial, e indica en qué sesiones del curso se trabaja cada uno; el curso dura cinco semanas, con dos sesiones de dos horas por semana (S1 a S10). Los temas que no aparecen de manera explícita en el temario, como el análisis de componentes principales, los índices compuestos o las mezclas gaussianas, se incorporan como desarrollo de algún subtema oficial.

Cuadro 1: Correspondencia entre el temario oficial y las notas

Módulo (horas)	**Subtemas del temario**	**Notas (sesiones)**
1. Introducción a la estadística multivariante de interdependencia (2)	1.1 Interdependencia contra dependencia; 1.2 escalas de medición; 1.3 filosofía de trabajo; 1.4 etapas de una técnica multivariada	Cap. 1 y Apéndice A (S1)
2. Análisis de factores (10)	2.1 Definición del problema, objetivos y plan	Cap. 2, componentes principales (S2–S3)
	2.2 Supuestos y estimación; 2.3 interpretación y validación	Cap. 3 (S4–S5)
	2.4 Desarrollo de un análisis de factores con software	Cap. 3, Python, y Cap. 4, índices compuestos (S6)
3. Análisis de conglomerados (8)	3.1 Definición del problema, objetivos y plan	Cap. 5: distancias (S7)
	3.2 Supuestos y estimación	Jerárquico, k-medias, mezclas (S7, S9)
	3.3 Interpretación y validación	Número de grupos, perfilado (S9–S10)
	3.4 Desarrollo de un análisis de conglomerados con software	Aplicación y series de tiempo (S10)

Los contenidos procedimentales del curso se cubren de la siguiente manera:

1. *Construcción de indicadores y de una base de datos*: los indicadores

estatales de la ENIGH 2024 construidos en el Capítulo 3 a partir de los microdatos.

2. *Cálculo de un índice agregado*: el Capítulo 4 completo.

3. *Generación de una segmentación y perfilado*: la aplicación del Capítulo 5.

4. *Elaboración de un reporte bajo el método científico*: las seis etapas de la Sección 1.8, que estructuran cada capítulo, y el proyecto integrador descrito al final de esta introducción.

5. *Referencia de fuentes bajo formatos preestablecidos*: cada capítulo indica las fuentes que sigue, y cada figura, el origen de sus datos.

6. *Resolución de problemas de la realidad con metodologías de investigación científica*: las aplicaciones con datos mexicanos y el proyecto.

El hilo conductor

Para que las técnicas no se vean como herramientas aisladas, las notas siguen un mismo problema a lo largo de varios capítulos: describir las condiciones socioeconómicas de los hogares en las 32 entidades federativas con los microdatos de la ENIGH 2024 (INEGI 2025).

- En el Capítulo 3 se construyen seis indicadores por entidad y un análisis factorial encuentra dos dimensiones: nivel socioeconómico y envejecimiento.

- En el Capítulo 4, la primera dimensión se convierte en un índice compuesto, cuya robustez se evalúa frente a decisiones metodológicas alternativas.

- En el Capítulo 5, las dos dimensiones se usan para construir una tipología de las entidades.

El Capítulo 1 usa un ejemplo de cinco hogares que puede calcularse a mano, y el Capítulo 2, indicadores de desarrollo de 167 países. A lo largo del camino aparecen también casos en los que las técnicas *fallan* o engañan: un análisis paralelo que no encuentra estructura con seis observaciones, un cuestionario

cuyo "factor" resulta ser una etiqueta de grupo, y un estadístico gap que advierte que las entidades no forman grupos naturales. Esos casos son tan instructivos como los exitosos.

Cómo leer estas notas

- **Notación.** Los vectores se escriben en negrita minúscula ($\mathbf{x}$, $\boldsymbol{\mu}$) y las matrices en negrita mayúscula ($\mathbf{X}$, $\boldsymbol{\Sigma}$). La notación completa se fija al inicio del Capítulo 1.
- **Resultados y demostraciones.** Las definiciones, proposiciones y teoremas están numerados por capítulo. Las demostraciones terminan con el símbolo ■; en una primera lectura pueden omitirse, pero entenderlas es lo que permite usar las técnicas con criterio.
- **Ejemplos numéricos.** Cada capítulo trabaja con un conjunto de datos pequeño que se retoma en varios ejemplos, de modo que los cálculos pueden seguirse con lápiz y calculadora. Todas las cifras se verificaron con Python.
- **Ejercicios.** Al final de cada capítulo hay ejercicios teóricos (demostraciones y cálculos a mano), computacionales (con los datos del repositorio) y, en algunos casos, de proyecto.
- **Reproducibilidad.** Todas las figuras son de elaboración propia. Cada capítulo tiene en el repositorio del curso un cuaderno de Python, que se indica en su sección de implementación, que reproduce paso a paso sus ejemplos numéricos y aplicaciones. Los fragmentos de código de las notas usan rutas relativas a la raíz del repositorio.

Conocimientos previos

- **Cálculo diferencial e integral**, incluida la optimización con restricciones mediante multiplicadores de Lagrange.
- **Álgebra lineal**: operaciones con matrices, determinantes, rango, eigenvalores y eigenvectores. El Apéndice A repasa y demuestra los resultados que se usan.

- **Probabilidad y estadística**: esperanza, varianza y covarianza; las distribuciones normal y ji-cuadrada; estimación por máxima verosimilitud y pruebas de hipótesis.
- **Regresión lineal** al nivel de un primer curso de econometría: mínimos cuadrados ordinarios y generalizados. Se usa como punto de comparación con las técnicas de interdependencia.
- **Python** básico: `numpy`, `pandas` y `matplotlib`. Las técnicas se implementan con `scipy` y `scikit-learn`.

Recursos

Los datos, los cuadernos de Python y el código del curso están en el repositorio `https://github.com/benjov/Multivariante-II-2026-Tec`. La bibliografía básica es:

- Hair et al. (2006): la referencia aplicada del temario oficial, con énfasis en el diseño y la interpretación.
- Johnson y Wichern (2007): el libro de texto principal para la teoría, a un nivel intermedio.
- Mardia, Kent y Bibby (1979): un tratamiento más riguroso, útil para las demostraciones.
- James et al. (2021) y Hastie, Tibshirani y Friedman (2017): la perspectiva del aprendizaje estadístico, con aplicaciones computacionales.
- Everitt et al. (2011) y Kaufman y Rousseeuw (1990): referencias especializadas en análisis de conglomerados.
- OECD y European Commission Joint Research Centre (2008): el manual de referencia para construir índices compuestos.

Perspectiva histórica

El análisis multivariante nació a principios del siglo XX, en buena medida en la psicología. En 1901, Karl Pearson buscó las rectas y los planos que mejor

se ajustan a una nube de puntos en el espacio, lo que hoy reconocemos como el primer componente principal (Pearson 1901). Tres años después, Charles Spearman observó que las calificaciones de los escolares en materias muy distintas estaban todas positivamente correlacionadas y propuso explicarlas con un único factor de "inteligencia general": así nació el análisis factorial (Spearman 1904).

En la década de 1930 se establecieron las bases estadísticas. Harold Hotelling formuló el análisis de componentes principales como el problema de encontrar combinaciones lineales de máxima varianza (Hotelling 1933); Prasanta Chandra Mahalanobis, trabajando con mediciones antropométricas en la India, definió la distancia que lleva su nombre (Mahalanobis 1936); y Robert Tryon acuñó el término "análisis de conglomerados" (Tryon 1939). Louis Thurstone extendió el análisis factorial a varios factores y propuso el criterio de estructura simple que motivaría las rotaciones (Thurstone 1947).

La llegada de las computadoras transformó el campo. Henry Kaiser propuso la rotación varimax como un criterio analítico que podía programarse (Kaiser 1958), Joe Ward el método jerárquico de mínima varianza (Ward 1963) y James MacQueen el algoritmo de k-medias (MacQueen 1967). Karl Jöreskog hizo práctica la estimación por máxima verosimilitud del análisis factorial (Jöreskog 1967), y el algoritmo EM (Dempster, Laird y Rubin 1977) abrió el camino al agrupamiento basado en modelos. Desde entonces, estas técnicas se han vuelto herramientas cotidianas en economía, mercadotecnia, salud pública y política social, y hoy forman parte del aprendizaje automático no supervisado.

Uso responsable de la información

Las técnicas de este curso siempre producen un resultado: un factor, un índice o un conjunto de grupos. Pero que un algoritmo produzca un resultado no significa que el resultado sea válido. Por eso cada capítulo dedica espacio a la validación y a las limitaciones, y el curso insiste en algunas actitudes:

- **Ética profesional en el uso de los datos.** Los microdatos de encuestas como la ENIGH se publican anonimizados; deben usarse respetando esa confidencialidad y las condiciones de su fuente.
- **Integridad académica.** Toda idea, dato o figura tomados de otro autor se citan.

- **Sensibilidad a los problemas de México.** Un índice o una tipología de entidades puede influir en decisiones de política pública y en cómo se percibe a una región. Las decisiones metodológicas deben ser explícitas, y la incertidumbre de los resultados, comunicada.
- **Pensamiento crítico.** Antes de interpretar un resultado hay que preguntarse si los datos lo justifican, como lo muestran los ejemplos de advertencia de las notas.

Evaluación

Instrumento	Momento	Peso	Contenido y formato
Quiz	S4 (miércoles de la semana 2)	15 %	Caps. 1 y 2; 20 minutos; opción múltiple con justificación
Práctica de Python	Domingo de la semana 3	15 %	Caps. 1 y 2 con datos nuevos; individual; uso de Python e interpretación
Examen	S8 (semana 4)	30 %	Caps. 1 a 4; presencial, a libro y apuntes abiertos; teoría e interpretación de código y resultados; opción múltiple con justificación
Trabajo final	Domingo de la semana 5	40 %	Todo el curso; en equipo; el artículo de investigación descrito abajo

En los reactivos de opción múltiple, la mitad del puntaje corresponde a elegir la opción correcta y la otra mitad a justificarla: explicar, con los resultados de las notas, por qué es correcta.

Proyecto integrador

El curso culmina con un artículo de investigación en equipo, que responde a la situación problema "Medir para mejorar": construir una medición multidimensional de un fenómeno del desarrollo para un conjunto de unidades (municipios, entidades o zonas metropolitanas) y agruparlas en tipos. Recorre el mismo camino que las notas:

1. **Marco teórico.** Definir el fenómeno, por ejemplo marginación, rezago social o calidad de vida, sus dimensiones y cómo lo miden otros, a partir de una revisión de literatura.

2. **Base de datos.** Reunir al menos seis indicadores, para al menos 30 unidades, de fuentes públicas mexicanas, como el Censo de Población y Vivienda 2020 y la ENIGH del INEGI, CONEVAL o CONAPO, y documentar su construcción.

3. **Estructura.** Verificar con componentes principales o análisis factorial que los indicadores comparten las dimensiones propuestas (Capítulos 2 y 3).

4. **Índice.** Construir un índice compuesto, evaluar su robustez y validarlo con una variable externa (Capítulo 4).

5. **Segmentación.** Agrupar las unidades, justificar el número de grupos y perfilarlos (Capítulo 5).

6. **Artículo.** Presentar los resultados con la estructura de un artículo científico de máximo 15 cuartillas: introducción, marco teórico, datos, métodos, resultados, discusión de limitaciones, recomendaciones de política y referencias, con el código reproducible.

Licencia

Estas notas, junto con los cuadernos y el código del repositorio del curso, se dedican al dominio público bajo la licencia CC0 1.0 Universal: pueden copiarse, modificarse y distribuirse sin pedir permiso. Los conjuntos de datos de terceros conservan los términos de uso de su fuente original.

1

Fundamentos del análisis multivariante

El análisis multivariante estudia de manera simultánea $p \geq 2$ variables medidas sobre los mismos n individuos u objetos. La palabra clave es *simultánea*: lo que interesa no es cada variable por separado, sino la estructura de dependencia entre ellas, que se resume en matrices de covarianza o de correlación. Este capítulo fija la notación, introduce los objetos básicos (la matriz de datos, el vector de medias, la matriz de covarianzas, la distancia de Mahalanobis y la distribución normal multivariada) y presenta el marco metodológico con el que trabajaremos en el resto del curso. Las herramientas de álgebra matricial que se usan sin demostración están en el Apéndice A. Las secciones 1.3 a 1.6 siguen de cerca a Johnson y Wichern (2007, Caps. 1–4) y Mardia, Kent y Bibby (1979, Caps. 1–3); las secciones 1.7 y 1.8, a Hair et al. (2006, Cap. 1).

A lo largo del capítulo usaremos un mismo conjunto de datos, deliberadamente pequeño para que todos los cálculos puedan verificarse a mano.

Notación. Los escalares se denotan en itálica (x, λ), los vectores columna en negrita minúscula ($\mathbf{x}$, $\boldsymbol{\mu}$) y las matrices en negrita mayúscula ($\mathbf{X}$, $\boldsymbol{\Sigma}$). $\mathbf{A}'$ es la transpuesta de $\mathbf{A}$, $\mathbf{I}_p$ la identidad de orden p, $\mathbf{1}_n$ el vector de n unos y $\operatorname{tr}(\mathbf{A})$, $|\mathbf{A}|$ la traza y el determinante de una matriz cuadrada.

1.1. Técnicas de interdependencia y de dependencia

Las técnicas multivariantes se clasifican según la pregunta que responden (Hair et al. 2006, Cap. 1).

Definición 1.1 *Una técnica es* ***de dependencia*** *cuando el conjunto de variables se divide en variables* dependientes *(respuesta) y variables* independientes *(explicativas), y el objetivo es explicar o predecir las primeras a partir de las segundas. Una técnica es* ***de interdependencia*** *cuando ninguna variable tiene un papel privilegiado y el objetivo es describir la estructura del conjunto completo: qué variables se mueven juntas, qué individuos se parecen entre sí.*

En términos probabilísticos, una técnica de dependencia modela la distribución condicional $f(\mathbf{y} \mid \mathbf{x})$, o alguno de sus momentos, como la esperanza condicional $\mathbb{E}[\mathbf{y} \mid \mathbf{x}]$, que es el objeto del análisis de regresión. Una técnica de interdependencia modela la distribución conjunta $f(\mathbf{x})$, o una de sus características, típicamente la matriz de covarianzas $\mathbf{\Sigma}$. El Cuadro 1.1 resume la clasificación.

En el vocabulario de *machine learning*, las técnicas de dependencia corresponden al **aprendizaje supervisado**, porque existe una variable objetivo observada, y las de interdependencia al **aprendizaje no supervisado** (Hastie, Tibshirani y Friedman 2017, Cap. 14). Este curso se concentra en las segundas. La distinción no es una jerarquía: es frecuente que un índice construido con análisis factorial, o una segmentación hecha con conglomerados, se use después como variable explicativa en una regresión.

1.2. Escalas de medición

Antes de calcular una media o una correlación hay que preguntarse si esa operación tiene sentido para la variable en cuestión. Stevens (1946) propuso clasificar las escalas según las *transformaciones admisibles*, es decir, las transformaciones g que preservan toda la información empírica contenida en la medición.

Definición 1.2 *Sea x una medición con valores en un conjunto $\mathcal{X}$. La escala de x es:*

Cuadro 1.1: Clasificación de técnicas multivariantes

Tipo	**Pregunta**	**Técnicas**
Dependencia	¿Cómo explican $\mathbf{x}$ a $\mathbf{y}$?	Regresión múltiple, MANOVA, análisis discriminante, regresión logística, correlación canónica, modelos de ecuaciones estructurales
Interdependencia entre *variables*	¿Qué estructura latente comparten las columnas de $\mathbf{X}$?	Componentes principales, análisis factorial
Interdependencia entre *objetos*	¿Qué filas de $\mathbf{X}$ se parecen entre sí?	Análisis de conglomerados, escalamiento multidimensional
Interdependencia con datos categóricos	¿Cómo se asocian las categorías?	Análisis de correspondencias

1. ***Nominal**, si es admisible cualquier función biyectiva g. Solo se preserva la igualdad: $x_i = x_j \iff g(x_i) = g(x_j)$.*

2. ***Ordinal**, si es admisible cualquier g estrictamente creciente. Se preserva el orden.*

3. ***De intervalo**, si es admisible cualquier $g(x) = a + bx$ con $b > 0$. Se preservan los cocientes de* diferencias*: $(x_i - x_j)/(x_k - x_l)$.*

4. ***De razón**, si es admisible cualquier $g(x) = bx$ con $b > 0$. Existe un cero natural y se preservan los cocientes x_i/x_j.*

Un estadístico es *significativo* para una escala si las conclusiones que se obtienen con él no cambian al aplicar una transformación admisible. Por ejemplo, para una variable ordinal, la afirmación "la mediana del grupo A es mayor que la del grupo B" es invariante ante cualquier g creciente; la afirmación "la media de A es mayor que la de B" no lo es.

Ejemplo 1.1 (La media no es significativa en escala ordinal) Codifiquemos la escolaridad como 1 = primaria, 2 = secundaria, 3 =

preparatoria, 4 = licenciatura, 5 = posgrado. En el grupo A hay tres personas con códigos $\{1, 1, 5\}$ y en el grupo B, $\{2, 2, 2\}$. Las medias son $\bar{x}_A = 7/3 \approx 2.33 > \bar{x}_B = 2$. Ahora apliquemos la transformación creciente g que deja todo igual salvo $g(5) = 3.5$, lo que respeta el orden porque $3 < 3.5 < 4$. Con los nuevos códigos, $\bar{x}_A = 5.5/3 \approx 1.83 < \bar{x}_B = 2$. La conclusión se invirtió sin que cambiara la información empírica: nadie cambió de nivel educativo. En cambio, las medianas, 1 para A y 2 para B, conservan su orden ante cualquier g creciente.

Proposición 1.1 *Si x es de intervalo, el coeficiente de correlación de Pearson entre x y cualquier otra variable y es invariante ante transformaciones admisibles de x.*

Demostración. Sea $\tilde{x} = a + bx$ con $b > 0$. Entonces $\mathrm{Cov}(\tilde{x}, y) = b\,\mathrm{Cov}(x, y)$ y $\mathrm{Var}(\tilde{x}) = b^2\,\mathrm{Var}(x)$, de modo que

$$\mathrm{Corr}(\tilde{x}, y) = \frac{b\,\mathrm{Cov}(x, y)}{\sqrt{b^2\,\mathrm{Var}(x)}\sqrt{\mathrm{Var}(y)}} = \frac{b}{|b|}\,\mathrm{Corr}(x, y) = \mathrm{Corr}(x, y).$$

Si sólo se exige que g sea creciente (escala ordinal), la correlación de Pearson en general cambia; por eso para datos ordinales se usan correlaciones de rangos (Spearman, Kendall) o policóricas. ■

Cuadro 1.2: Escalas de medición y operaciones permitidas

Escala	**Transf. admisible**	**Estadísticos**	**Ejemplo (ENIGH)**
Nominal	biyección	moda, frecuencias, χ^2	entidad federativa, sexo del jefe del hogar
Ordinal	monótona creciente	mediana, cuantiles, rangos	nivel de escolaridad
Intervalo	$a + bx$, $b > 0$	media, varianza, Pearson	año de construcción de la vivienda
Razón	bx, $b > 0$	todo lo anterior, coeficiente de variación, media geométrica	ingreso corriente, número de cuartos

En la práctica, las variables nominales y ordinales se llaman *no métricas* y las de intervalo y razón *métricas*. El análisis factorial y el de componentes

principales, tal como los desarrollaremos, suponen variables métricas, porque trabajan con covarianzas. El análisis de conglomerados admite variables mixtas siempre que la medida de distancia sea adecuada; un ejemplo es la distancia de Gower, que veremos en el capítulo 5. Las escalas tipo Likert ("totalmente en desacuerdo" a "totalmente de acuerdo") son ordinales en sentido estricto; tratarlas como de intervalo es una aproximación común cuyas consecuencias deben discutirse en cada aplicación.

1.3. La matriz de datos

Los datos de un estudio multivariante se organizan en la **matriz de datos**

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} = \begin{bmatrix} \mathbf{x}_1' \\ \mathbf{x}_2' \\ \vdots \\ \mathbf{x}_n' \end{bmatrix} = \begin{bmatrix} \mathbf{X}_{(1)} & \mathbf{X}_{(2)} & \cdots & \mathbf{X}_{(p)} \end{bmatrix}, \qquad (1.1)$$

donde x_{ij} es el valor de la variable j en el individuo i, $\mathbf{x}_i \in \mathbb{R}^p$ es el vector (columna) de mediciones del individuo i y $\mathbf{X}_{(j)} \in \mathbb{R}^n$ es la columna de la variable j.

Ejemplo 1.2 (Datos de trabajo) Cinco hogares reportan su ingreso (x_1) y su gasto (x_2) mensuales, en miles de pesos:

$$\mathbf{X} = \begin{bmatrix} 10 & 9 \\ 12 & 10 \\ 15 & 12 \\ 18 & 16 \\ 25 & 18 \end{bmatrix}, \qquad n = 5,\ p = 2.$$

Ambas variables están en escala de razón. Este es el ejemplo que retomaremos en todo el capítulo.

Hay dos maneras de ver geométricamente la matriz $\mathbf{X}$, y ambas son útiles:

- **Espacio de las variables** ($\mathbb{R}^p$): cada individuo es un punto. Esta es la vista natural para el análisis de conglomerados, que busca nubes de puntos cercanos.

- **Espacio de los individuos** ($\mathbb{R}^n$): cada variable es un vector. El coseno del ángulo entre dos variables centradas es su correlación; es la vista natural para el análisis factorial.

1.3.1. Vector de medias y matriz de centrado

El **vector de medias muestrales** es

$$\bar{\mathbf{x}} = \frac{1}{n}\sum_{i=1}^{n}\mathbf{x}_i = \frac{1}{n}\mathbf{X}'\mathbf{1}_n \in \mathbb{R}^p. \tag{1.2}$$

Para centrar los datos se usa la **matriz de centrado**

$$\mathbf{H} = \mathbf{I}_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n'. \tag{1.3}$$

Proposición 1.2 *La matriz* $\mathbf{H}$ *satisface:*

1. $\mathbf{H}' = \mathbf{H}$ *(simétrica) y* $\mathbf{H}^2 = \mathbf{H}$ *(idempotente).*
2. $\mathbf{H}\mathbf{1}_n = \mathbf{0}$ *y* $\mathbf{H}\mathbf{X} = \mathbf{X} - \mathbf{1}_n\bar{\mathbf{x}}'$*, es decir,* $\mathbf{H}\mathbf{X}$ *es la matriz de datos centrada.*
3. $\operatorname{rango}(\mathbf{H}) = \operatorname{tr}(\mathbf{H}) = n - 1$.

Demostración. (1) La simetría es inmediata. Como $\mathbf{1}_n'\mathbf{1}_n = n$,

$$\mathbf{H}^2 = \mathbf{I}_n - \frac{2}{n}\mathbf{1}_n\mathbf{1}_n' + \frac{1}{n^2}\mathbf{1}_n(\mathbf{1}_n'\mathbf{1}_n)\mathbf{1}_n' = \mathbf{I}_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n' = \mathbf{H}.$$

(2) $\mathbf{H}\mathbf{1}_n = \mathbf{1}_n - \frac{1}{n}\mathbf{1}_n n = \mathbf{0}$ y $\mathbf{H}\mathbf{X} = \mathbf{X} - \mathbf{1}_n\left(\frac{1}{n}\mathbf{1}_n'\mathbf{X}\right) = \mathbf{X} - \mathbf{1}_n\bar{\mathbf{x}}'$. (3) Los eigenvalores de una matriz idempotente son 0 o 1 (si $\mathbf{H}\mathbf{v} = \lambda\mathbf{v}$, entonces $\lambda\mathbf{v} = \mathbf{H}^2\mathbf{v} = \lambda^2\mathbf{v}$), y como $\mathbf{H}$ es simétrica es diagonalizable; por tanto su rango es el número de eigenvalores iguales a 1, que es $\operatorname{tr}(\mathbf{H}) = n - \frac{1}{n}\operatorname{tr}(\mathbf{1}_n\mathbf{1}_n') = n - 1$. ■

Ejemplo 1.3 (Media y datos centrados) Con los datos del Ejemplo 1.2, $\mathbf{X}'\mathbf{1}_5 = (80, 65)'$, así que $\bar{\mathbf{x}} = (16, 13)'$: el hogar promedio gana 16 mil pesos y gasta 13 mil. La matriz centrada es

$$\mathbf{H}\mathbf{X} = \mathbf{X} - \mathbf{1}_5\bar{\mathbf{x}}' = \begin{bmatrix} -6 & -4 \\ -4 & -3 \\ -1 & -1 \\ 2 & 3 \\ 9 & 5 \end{bmatrix}.$$

Cada columna suma cero, como garantiza $\mathbf{1}_5'\mathbf{H} = \mathbf{0}'$.

1.3.2. Matrices de covarianzas y de correlaciones

Definición 1.3 *La* ***matriz de covarianzas muestral*** *es*

$$\mathbf{S} = \frac{1}{n}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})' = \frac{1}{n}\mathbf{X}'\mathbf{H}\mathbf{X}, \tag{1.4}$$

con elementos $s_{jk} = \frac{1}{n}\sum_i (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$. *Su versión insesgada es* $\mathbf{S}_u = \frac{n}{n-1}\mathbf{S}$. *Sea* $\mathbf{D} = \mathrm{diag}(s_{11}, \ldots, s_{pp})$. *La* ***matriz de correlaciones muestral*** *es*

$$\mathbf{R} = \mathbf{D}^{-1/2}\mathbf{S}\mathbf{D}^{-1/2}, \qquad r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}s_{kk}}}. \tag{1.5}$$

Ejemplo 1.4 (Covarianzas y correlaciones) Con la matriz centrada del ejemplo anterior,

$$(\mathbf{H}\mathbf{X})'(\mathbf{H}\mathbf{X}) = \begin{bmatrix} 36+16+1+4+81 & 24+12+1+6+45 \\ \cdot & 16+9+1+9+25 \end{bmatrix} = \begin{bmatrix} 138 & 88 \\ 88 & 60 \end{bmatrix},$$

de modo que

$$\mathbf{S} = \frac{1}{5}\begin{bmatrix} 138 & 88 \\ 88 & 60 \end{bmatrix} = \begin{bmatrix} 27.6 & 17.6 \\ 17.6 & 12 \end{bmatrix}, \qquad \mathbf{S}_u = \frac{5}{4}\mathbf{S} = \begin{bmatrix} 34.5 & 22 \\ 22 & 15 \end{bmatrix}.$$

La correlación es $r_{12} = 17.6/\sqrt{27.6 \times 12} = 17.6/18.20 = 0.967$, así que

$$\mathbf{R} = \begin{bmatrix} 1 & 0.967 \\ 0.967 & 1 \end{bmatrix}.$$

Ingreso y gasto están casi perfectamente asociados en esta muestra. Note que $\mathbf{R}$ es la misma con $\mathbf{S}$ o con $\mathbf{S}_u$: el factor $n/(n-1)$ se cancela.

La igualdad $\frac{1}{n}\sum_i(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})' = \frac{1}{n}\mathbf{X}'\mathbf{H}\mathbf{X}$ se sigue de la Proposición 1.2: $\mathbf{X}'\mathbf{H}\mathbf{X} = \mathbf{X}'\mathbf{H}'\mathbf{H}\mathbf{X} = (\mathbf{H}\mathbf{X})'(\mathbf{H}\mathbf{X})$, y el producto $(\mathbf{H}\mathbf{X})'(\mathbf{H}\mathbf{X})$ es la suma de los productos exteriores de las filas centradas.

Proposición 1.3 $\mathbf{S}$ *y* $\mathbf{R}$ *son simétricas y semidefinidas positivas.* $\mathbf{S}$ *es definida positiva si y sólo si* $\mathrm{rango}(\mathbf{H}\mathbf{X}) = p$, *lo que exige* $n - 1 \geq p$.

Demostración. Para cualquier $\mathbf{a} \in \mathbb{R}^p$,

$$\mathbf{a}'\mathbf{S}\mathbf{a} = \frac{1}{n}\mathbf{a}'\mathbf{X}'\mathbf{H}'\mathbf{H}\mathbf{X}\mathbf{a} = \frac{1}{n}\|\mathbf{H}\mathbf{X}\mathbf{a}\|^2 \geq 0,$$

con igualdad si y sólo si $\mathbf{H}\mathbf{X}\mathbf{a} = \mathbf{0}$. Así, $\mathbf{S}$ es definida positiva si y sólo si el único $\mathbf{a}$ con $\mathbf{H}\mathbf{X}\mathbf{a} = \mathbf{0}$ es $\mathbf{a} = \mathbf{0}$, es decir, si las columnas de $\mathbf{H}\mathbf{X}$ son linealmente independientes. Como rango$(\mathbf{H}\mathbf{X}) \leq$ rango$(\mathbf{H}) = n - 1$, esto requiere $n - 1 \geq p$. Para $\mathbf{R}$, basta notar que $\mathbf{a}'\mathbf{R}\mathbf{a} = \mathbf{b}'\mathbf{S}\mathbf{b}$ con $\mathbf{b} = \mathbf{D}^{-1/2}\mathbf{a}$. ■

Observación 1.1 Si $\mathbf{S}$ es singular, alguna combinación lineal de las variables es constante en la muestra: hay *colinealidad exacta*. Esto ocurre, por ejemplo, si se incluyen el gasto total y todos sus componentes, o si $p > n-1$, como en datos genómicos o de texto. En el capítulo de componentes principales veremos que los eigenvalores nulos de $\mathbf{S}$ detectan precisamente estas restricciones.

1.3.3. Combinaciones lineales

Casi todas las técnicas del curso construyen nuevas variables como combinaciones lineales de las originales. Hair et al. (2006) llaman a estas combinaciones el *valor teórico* (*variate*) de la técnica. El siguiente resultado, elemental pero central, dice cómo se transforman sus momentos.

Proposición 1.4 *Sea* $\mathbf{A}$ *una matriz* $p \times q$ *y* $\mathbf{b} \in \mathbb{R}^q$*, y defínanse las nuevas observaciones* $\mathbf{y}_i = \mathbf{A}'\mathbf{x}_i + \mathbf{b}$*, es decir,* $\mathbf{Y} = \mathbf{X}\mathbf{A} + \mathbf{1}_n\mathbf{b}'$*. Entonces*

$$\bar{\mathbf{y}} = \mathbf{A}'\bar{\mathbf{x}} + \mathbf{b}, \qquad \mathbf{S}_\mathbf{y} = \mathbf{A}'\mathbf{S}\mathbf{A}. \tag{1.6}$$

En particular, para $q = 1$ *y* $y_i = \mathbf{a}'\mathbf{x}_i$*:* $\bar{y} = \mathbf{a}'\bar{\mathbf{x}}$ *y* $s_y^2 = \mathbf{a}'\mathbf{S}\mathbf{a}$*.*

Demostración. $\bar{\mathbf{y}} = \frac{1}{n}\mathbf{Y}'\mathbf{1}_n = \frac{1}{n}\mathbf{A}'\mathbf{X}'\mathbf{1}_n + \mathbf{b}\frac{1}{n}\mathbf{1}_n'\mathbf{1}_n = \mathbf{A}'\bar{\mathbf{x}} + \mathbf{b}$. Como $\mathbf{H}\mathbf{1}_n = \mathbf{0}$, $\mathbf{H}\mathbf{Y} = \mathbf{H}\mathbf{X}\mathbf{A}$ y $\mathbf{S}_\mathbf{y} = \frac{1}{n}\mathbf{Y}'\mathbf{H}\mathbf{Y} = \frac{1}{n}\mathbf{A}'\mathbf{X}'\mathbf{H}\mathbf{X}\mathbf{A} = \mathbf{A}'\mathbf{S}\mathbf{A}$. ■

Ejemplo 1.5 (El ahorro como combinación lineal) El ahorro de cada hogar es $y_i = x_{i1} - x_{i2} = \mathbf{a}'\mathbf{x}_i$ con $\mathbf{a} = (1, -1)'$. Por la proposición,

$$\bar{y} = \mathbf{a}'\bar{\mathbf{x}} = 16 - 13 = 3, \qquad s_y^2 = \mathbf{a}'\mathbf{S}\mathbf{a} = s_{11} + s_{22} - 2s_{12} = 27.6 + 12 - 35.2 = 4.4.$$

La verificación directa confirma el resultado: los ahorros son $(1, 2, 3, 2, 7)$, con media 3 y varianza $(4 + 1 + 0 + 1 + 16)/5 = 4.4$. Aunque ingreso y gasto tienen varianzas grandes (27.6 y 12), el ahorro varía poco, precisamente porque la covarianza positiva se resta dos veces. Una combinación lineal puede tener mucha menos varianza que sus componentes cuando éstos están correlacionados.

La Proposición 1.4 convierte preguntas estadísticas en problemas de álgebra lineal. Por ejemplo, "¿cuál es la combinación lineal normalizada de las variables con mayor varianza?" se convierte en maximizar $\mathbf{a}'\mathbf{S}\mathbf{a}$ sujeto a $\mathbf{a}'\mathbf{a} = 1$, cuya solución (Apéndice A, cociente de Rayleigh) es el primer eigenvector de $\mathbf{S}$: el primer componente principal.

1.3.4. Medidas escalares de dispersión

Para resumir la dispersión de una nube de puntos en un solo número se usan dos medidas.

Definición 1.4 *La* ***varianza total*** *es* $\operatorname{tr}(\mathbf{S}) = \sum_{j=1}^{p} s_{jj}$*, y la* ***varianza generalizada*** *es* $|\mathbf{S}|$.

Si $\lambda_1 \geq \cdots \geq \lambda_p \geq 0$ son los eigenvalores de $\mathbf{S}$, entonces $\operatorname{tr}(\mathbf{S}) = \sum_j \lambda_j$ y $|\mathbf{S}| = \prod_j \lambda_j$. La varianza total ignora las covarianzas; la varianza generalizada sí las toma en cuenta: $\sqrt{|\mathbf{S}|}$ es proporcional al volumen del elipsoide $\{\mathbf{x} : (\mathbf{x} - \bar{\mathbf{x}})'\mathbf{S}^{-1}(\mathbf{x} - \bar{\mathbf{x}}) \leq c^2\}$, y vale cero si los datos están contenidos en un subespacio de dimensión menor que p. Para $p = 2$, $|\mathbf{S}| = s_{11}s_{22}(1 - r_{12}^2)$: con varianzas fijas, la dispersión conjunta disminuye cuando la correlación crece en valor absoluto.

Ejemplo 1.6 (Varianza total, generalizada y eigenvalores) Para $\mathbf{S}$ del Ejemplo 1.4, la varianza total es $\operatorname{tr}(\mathbf{S}) = 27.6 + 12 = 39.6$ y la generalizada es $|\mathbf{S}| = 27.6 \times 12 - 17.6^2 = 331.2 - 309.76 = 21.44$. Los eigenvalores resuelven $\lambda^2 - 39.6\lambda + 21.44 = 0$:

$$\lambda_{1,2} = \frac{39.6 \pm \sqrt{39.6^2 - 4(21.44)}}{2} = \frac{39.6 \pm 38.50}{2}, \qquad \lambda_1 = 39.05,\ \lambda_2 = 0.55.$$

Se verifica que $\lambda_1 + \lambda_2 = 39.6 = \operatorname{tr}(\mathbf{S})$ y $\lambda_1\lambda_2 = 21.44 = |\mathbf{S}|$. El primer eigenvalor concentra el $39.05/39.6 = 98.6\,\%$ de la varianza total: la nube de cinco puntos es prácticamente una recta, en la dirección del eigenvector

$\boldsymbol{\gamma}_1 = (0.838, 0.545)'$. Este es, en miniatura, el argumento del análisis de componentes principales: una sola combinación lineal, $0.838\,x_1 + 0.545\,x_2$, resume casi toda la información de las dos variables.

1.4. Vectores aleatorios

La sección anterior fue descriptiva. Para hacer inferencia suponemos que $\mathbf{x}_1, \ldots, \mathbf{x}_n$ son realizaciones independientes de un vector aleatorio $\mathbf{x} = (x_1, \ldots, x_p)'$.

Definición 1.5 *El **vector de medias** y la **matriz de covarianzas** de* $\mathbf{x}$ *son*

$$\boldsymbol{\mu} = \mathbb{E}[\mathbf{x}], \qquad \boldsymbol{\Sigma} = \mathbb{E}\left[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})'\right] = \mathbb{E}[\mathbf{x}\mathbf{x}'] - \boldsymbol{\mu}\boldsymbol{\mu}', \tag{1.7}$$

con $\sigma_{jk} = \mathrm{Cov}(x_j, x_k)$. *La **matriz de correlaciones poblacional** es* $\mathbf{P} = \mathbf{V}^{-1/2}\boldsymbol{\Sigma}\mathbf{V}^{-1/2}$, *con* $\mathbf{V} = \mathrm{diag}(\sigma_{11}, \ldots, \sigma_{pp})$.

Proposición 1.5 *Sea* $\mathbf{y} = \mathbf{A}'\mathbf{x} + \mathbf{b}$ *con* $\mathbf{A} \in \mathbb{R}^{p \times q}$. *Entonces* $\mathbb{E}[\mathbf{y}] = \mathbf{A}'\boldsymbol{\mu} + \mathbf{b}$ *y* $\mathrm{Cov}(\mathbf{y}) = \mathbf{A}'\boldsymbol{\Sigma}\mathbf{A}$. *En particular,* $\boldsymbol{\Sigma}$ *es semidefinida positiva.*

Demostración. La primera igualdad es la linealidad de la esperanza. Para la segunda, $\mathbf{y} - \mathbb{E}[\mathbf{y}] = \mathbf{A}'(\mathbf{x} - \boldsymbol{\mu})$, de donde $\mathrm{Cov}(\mathbf{y}) = \mathbb{E}[\mathbf{A}'(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})'\mathbf{A}] = \mathbf{A}'\boldsymbol{\Sigma}\mathbf{A}$. Tomando $q = 1$, $\mathbf{a}'\boldsymbol{\Sigma}\mathbf{a} = \mathrm{Var}(\mathbf{a}'\mathbf{x}) \geq 0$. ■

Proposición 1.6 *Si* $\mathbf{x}_1, \ldots, \mathbf{x}_n$ *son independientes e idénticamente distribuidos con media* $\boldsymbol{\mu}$ *y covarianza* $\boldsymbol{\Sigma}$, *entonces* $\mathbb{E}[\bar{\mathbf{x}}] = \boldsymbol{\mu}$, $\mathrm{Cov}(\bar{\mathbf{x}}) = \frac{1}{n}\boldsymbol{\Sigma}$ *y* $\mathbb{E}[\mathbf{S}] = \frac{n-1}{n}\boldsymbol{\Sigma}$. *Por tanto* $\mathbf{S}_u = \frac{n}{n-1}\mathbf{S}$ *es insesgado para* $\boldsymbol{\Sigma}$.

Demostración. $\mathbb{E}[\bar{\mathbf{x}}] = \boldsymbol{\mu}$ es inmediato. Por independencia, $\mathrm{Cov}(\bar{\mathbf{x}}) = \frac{1}{n^2}\sum_i \mathrm{Cov}(\mathbf{x}_i) = \frac{1}{n}\boldsymbol{\Sigma}$. Para $\mathbf{S}$, escribimos

$$\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})' = \sum_{i=1}^{n}(\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})' - n(\bar{\mathbf{x}} - \boldsymbol{\mu})(\bar{\mathbf{x}} - \boldsymbol{\mu})',$$

identidad que se verifica sumando y restando $\boldsymbol{\mu}$ y usando $\sum_i(\mathbf{x}_i - \boldsymbol{\mu}) = n(\bar{\mathbf{x}} - \boldsymbol{\mu})$. Tomando esperanzas, $n\mathbb{E}[\mathbf{S}] = n\boldsymbol{\Sigma} - n \cdot \frac{1}{n}\boldsymbol{\Sigma} = (n-1)\boldsymbol{\Sigma}$. ■

1.5. Distancias

Medir qué tan lejos está un individuo de otro, o del centro de la nube, es la base del análisis de conglomerados y de la detección de valores atípicos.

Definición 1.6 *Sea* $\mathbf{A}$ *una matriz* $p \times p$ *simétrica definida positiva. La distancia inducida por* $\mathbf{A}$ *entre* $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ *es* $d_{\mathbf{A}}(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x}-\mathbf{y})'\mathbf{A}(\mathbf{x}-\mathbf{y})}$. *Casos particulares:*

1. ***Euclidiana****:* $\mathbf{A} = \mathbf{I}_p$.
2. ***Euclidiana estandarizada****:* $\mathbf{A} = \mathbf{D}^{-1}$, *con* $\mathbf{D} = \operatorname{diag}(s_{11}, \ldots, s_{pp})$.
3. ***Mahalanobis*** *(Mahalanobis 1936):* $\mathbf{A} = \boldsymbol{\Sigma}^{-1}$ *(o* $\mathbf{S}^{-1}$ *en la muestra),*

$$\Delta^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x}-\mathbf{y})'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\mathbf{y}). \tag{1.8}$$

La distancia euclidiana depende de las unidades: medir el ingreso en pesos o en miles de pesos cambia por completo qué individuos son "cercanos". La estandarizada corrige las unidades, pero ignora las correlaciones: dos variables muy correlacionadas, como ingreso y gasto, cuentan prácticamente la misma información dos veces. La distancia de Mahalanobis corrige ambas cosas.

Proposición 1.7 *La distancia de Mahalanobis es invariante ante transformaciones afines no singulares: si* $\mathbf{x}^* = \mathbf{C}\mathbf{x} + \mathbf{b}$ *con* $\mathbf{C}$ *invertible, entonces* $\boldsymbol{\Sigma}^* = \mathbf{C}\boldsymbol{\Sigma}\mathbf{C}'$ *y* $\Delta^*(\mathbf{x}^*, \mathbf{y}^*) = \Delta(\mathbf{x}, \mathbf{y})$. *Además,* $\Delta^2(\mathbf{x}, \mathbf{y}) = \|\boldsymbol{\Sigma}^{-1/2}(\mathbf{x}-\mathbf{y})\|^2$*: la distancia de Mahalanobis es la distancia euclidiana después de transformar los datos a variables no correlacionadas y de varianza unitaria.*

Demostración. Por la Proposición 1.5, $\boldsymbol{\Sigma}^* = \mathbf{C}\boldsymbol{\Sigma}\mathbf{C}'$. Entonces

$$\begin{aligned}(\mathbf{x}^*-\mathbf{y}^*)'(\boldsymbol{\Sigma}^*)^{-1}(\mathbf{x}^*-\mathbf{y}^*) &= (\mathbf{x}-\mathbf{y})'\mathbf{C}'(\mathbf{C}')^{-1}\boldsymbol{\Sigma}^{-1}\mathbf{C}^{-1}\mathbf{C}(\mathbf{x}-\mathbf{y}) \\ &= (\mathbf{x}-\mathbf{y})'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\mathbf{y}).\end{aligned}$$

Para la segunda afirmación, $\boldsymbol{\Sigma}^{-1} = \boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}^{-1/2}$ con $\boldsymbol{\Sigma}^{-1/2}$ simétrica (Apéndice A), y $\mathbf{z} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{x}-\boldsymbol{\mu})$ tiene $\operatorname{Cov}(\mathbf{z}) = \boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{-1/2} = \mathbf{I}_p$. ■

Ejemplo 1.7 (Euclidiana contra Mahalanobis) Con $\bar{\mathbf{x}} = (16, 13)'$ y $\mathbf{S}$ del Ejemplo 1.4,

$$\mathbf{S}^{-1} = \frac{1}{21.44}\begin{bmatrix} 12 & -17.6 \\ -17.6 & 27.6 \end{bmatrix}.$$

Consideremos dos hogares nuevos: A $= (19, 10)'$, que gana 3 mil pesos más que el promedio y gasta 3 mil menos, y B $= (19, 16)'$, que gana y gasta 3 mil más. Sus desviaciones respecto a la media son $\mathbf{v}_A = (3, -3)'$ y $\mathbf{v}_B = (3, 3)'$. Ambos están a la misma distancia euclidiana del centro, $\sqrt{18} = 4.24$. Sin embargo,

$$\Delta_A^2 = \frac{9(12) + 9(27.6) + 2(9)(17.6)}{21.44} = \frac{673.2}{21.44} = 31.40,$$
$$\Delta_B^2 = \frac{9(12) + 9(27.6) - 2(9)(17.6)}{21.44} = \frac{39.6}{21.44} = 1.85.$$

B se mueve *a lo largo* de la correlación (más ingreso, más gasto) y es un hogar típico. A se mueve *contra* ella: ahorra 9 mil pesos cuando el ahorro promedio es 3 mil con desviación estándar $\sqrt{4.4} = 2.1$ (Ejemplo 1.5). La distancia de Mahalanobis lo detecta; la euclidiana, no.

Ahora midamos el ingreso en pesos y el gasto en miles de pesos, es decir, $\mathbf{C} = \text{diag}(1000, 1)$. Las distancias euclidianas de A y de B al centro pasan a ser $\sqrt{3000^2 + 3^2} \approx 3000$: quedan dominadas por la variable con unidades más grandes. Las de Mahalanobis siguen siendo exactamente 31.40 y 1.85, como asegura la Proposición 1.7.

Los conjuntos $\{\mathbf{x} : \Delta^2(\mathbf{x}, \boldsymbol{\mu}) = c^2\}$ son elipsoides centrados en $\boldsymbol{\mu}$, cuyos ejes apuntan en las direcciones de los eigenvectores de $\boldsymbol{\Sigma}$ y tienen semilongitudes $c\sqrt{\lambda_j}$. Es la misma geometría que reaparece en componentes principales.

1.6. La distribución normal multivariada

Definición 1.7 *Un vector aleatorio $\mathbf{x} \in \mathbb{R}^p$ tiene distribución **normal multivariada** con media $\boldsymbol{\mu}$ y covarianza $\boldsymbol{\Sigma}$ (definida positiva), $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, si su densidad es*

$$f(\mathbf{x}) = (2\pi)^{-p/2} |\boldsymbol{\Sigma}|^{-1/2} \exp\left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \qquad \mathbf{x} \in \mathbb{R}^p. \quad (1.9)$$

La densidad depende de $\mathbf{x}$ sólo a través de la distancia de Mahalanobis $\Delta^2(\mathbf{x}, \boldsymbol{\mu})$: las curvas de nivel son los elipsoides de la sección anterior.

Teorema 1.8 *Sea $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.*

1. ***Combinaciones lineales.** Si $\mathbf{A} \in \mathbb{R}^{p \times q}$ tiene rango q, entonces $\mathbf{A}'\mathbf{x} + \mathbf{b} \sim N_q(\mathbf{A}'\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}'\boldsymbol{\Sigma}\mathbf{A})$. En particular, las marginales son normales.*

2. ***Independencia.*** *Dos subvectores de* $\mathbf{x}$ *son independientes si y sólo si su bloque de covarianzas es cero.*

3. ***Condicionales.*** *Particiónese*

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix}.$$

Entonces $\mathbf{x}_1 \mid \mathbf{x}_2 \sim N\left(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2),\ \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}\right)$.

4. ***Forma cuadrática.*** $(\mathbf{x} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \sim \chi^2_p$.

Demostración. (1) Usamos la función característica $\varphi_{\mathbf{x}}(\boldsymbol{t}) = \mathbb{E}[e^{i\boldsymbol{t}'\mathbf{x}}] = \exp\{i\boldsymbol{t}'\boldsymbol{\mu} - \frac{1}{2}\boldsymbol{t}'\boldsymbol{\Sigma}\boldsymbol{t}\}$. Para $\mathbf{y} = \mathbf{A}'\mathbf{x} + \mathbf{b}$, $\varphi_{\mathbf{y}}(\boldsymbol{s}) = e^{i\boldsymbol{s}'\mathbf{b}}\varphi_{\mathbf{x}}(\mathbf{A}\boldsymbol{s}) = \exp\{i\boldsymbol{s}'(\mathbf{A}'\boldsymbol{\mu} + \mathbf{b}) - \frac{1}{2}\boldsymbol{s}'\mathbf{A}'\boldsymbol{\Sigma}\mathbf{A}\boldsymbol{s}\}$, que es la función característica de $N_q(\mathbf{A}'\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}'\boldsymbol{\Sigma}\mathbf{A})$.

(2) Si $\boldsymbol{\Sigma}_{12} = \mathbf{0}$, entonces $\boldsymbol{\Sigma}^{-1}$ es diagonal por bloques, $|\boldsymbol{\Sigma}| = |\boldsymbol{\Sigma}_{11}||\boldsymbol{\Sigma}_{22}|$, y la densidad conjunta se factoriza en el producto de las marginales. El recíproco vale para cualquier distribución con segundos momentos finitos.

(3) Sea $\mathbf{B} = \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}$ y defínase $\boldsymbol{w} = \mathbf{x}_1 - \mathbf{B}\mathbf{x}_2$. Por (1), $(\boldsymbol{w}, \mathbf{x}_2)$ es conjuntamente normal, y $\operatorname{Cov}(\boldsymbol{w}, \mathbf{x}_2) = \boldsymbol{\Sigma}_{12} - \mathbf{B}\boldsymbol{\Sigma}_{22} = \mathbf{0}$, de modo que por (2) $\boldsymbol{w}$ es independiente de $\mathbf{x}_2$. Además $\mathbb{E}[\boldsymbol{w}] = \boldsymbol{\mu}_1 - \mathbf{B}\boldsymbol{\mu}_2$ y $\operatorname{Cov}(\boldsymbol{w}) = \boldsymbol{\Sigma}_{11} - \mathbf{B}\boldsymbol{\Sigma}_{21}$. Como $\mathbf{x}_1 = \boldsymbol{w} + \mathbf{B}\mathbf{x}_2$ y $\boldsymbol{w}$ no depende de $\mathbf{x}_2$, condicionando en $\mathbf{x}_2$ se obtiene el resultado.

(4) Sea $\mathbf{z} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{x} - \boldsymbol{\mu})$. Por (1), $\mathbf{z} \sim N_p(\mathbf{0}, \mathbf{I}_p)$, así que sus componentes son normales estándar independientes y $(\mathbf{x} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = \mathbf{z}'\mathbf{z} = \sum_{j=1}^{p} z_j^2 \sim \chi^2_p$. ∎

Observación 1.2 El inciso (3) conecta con el análisis de regresión: bajo normalidad conjunta, la esperanza condicional $\mathbb{E}[\mathbf{x}_1 \mid \mathbf{x}_2]$ es *exactamente* lineal en $\mathbf{x}_2$, con coeficientes $\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}$, que son la versión poblacional de los coeficientes de MCO, y la varianza condicional no depende de $\mathbf{x}_2$: hay homocedasticidad. La matriz $\boldsymbol{\Sigma}_{11\cdot 2} = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}$ (el complemento de Schur de $\boldsymbol{\Sigma}_{22}$) define las *covarianzas parciales*, que reaparecen en la medida KMO del análisis factorial.

Ejemplo 1.8 (Condicional normal y regresión) Supongamos que (ingreso, gasto) $\sim N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ con los valores del Ejemplo 1.4: $\boldsymbol{\mu} = (16, 13)'$ y

$\boldsymbol{\Sigma} = \mathbf{S}$. Por el Teorema 1.8(3), con $\mathbf{x}_1 =$ gasto y $\mathbf{x}_2 =$ ingreso,

$$\mathbb{E}[\text{gasto} \mid \text{ingreso} = x] = 13 + \frac{17.6}{27.6}(x - 16) = 13 + 0.638\,(x - 16),$$
$$\text{Var}(\text{gasto} \mid \text{ingreso}) = 12 - \frac{17.6^2}{27.6} = 12 - 11.22 = 0.78.$$

La pendiente $0.638 = s_{12}/s_{11}$ es exactamente la pendiente de MCO de gasto sobre ingreso en la muestra: la propensión marginal a gastar. Conocer el ingreso reduce la varianza del gasto de 12 a 0.78, es decir, en un $1 - 0.78/12 = 93.5\,\% = r_{12}^2$. Para un hogar con ingreso de 25 mil pesos, el gasto esperado es $13 + 0.638(9) = 18.74$ mil, con un intervalo de $95\,\%$ de $18.74 \pm 1.96\sqrt{0.78} = [17.01,\ 20.47]$. El hogar 5 de la muestra gasta 18 mil, dentro del intervalo.

Ejemplo 1.9 (Probabilidad de una distancia) Para $p = 2$, la distribución χ^2_2 tiene una forma cerrada: $P(\chi^2_2 > c) = e^{-c/2}$. Bajo el modelo del ejemplo anterior, el elipsoide $\{\mathbf{x} : \Delta^2(\mathbf{x}, \boldsymbol{\mu}) \leq 5.99\}$ contiene al $95\,\%$ de los hogares. El hogar A del Ejemplo 1.7, con $\Delta^2 = 31.40$, tiene probabilidad de cola $e^{-15.7} \approx 1.5 \times 10^{-7}$: es un caso extremadamente atípico (o un error de captura). El hogar B, con $\Delta^2 = 1.85$, tiene probabilidad de cola $e^{-0.92} = 0.40$.

Teorema 1.9 (Estimadores de máxima verosimilitud) *Si* $\mathbf{x}_1, \ldots, \mathbf{x}_n$ *es una muestra aleatoria de* $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ *con* $n > p$*, los estimadores de máxima verosimilitud son* $\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}$ *y* $\hat{\boldsymbol{\Sigma}} = \mathbf{S}$ *(con divisor* n*).*

Demostración. La log-verosimilitud es

$$\ell(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{np}{2}\log 2\pi - \frac{n}{2}\log|\boldsymbol{\Sigma}| - \frac{1}{2}\sum_{i=1}^{n}(\mathbf{x}_i - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}).$$

Usando la identidad de la Proposición 1.6 y $\boldsymbol{v}'\mathbf{A}\boldsymbol{v} = \text{tr}(\mathbf{A}\boldsymbol{v}\boldsymbol{v}')$,

$$\sum_{i=1}^{n}(\mathbf{x}_i - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}) = n\,\text{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S}) + n(\bar{\mathbf{x}} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}).$$

Como $\boldsymbol{\Sigma}^{-1}$ es definida positiva, el último término es mínimo (igual a cero) en $\boldsymbol{\mu} = \bar{\mathbf{x}}$ para cualquier $\boldsymbol{\Sigma}$. Sustituyendo,

$$\ell(\bar{\mathbf{x}}, \boldsymbol{\Sigma}) = \text{cte} - \frac{n}{2}\left[\log|\boldsymbol{\Sigma}| + \text{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S})\right].$$

Sean $\eta_1, \ldots, \eta_p > 0$ los eigenvalores de $\boldsymbol{\Sigma}^{-1}\mathbf{S}$, que son los mismos que los de $\mathbf{S}^{1/2}\boldsymbol{\Sigma}^{-1}\mathbf{S}^{1/2}$. Entonces

$$\log|\boldsymbol{\Sigma}| + \operatorname{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S}) = \log|\mathbf{S}| + \sum_{j=1}^{p}(\eta_j - \log\eta_j),$$

y como $\eta - \log\eta \geq 1$ con igualdad sólo en $\eta = 1$, el mínimo se alcanza cuando todos los $\eta_j = 1$, es decir, $\boldsymbol{\Sigma}^{-1}\mathbf{S} = \mathbf{I}_p$, o sea $\boldsymbol{\Sigma} = \mathbf{S}$. ■

1.6.1. Evaluación de la normalidad multivariada

La normalidad de cada marginal no implica normalidad conjunta, por lo que conviene revisar la distribución multivariada directamente. Dos herramientas habituales:

1. **Gráfica Q–Q ji-cuadrada.** Por el Teorema 1.8(4), las distancias $d_i^2 = (\mathbf{x}_i - \bar{\mathbf{x}})'\mathbf{S}^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$ son aproximadamente χ^2_p. Se grafican los $d^2_{(i)}$ ordenados contra los cuantiles $\chi^2_p\left((i-1/2)/n\right)$; bajo normalidad los puntos caen sobre la recta de 45 grados. Esta misma gráfica identifica **valores atípicos multivariados**: observaciones con d_i^2 por encima, por ejemplo, de $\chi^2_{p;\,0.999}$.

2. **Pruebas de Mardia** (Mardia 1970). Con $g_{ij} = (\mathbf{x}_i - \bar{\mathbf{x}})'\mathbf{S}^{-1}(\mathbf{x}_j - \bar{\mathbf{x}})$ se definen la asimetría $b_{1,p} = n^{-2}\sum_{i,j} g_{ij}^3$ y la curtosis $b_{2,p} = n^{-1}\sum_i g_{ii}^2$. Bajo normalidad, $\frac{n}{6}b_{1,p} \to \chi^2_{p(p+1)(p+2)/6}$ y $(b_{2,p} - p(p+2))/\sqrt{8p(p+2)/n} \to N(0,1)$.

Ejemplo 1.10 (Distancias de la muestra) Para los cinco hogares del Ejemplo 1.2, las distancias $d_i^2 = (\mathbf{x}_i - \bar{\mathbf{x}})'\mathbf{S}^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$ son 1.34, 0.84, 0.21, 3.97 y 3.64. Ninguna supera $\chi^2_{2;\,0.95} = 5.99$. Su suma es exactamente $10 = np$, lo cual no es casualidad: $\sum_i d_i^2 = \operatorname{tr}\left(\mathbf{S}^{-1}\sum_i (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'\right) = n\operatorname{tr}(\mathbf{S}^{-1}\mathbf{S}) = np$. Por eso el promedio de las d_i^2 siempre es p, que coincide con la media de una χ^2_p. Con $n = 5$, sin embargo, ninguna prueba de normalidad tiene potencia; el ejemplo sólo ilustra el cálculo.

En este curso la normalidad se usa en el análisis factorial por máxima verosimilitud y en algunas pruebas formales, como la de esfericidad de Bartlett. Componentes principales, k-medias y conglomerados jerárquicos son procedimientos descriptivos que no la requieren, aunque son sensibles a valores atípicos.

1.7. Filosofía de trabajo de una técnica multivariada

Las técnicas de este curso siempre producen una respuesta: el algoritmo k-medias entregará k grupos aunque los datos no tengan ninguna estructura de grupos, y el análisis factorial entregará factores aunque las variables sean independientes. Por eso la parte metodológica no es un accesorio. Siguiendo a Hair et al. (2006, Cap. 1), adoptamos los siguientes principios:

1. **La teoría precede a la técnica.** Las variables se eligen porque hay razones sustantivas para pensar que miden el fenómeno de interés (bienestar, carencias, comportamiento del consumidor), no porque estén disponibles.

2. **Significancia estadística no es relevancia práctica.** Con n grande, cualquier correlación distinta de cero es "significativa". Lo que importa es la magnitud: qué proporción de la varianza explica un factor, o qué tan distintos son dos segmentos en las variables que importan para la decisión.

3. **El tamaño de muestra condiciona lo que se puede estimar.** Una matriz $p \times p$ tiene $p(p+1)/2$ parámetros; con $p = 30$ son 465. Como guía, en análisis factorial se piden al menos 5 a 10 observaciones por variable.

4. **Parsimonia.** Entre dos soluciones con ajuste similar, se prefiere la que tiene menos factores o menos grupos y una interpretación más clara.

5. **Datos faltantes.** Antes de eliminar observaciones incompletas, hay que entender el mecanismo (Little y Rubin 2019): completamente al azar (MCAR), al azar condicional en lo observado (MAR) o no aleatorio (MNAR). Eliminar casos sólo es inocuo, en términos de sesgo, bajo MCAR.

6. **Valores atípicos.** Se detectan con la distancia de Mahalanobis (Sección 1.6) y se decide, con criterio sustantivo, si son errores de captura, casos legítimos pero extremos (que pueden dominar una covarianza) o la señal misma de interés.

7. **Validación.** Una solución que sólo existe en la muestra con la que se estimó no es un hallazgo. Se valida con submuestras, con otra base de datos o por estabilidad ante perturbaciones.

1.8. Etapas en el desarrollo de una técnica multivariada

Hair et al. (2006) proponen un proceso de seis etapas que usaremos como estructura común en cada capítulo y en el proyecto del curso:

1. **Definir el problema, los objetivos y la técnica.** ¿Qué pregunta sustantiva se quiere responder? ¿Se busca reducir dimensiones (componentes, factores), construir un índice o agrupar individuos (conglomerados)?

2. **Diseñar el plan de análisis.** Elegir las variables y su escala, la unidad de análisis (hogar, municipio, cliente), el tamaño de muestra, y cómo se tratarán los datos faltantes y la estandarización.

3. **Evaluar los supuestos.** Linealidad, normalidad cuando se requiera, suficiente correlación entre variables (análisis factorial) o tendencia a formar grupos (conglomerados), y valores atípicos.

4. **Estimar el modelo y evaluar el ajuste global.** Número de factores o de grupos, varianza explicada, índices de ajuste.

5. **Interpretar el valor teórico.** Nombrar los factores a partir de sus cargas, perfilar los grupos a partir de sus centroides.

6. **Validar.** Estabilidad de la solución, validez de criterio (¿el índice se asocia con variables externas como se esperaría?) y utilidad práctica.

Ejemplo 1.11 (Hilo conductor del curso) Con los microdatos de la ENIGH 2024 (INEGI), queremos describir las condiciones socioeconómicas de los hogares en las 32 entidades federativas. (1) El objetivo es construir un índice estatal de condiciones socioeconómicas y una tipología de las entidades. (2) La unidad de análisis es la entidad federativa, y se usan seis indicadores métricos, estandarizados, construidos a partir de los hogares: ingreso per cápita, escolaridad del jefe del hogar, proporción de menores,

proporción de perceptores de ingreso, proporción de adultos mayores y peso del ingreso laboral. (3) Se revisan las correlaciones y los valores atípicos. (4) Se estima un análisis factorial (Capítulo 3), con los indicadores del factor socioeconómico se construye un índice (Capítulo 4) y, con las puntuaciones factoriales, se segmenta a las entidades con conglomerados (Capítulo 5). (5) Se interpretan las cargas y se perfilan los segmentos. (6) Se valida contrastando el índice con variables que no entraron en su construcción, como la proporción del gasto destinada a alimentos (ley de Engel).

1.9. Implementación en Python

El siguiente fragmento calcula los objetos de este capítulo. El cuaderno `01 Intro/01 Fundamentos/Fundamentos_Multivariante.ipynb` del repositorio reproduce todos los ejemplos numéricos con los cinco hogares y propone el ejercicio computacional con `Country-data.csv`.

```
import numpy as np
from scipy import stats

def resumen_multivariante(X):
    """X: arreglo n x p. Devuelve media, S (divisor n), R y
       distancias de Mahalanobis."""
    n, p = X.shape
    H = np.eye(n) - np.ones((n, n)) / n # matriz de centrado
    Xc = H @ X # equivale a X - X.mean(axis=0)
    xbar = X.mean(axis=0)
    S = Xc.T @ Xc / n
    d = np.sqrt(np.diag(S))
    R = S / np.outer(d, d)
    d2 = np.einsum('ij,jk,ik->i', Xc, np.linalg.inv(S), Xc) #
       Mahalanobis^2
    return xbar, S, R, d2

# Q-Q ji-cuadrada: comparar d2 ordenadas contra cuantiles teoricos
# q = stats.chi2.ppf((np.arange(1, n + 1) - 0.5) / n, df=p)
```

En la práctica no se construye $\mathbf{H}$ explícitamente (es $n \times n$), sino que se resta la media por columnas; la matriz aparece aquí para mostrar la correspondencia con las fórmulas.

1.10. Ejercicios

1. Clasifique cada técnica según la Sección 1.1 y justifique: (a) predecir si un hogar es pobre a partir de sus características; (b) agrupar municipios según su perfil de servicios públicos; (c) resumir 20 reactivos de un cuestionario de satisfacción en pocas dimensiones.

2. Para cada variable de la ENIGH que elija (al menos seis), determine su escala de medición y los estadísticos que tienen sentido. ¿Es razonable calcular la media del "nivel de escolaridad" codificado de 0 a 11?

3. Demuestre que, para n impar, la mediana conmuta con cualquier transformación estrictamente creciente: $\text{med}(g(x_1), \dots, g(x_n)) = g(\text{med}(x_1, \dots, x_n))$. Concluya que la comparación de medianas es significativa en escala ordinal (contraste con el Ejemplo 1.1).

4. Con los datos del Ejemplo 1.2, agregue un sexto hogar $(20, 19)'$. Recalcule $\bar{\mathbf{x}}$, $\mathbf{S}$, $\mathbf{R}$, los eigenvalores de $\mathbf{S}$ y la distancia de Mahalanobis del nuevo hogar. ¿Qué le ocurre a la correlación? ¿Por qué?

5. Demuestre que $\mathbf{S} = \frac{1}{n}\mathbf{X}'\mathbf{X} - \bar{\mathbf{x}}\bar{\mathbf{x}}'$.

6. Sean $p = 2$, $s_{11} = s_{22} = 1$ y $s_{12} = r$. Calcule los eigenvalores y eigenvectores de $\mathbf{S}$, la varianza total y la varianza generalizada como funciones de r. Interprete los casos $r = 0$ y $|r| \to 1$.

7. Demuestre que la matriz de correlaciones de $\mathbf{Z} = \mathbf{H}\mathbf{X}\mathbf{D}^{-1/2}$ (datos estandarizados) es $\mathbf{R}$ y que $\text{tr}(\mathbf{R}) = p$.

8. Sea $\mathbf{x} \sim N_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ con $\boldsymbol{\mu} = (1, 0, 2)'$ y $\boldsymbol{\Sigma} = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 3 \end{bmatrix}$. (a) Encuentre la distribución de $x_1 - x_2 + x_3$. (b) Encuentre la distribución de $x_1 \mid (x_2, x_3)$. (c) ¿Son independientes x_1 y x_3? ¿Lo son condicionalmente en x_2?

9. Demuestre que la distancia euclidiana estandarizada coincide con la de Mahalanobis si y sólo si $\mathbf{R} = \mathbf{I}_p$.

10. (Computacional) Con la base `Country-data.csv` del repositorio, calcule $\bar{\mathbf{x}}$, $\mathbf{S}$, $\mathbf{R}$, la varianza generalizada y las distancias de Mahalanobis;

elabore la gráfica Q–Q ji-cuadrada e identifique los cinco países más atípicos. ¿Cambia la lista si usa la distancia euclidiana estandarizada? Explique.

2

Análisis de Componentes Principales

El análisis de componentes principales (PCA, por sus siglas en inglés) es la técnica básica de *reducción de dimensión*. Dadas p variables correlacionadas, busca un número menor $k < p$ de combinaciones lineales no correlacionadas entre sí, los **componentes principales**, que conserven la mayor parte posible de la variabilidad de los datos. La idea tiene dos orígenes independientes: Pearson (1901) buscaba las rectas y los planos que mejor se ajustan a una nube de puntos, y Hotelling (1933) buscaba un número pequeño de variables que resumieran un conjunto grande de mediciones psicológicas. Veremos que ambos problemas tienen la misma solución: los eigenvectores de la matriz de covarianzas.

El capítulo sigue a Johnson y Wichern (2007, Cap. 8), Mardia, Kent y Bibby (1979, Cap. 8) y Jolliffe (2002); la presentación como técnica de aprendizaje no supervisado sigue a James et al. (2021, Cap. 12) y Hastie, Tibshirani y Friedman (2017, Sec. 14.5). Usa intensivamente el teorema espectral y el cociente de Rayleigh (Apéndice A).

En el curso, PCA cumple tres funciones: (i) es una técnica descriptiva por derecho propio; (ii) es el punto de partida del análisis factorial (Capítulo 3), que usa los componentes principales como uno de sus métodos de estimación; y (iii) es una de las formas de ponderar variables al construir índices compuestos (Capítulo 4).

Datos de trabajo. Además de los cinco hogares del Capítulo 1, usaremos seis países americanos con tres indicadores tomados de la base

`Country-data.csv` del repositorio del curso (Kokkula 2020): mortalidad infantil (x_1, muertes de menores de cinco años por cada mil nacidos vivos), ingreso neto por persona (x_2, dólares) y exportaciones (x_3, porcentaje del PIB).

Cuadro 2.1: Datos de trabajo del capítulo: seis países

País	Mort. infantil	Ingreso (USD)	Exportaciones (% PIB)
Canadá	5.6	40 700	29.1
Chile	8.7	19 400	37.7
Colombia	18.6	10 900	15.9
Perú	20.3	9 960	27.8
Bolivia	46.6	5 410	41.2
Guatemala	35.4	6 710	25.8
Media	22.53	15 513.33	29.58
Desv. est. (n)	14.40	12 118.67	8.22

2.1. Componentes principales poblacionales

Sea $\mathbf{x} \in \mathbb{R}^p$ un vector aleatorio con media $\boldsymbol{\mu}$ y matriz de covarianzas $\boldsymbol{\Sigma}$, y sea $\boldsymbol{\Sigma} = \boldsymbol{\Gamma}\boldsymbol{\Lambda}\boldsymbol{\Gamma}'$ su descomposición espectral (Teorema A.2), con $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$ y eigenvectores ortonormales $\boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_p$.

Queremos una combinación lineal $y = \mathbf{a}'\mathbf{x}$ con varianza máxima. Sin restricción el problema no tiene solución, porque $\operatorname{Var}(c\,\mathbf{a}'\mathbf{x}) = c^2 \operatorname{Var}(\mathbf{a}'\mathbf{x})$ crece sin límite; por eso se normaliza $\mathbf{a}'\mathbf{a} = 1$.

Definición 2.1 *El **primer componente principal** de $\mathbf{x}$ es $y_1 = \mathbf{a}_1'\mathbf{x}$, donde $\mathbf{a}_1$ maximiza $\operatorname{Var}(\mathbf{a}'\mathbf{x})$ sujeto a $\mathbf{a}'\mathbf{a} = 1$. Para $k = 2, \ldots, p$, el **k-ésimo componente principal** es $y_k = \mathbf{a}_k'\mathbf{x}$, donde $\mathbf{a}_k$ maximiza $\operatorname{Var}(\mathbf{a}'\mathbf{x})$ sujeto a $\mathbf{a}'\mathbf{a} = 1$ y $\operatorname{Cov}(\mathbf{a}'\mathbf{x}, y_j) = 0$ para $j = 1, \ldots, k-1$. El vector $\mathbf{a}_k$ se llama **vector de cargas** (*loadings*) del componente k.*

Teorema 2.1 *Los componentes principales de $\mathbf{x}$ son $y_k = \boldsymbol{\gamma}_k'\mathbf{x}$, $k = 1, \ldots, p$, y satisfacen:*

1. $\operatorname{Var}(y_k) = \lambda_k$ *y* $\operatorname{Cov}(y_j, y_k) = 0$ *para* $j \neq k$.

2. $\sum_{k=1}^{p} \mathrm{Var}(y_k) = \sum_{k=1}^{p} \lambda_k = \mathrm{tr}(\boldsymbol{\Sigma}) = \sum_{j=1}^{p} \mathrm{Var}(x_j)$*: los componentes reparten, sin perderla, la varianza total.*

Si los eigenvalores son distintos, cada $\boldsymbol{\gamma}_k$ es único salvo el signo.

Demostración. Por la Proposición 1.5, $\mathrm{Var}(\mathbf{a}'\mathbf{x}) = \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a}$. El primer problema es, entonces, maximizar el cociente de Rayleigh $\mathbf{a}'\boldsymbol{\Sigma}\mathbf{a}/\mathbf{a}'\mathbf{a}$, cuyo máximo λ_1 se alcanza en $\mathbf{a} = \boldsymbol{\gamma}_1$ (Teorema A.4).

Para $k \geq 2$, supongamos (hipótesis de inducción) que $y_j = \boldsymbol{\gamma}_j'\mathbf{x}$ para $j < k$. Entonces

$$\mathrm{Cov}(\mathbf{a}'\mathbf{x}, y_j) = \mathbf{a}'\boldsymbol{\Sigma}\boldsymbol{\gamma}_j = \lambda_j\, \mathbf{a}'\boldsymbol{\gamma}_j.$$

Si $\lambda_j > 0$, la restricción de no correlación equivale a $\mathbf{a} \perp \boldsymbol{\gamma}_j$. (Si $\lambda_j = 0$, la restricción se cumple trivialmente, pero entonces todos los eigenvalores restantes también son cero y la varianza máxima alcanzable es cero.) Así, el problema es maximizar $\mathbf{a}'\boldsymbol{\Sigma}\mathbf{a}/\mathbf{a}'\mathbf{a}$ sobre $\mathbf{a} \perp \boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_{k-1}$, y por la segunda parte del Teorema A.4 el máximo es λ_k, alcanzado en $\boldsymbol{\gamma}_k$.

Para (1), $\mathrm{Cov}(y_j, y_k) = \boldsymbol{\gamma}_j'\boldsymbol{\Sigma}\boldsymbol{\gamma}_k = \lambda_k\boldsymbol{\gamma}_j'\boldsymbol{\gamma}_k = \lambda_k\delta_{jk}$. Para (2), $\sum_k \lambda_k = \mathrm{tr}(\boldsymbol{\Lambda}) = \mathrm{tr}(\boldsymbol{\Gamma}'\boldsymbol{\Sigma}\boldsymbol{\Gamma}) = \mathrm{tr}(\boldsymbol{\Sigma}\boldsymbol{\Gamma}\boldsymbol{\Gamma}') = \mathrm{tr}(\boldsymbol{\Sigma})$.

Finalmente, si λ_k es un eigenvalor simple, el eigenespacio correspondiente tiene dimensión uno y los únicos vectores unitarios en él son $\pm\boldsymbol{\gamma}_k$. ■

Observación 2.1 (El signo es arbitrario) Si $\boldsymbol{\gamma}_k$ es un vector de cargas, $-\boldsymbol{\gamma}_k$ también lo es. Distintos programas pueden reportar signos opuestos para el mismo componente; la interpretación no cambia, sólo se invierte la dirección del eje. En las notas fijaremos el signo para que la interpretación sea natural (por ejemplo, que el ingreso cargue positivamente).

En forma matricial, el vector de componentes es $\mathbf{y} = \boldsymbol{\Gamma}'(\mathbf{x} - \boldsymbol{\mu})$, que es una rotación rígida de los datos centrados (pues $\boldsymbol{\Gamma}$ es ortogonal), y $\mathrm{Cov}(\mathbf{y}) = \boldsymbol{\Gamma}'\boldsymbol{\Sigma}\boldsymbol{\Gamma} = \boldsymbol{\Lambda}$. PCA, entonces, *rota los ejes* hasta alinearlos con los ejes del elipsoide de concentración $\{\mathbf{x} : (\mathbf{x} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2\}$ que vimos en la Sección 1.5.

Definición 2.2 *La **proporción de varianza explicada** por el componente k es $\lambda_k / \sum_{j=1}^{p} \lambda_j$, y la proporción acumulada por los primeros m componentes es $\sum_{k=1}^{m} \lambda_k / \sum_{j=1}^{p} \lambda_j$.*

Proposición 2.2 *La correlación entre el componente y_k y la variable original x_j es*

$$\operatorname{Corr}(y_k, x_j) = \frac{\gamma_{jk}\sqrt{\lambda_k}}{\sqrt{\sigma_{jj}}}, \tag{2.1}$$

donde γ_{jk} es el elemento j del vector $\boldsymbol{\gamma}_k$.

Demostración. Con $\mathbf{e}_j$ el j-ésimo vector canónico, $\operatorname{Cov}(y_k, x_j) = \operatorname{Cov}(\boldsymbol{\gamma}_k'\mathbf{x}, \mathbf{e}_j'\mathbf{x}) = \mathbf{e}_j'\boldsymbol{\Sigma}\boldsymbol{\gamma}_k = \lambda_k\gamma_{jk}$. Dividiendo entre $\sqrt{\operatorname{Var}(y_k)\operatorname{Var}(x_j)} = \sqrt{\lambda_k\sigma_{jj}}$ se obtiene el resultado. ■

Las cargas γ_{jk} dicen cómo se *construye* el componente a partir de las variables; las correlaciones $\operatorname{Corr}(y_k, x_j)$ dicen cuánto del comportamiento de cada variable *refleja* el componente. Cuando las variables tienen escalas muy distintas, ambas cosas pueden diferir mucho; para interpretar conviene mirar las correlaciones.

2.2. ¿Covarianzas o correlaciones?

Los componentes principales *no* son invariantes ante cambios de escala: si se multiplica una variable por una constante grande, su varianza crece y termina dominando el primer componente. La solución habitual es estandarizar las variables, $z_j = (x_j - \mu_j)/\sqrt{\sigma_{jj}}$, y aplicar PCA a $\mathbf{z}$, cuya matriz de covarianzas es la matriz de correlaciones $\mathbf{P}$.

Proposición 2.3 *Sean λ_k y $\boldsymbol{\gamma}_k$ los eigenvalores y eigenvectores de $\mathbf{P}$, y $y_k = \boldsymbol{\gamma}_k'\mathbf{z}$. Entonces:*

1. *$\sum_k \lambda_k = p$, de modo que el eigenvalor promedio es 1.*
2. *$\operatorname{Corr}(y_k, z_j) = \gamma_{jk}\sqrt{\lambda_k}$.*
3. *Para cada variable, $\sum_{k=1}^{p} \operatorname{Corr}^2(y_k, z_j) = 1$; para cada componente, $\sum_{j=1}^{p} \operatorname{Corr}^2(y_k, z_j) = \lambda_k$.*

Demostración. (1) $\operatorname{tr}(\mathbf{P}) = p$ porque su diagonal son unos. (2) Es la Proposición 2.2 con $\sigma_{jj} = 1$. (3) $\sum_k \gamma_{jk}^2\lambda_k$ es el elemento (j,j) de $\boldsymbol{\Gamma}\boldsymbol{\Lambda}\boldsymbol{\Gamma}' = \mathbf{P}$, que vale 1. Por otra parte, $\sum_j \gamma_{jk}^2\lambda_k = \lambda_k\|\boldsymbol{\gamma}_k\|^2 = \lambda_k$. ■

Ejemplo 2.1 (Dos variables estandarizadas: solución cerrada) Si $p = 2$ y $\mathbf{P} = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}$ con $\rho > 0$, la ecuación característica es $(1-\lambda)^2 - \rho^2 = 0$, de donde

$$\lambda_1 = 1 + \rho, \quad \boldsymbol{\gamma}_1 = \tfrac{1}{\sqrt{2}}(1, 1)', \qquad \lambda_2 = 1 - \rho, \quad \boldsymbol{\gamma}_2 = \tfrac{1}{\sqrt{2}}(1, -1)'.$$

Las *direcciones* no dependen de ρ: el primer componente siempre es el promedio (escalado) de las dos variables estandarizadas y el segundo, su diferencia. Lo único que depende de ρ es cuánta varianza explica cada uno: $(1 + \rho)/2$ y $(1 - \rho)/2$. Para los hogares del Capítulo 1, con $r_{12} = 0.967$, el primer componente explica el $1.967/2 = 98.4\,\%$ de la varianza de los datos estandarizados.

Ejemplo 2.2 (El efecto de las unidades) Con los mismos hogares pero sin estandarizar, el primer eigenvector de $\mathbf{S}$ es $(0.838, 0.545)'$ y explica el $98.6\,\%$ (Ejemplo 1.6). Si el ingreso se mide en pesos y el gasto en miles de pesos, la nueva matriz de covarianzas es $\mathbf{CSC}$ con $\mathbf{C} = \mathrm{diag}(1000, 1)$: s_{11} pasa a ser $27\,600\,000$. Su primer eigenvector es $(1.000, 0.0006)'$ y explica el $99.99999\,\%$ de la varianza total. El "primer componente" ya no resume nada: es simplemente el ingreso, porque es la variable con los números más grandes.

Lo mismo ocurre con los seis países del Cuadro 2.1. Las varianzas son $s_{11} = 207.2$, $s_{22} \approx 1.469 \times 10^8$ y $s_{33} = 67.6$; el primer componente de $\mathbf{S}$ tiene cargas $(0.0009, -1.000, 0.000)'$ y concentra el $99.9999\,\%$ de la varianza total. Un análisis con $\mathbf{S}$ aquí sólo "descubre" que el ingreso se mide en dólares.

Regla práctica. Use $\mathbf{S}$ sólo cuando todas las variables estén en las mismas unidades y sus varianzas sean comparables en sentido sustantivo; por ejemplo, gastos en distintos rubros, todos en pesos. En cualquier otro caso, use $\mathbf{R}$. En el resto del capítulo trabajaremos con $\mathbf{R}$ salvo que se indique lo contrario.

2.3. Componentes principales muestrales

En la práctica $\boldsymbol{\Sigma}$ (o $\mathbf{P}$) es desconocida y se sustituye por $\mathbf{S}$ (o $\mathbf{R}$). Sea $\mathbf{Z}$ la matriz de datos estandarizados, $z_{ij} = (x_{ij} - \bar{x}_j)/\sqrt{s_{jj}}$, de modo que $\mathbf{R} = \frac{1}{n}\mathbf{Z}'\mathbf{Z}$, y sea $\mathbf{R} = \boldsymbol{GLG}'$ su descomposición espectral, con $\boldsymbol{L} = \mathrm{diag}(l_1, \ldots, l_p)$.

Definición 2.3 *Las **puntuaciones** (*scores*) de los componentes principales muestrales son las columnas de*

$$\mathbf{Y} = \mathbf{Z}\boldsymbol{G} \in \mathbb{R}^{n\times p}, \qquad y_{ik} = \boldsymbol{g}_k'\mathbf{z}_i. \tag{2.2}$$

La fila i de $\mathbf{Y}$ contiene las coordenadas del individuo i en el nuevo sistema de ejes.

Por la Proposición 1.4, las columnas de $\mathbf{Y}$ tienen media cero y matriz de covarianzas $\boldsymbol{G}'\mathbf{R}\boldsymbol{G} = \boldsymbol{L}$: las puntuaciones de distintos componentes no están correlacionadas en la muestra, y la varianza muestral del componente k es l_k.

Proposición 2.4 (PCA mediante la SVD) *Sea $\mathbf{Z} = \mathbf{U}\mathbf{D}\mathbf{V}'$ la descomposición en valores singulares de la matriz estandarizada (Teorema A.5). Entonces los vectores de cargas son las columnas de $\mathbf{V}$, los eigenvalores son $l_k = d_k^2/n$ y las puntuaciones son $\mathbf{Y} = \mathbf{U}\mathbf{D}$.*

Demostración. $\mathbf{R} = \frac{1}{n}\mathbf{Z}'\mathbf{Z} = \frac{1}{n}\mathbf{V}\mathbf{D}\mathbf{U}'\mathbf{U}\mathbf{D}\mathbf{V}' = \mathbf{V}\left(\frac{1}{n}\mathbf{D}^2\right)\mathbf{V}'$, que es una descomposición espectral de $\mathbf{R}$; de ahí $\boldsymbol{G} = \mathbf{V}$ y $l_k = d_k^2/n$. Además, $\mathbf{Y} = \mathbf{Z}\mathbf{V} = \mathbf{U}\mathbf{D}\mathbf{V}'\mathbf{V} = \mathbf{U}\mathbf{D}$. ■

Los programas de cómputo (por ejemplo, `sklearn.decomposition.PCA`) usan la SVD: es numéricamente más estable que formar $\mathbf{Z}'\mathbf{Z}$ y diagonalizarla.

Ejemplo 2.3 (Seis países: matriz de correlaciones y eigenvalores) Estandarizando el Cuadro 2.1 con las medias y desviaciones estándar (divisor $n = 6$) de su última fila, se obtiene

$$\mathbf{Z} = \begin{bmatrix} -1.176 & 2.078 & -0.059 \\ -0.961 & 0.321 & 0.987 \\ -0.273 & -0.381 & -1.664 \\ -0.155 & -0.458 & -0.217 \\ 1.672 & -0.834 & 1.413 \\ 0.894 & -0.726 & -0.460 \end{bmatrix},$$

$$\mathbf{R} = \frac{1}{6}\mathbf{Z}'\mathbf{Z} = \begin{bmatrix} 1 & -0.770 & 0.260 \\ -0.770 & 1 & 0.014 \\ 0.260 & 0.014 & 1 \end{bmatrix}.$$

La mortalidad infantil y el ingreso tienen una correlación negativa fuerte; las exportaciones están prácticamente no correlacionadas con el ingreso. Los eigenvalores de $\mathbf{R}$ son

$$l_1 = 1.809, \qquad l_2 = 1.008, \qquad l_3 = 0.183,$$

que suman $3 = p$, y explican el 60.3 %, 33.6 % y 6.1 % de la varianza; los dos primeros acumulan el 93.9 %. Los vectores de cargas (columnas de $\boldsymbol{G}$) son

$$\boldsymbol{G} = \begin{bmatrix} -0.709 & 0.014 & 0.705 \\ 0.671 & 0.320 & 0.669 \\ -0.216 & 0.948 & -0.236 \end{bmatrix}.$$

Puede verificarse a mano que $\mathbf{R}\boldsymbol{g}_1 = (-1.282, 1.214, -0.391)' = 1.809\,\boldsymbol{g}_1$, salvo redondeo.

2.4. Optimalidad: la mejor aproximación de dimensión baja

La definición de Hotelling (máxima varianza) tiene un equivalente geométrico, que es el de Pearson: los primeros k componentes generan el subespacio de dimensión k que está *más cerca* de los datos. Para demostrarlo necesitamos un lema.

Lema 2.5 (Ky Fan) *Sea* $\mathbf{A}$ *simétrica* $p \times p$ *con eigenvalores* $\lambda_1 \geq \cdots \geq \lambda_p$ *y eigenvectores ortonormales* $\boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_p$*. Para toda matriz* $\mathbf{Q} \in \mathbb{R}^{p \times k}$ *con columnas ortonormales (*$\mathbf{Q}'\mathbf{Q} = \mathbf{I}_k$*),*

$$\operatorname{tr}(\mathbf{Q}'\mathbf{A}\mathbf{Q}) \leq \lambda_1 + \cdots + \lambda_k, \tag{2.3}$$

con igualdad si $\mathbf{Q} = [\boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_k]$ *(Fan 1949).*

Demostración. Escriba $\mathbf{A} = \sum_j \lambda_j \boldsymbol{\gamma}_j \boldsymbol{\gamma}_j'$. Entonces

$$\operatorname{tr}(\mathbf{Q}'\mathbf{A}\mathbf{Q}) = \sum_{j=1}^{p} \lambda_j \operatorname{tr}(\mathbf{Q}'\boldsymbol{\gamma}_j\boldsymbol{\gamma}_j'\mathbf{Q}) = \sum_{j=1}^{p} \lambda_j h_j, \qquad h_j = \|\mathbf{Q}'\boldsymbol{\gamma}_j\|^2.$$

Los pesos h_j cumplen dos condiciones. Primero, $0 \leq h_j \leq 1$: $\mathbf{Q}\mathbf{Q}'$ es la proyección ortogonal sobre el espacio columna de $\mathbf{Q}$, y $h_j = \boldsymbol{\gamma}_j'\mathbf{Q}\mathbf{Q}'\boldsymbol{\gamma}_j$ es la

norma al cuadrado de la proyección de un vector unitario. Segundo, $\sum_j h_j = \operatorname{tr}(\mathbf{Q}'\boldsymbol{\Gamma}\boldsymbol{\Gamma}'\mathbf{Q}) = \operatorname{tr}(\mathbf{Q}'\mathbf{Q}) = k$. El máximo de $\sum_j \lambda_j h_j$ sujeto a esas restricciones se alcanza poniendo peso 1 en los k eigenvalores más grandes. Para verlo, note que

$$\sum_{j=1}^{k} \lambda_j - \sum_{j=1}^{p} \lambda_j h_j = \sum_{j=1}^{k} (\lambda_j - \lambda_k)(1 - h_j) + \sum_{j=k+1}^{p} (\lambda_k - \lambda_j) h_j \geq 0,$$

identidad que se verifica usando $\sum_j h_j = k$. La igualdad se alcanza con $h_1 = \cdots = h_k = 1$, es decir, con $\mathbf{Q} = [\boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_k]$. ■

Teorema 2.6 (Pearson, 1901) *Sean $\mathbf{z}_1, \ldots, \mathbf{z}_n \in \mathbb{R}^p$ datos centrados con matriz de covarianzas $\mathbf{R} = \frac{1}{n}\sum_i \mathbf{z}_i \mathbf{z}_i'$, y sea $\mathbf{Q} \in \mathbb{R}^{p \times k}$ con columnas ortonormales. El error cuadrático de proyectar los datos sobre el espacio columna de $\mathbf{Q}$,*

$$E(\mathbf{Q}) = \sum_{i=1}^{n} \|\mathbf{z}_i - \mathbf{Q}\mathbf{Q}'\mathbf{z}_i\|^2, \tag{2.4}$$

se minimiza con $\mathbf{Q} = [\boldsymbol{g}_1, \ldots, \boldsymbol{g}_k]$, los primeros k vectores de cargas, y su valor mínimo es $n(l_{k+1} + \cdots + l_p)$.

Demostración. Como $\mathbf{Q}\mathbf{Q}'$ es una proyección ortogonal, el teorema de Pitágoras da $\|\mathbf{z}_i\|^2 = \|\mathbf{Q}\mathbf{Q}'\mathbf{z}_i\|^2 + \|\mathbf{z}_i - \mathbf{Q}\mathbf{Q}'\mathbf{z}_i\|^2$ y $\|\mathbf{Q}\mathbf{Q}'\mathbf{z}_i\|^2 = \mathbf{z}_i'\mathbf{Q}\mathbf{Q}'\mathbf{z}_i$. Sumando sobre i,

$$E(\mathbf{Q}) = \sum_i \|\mathbf{z}_i\|^2 - \sum_i \operatorname{tr}(\mathbf{Q}'\mathbf{z}_i\mathbf{z}_i'\mathbf{Q}) = n \operatorname{tr}(\mathbf{R}) - n \operatorname{tr}(\mathbf{Q}'\mathbf{R}\mathbf{Q}).$$

Minimizar E equivale a maximizar $\operatorname{tr}(\mathbf{Q}'\mathbf{R}\mathbf{Q})$, y por el Lema 2.5 el máximo es $l_1 + \cdots + l_k$, alcanzado en los primeros k eigenvectores. El mínimo de E es $n\sum_{j=1}^{p} l_j - n\sum_{j=1}^{k} l_j$. ■

Así, maximizar la varianza de las proyecciones (Hotelling) y minimizar la distancia de los puntos al subespacio (Pearson) son el mismo problema: por Pitágoras, la varianza total, que es fija, es la suma de la varianza "capturada" más la "perdida". El Teorema 2.6 es un caso particular del teorema de Eckart–Young (Teorema A.6), que afirma que $\mathbf{X}_k = \sum_{j \leq k} d_j \mathbf{u}_j \mathbf{v}_j'$ es la mejor aproximación de rango k de $\mathbf{X}$ en norma de Frobenius entre *todas* las matrices de rango k, no sólo entre las proyecciones (Eckart y Young 1936); la demostración general usa las desigualdades de Weyl para valores singulares (Horn y Johnson 2013, Sec. 7.4).

Ejemplo 2.4 (Regresión ortogonal contra MCO) Para los cinco hogares (ingreso x_1, gasto x_2, sin estandarizar), la recta del primer componente pasa por $\bar{\mathbf{x}} = (16, 13)$ con dirección $\boldsymbol{\gamma}_1 = (0.838, 0.545)'$, es decir, con pendiente $0.545/0.838 = 0.651$. Esta recta minimiza la suma de las distancias *perpendiculares* al cuadrado, que vale $n\lambda_2 = 5(0.549) = 2.75$. Compárese con:

- la regresión de MCO de gasto sobre ingreso, que minimiza las distancias *verticales*: pendiente $s_{12}/s_{11} = 0.638$;
- la regresión de ingreso sobre gasto, que minimiza las distancias *horizontales*: en el plano (ingreso, gasto) tiene pendiente $s_{22}/s_{12} = 0.682$.

La recta de PCA queda entre las dos regresiones. MCO trata asimétricamente a las variables (una explica a la otra); PCA las trata simétricamente, como corresponde a una técnica de interdependencia.

Ejemplo 2.5 (Aproximación de rango uno de los seis países) Los valores singulares de la matriz $\mathbf{Z}$ del Ejemplo 2.3 son $d = (3.294,\ 2.460,\ 1.047)$, y en efecto $d_k^2/6 = (1.809,\ 1.008,\ 0.183) = (l_1, l_2, l_3)$. La suma de cuadrados total es $\|\mathbf{Z}\|_F^2 = np = 18$. Al aproximar $\mathbf{Z}$ por el primer componente, $\mathbf{Z}_1 = d_1 \mathbf{u}_1 \mathbf{v}_1'$, el error es $\|\mathbf{Z} - \mathbf{Z}_1\|_F^2 = 6(1.008 + 0.183) = 7.15$, es decir, se pierde el $39.7\,\% = 1 - 0.603$ de la información.

2.5. ¿Cuántos componentes retener?

No hay una respuesta única. Los criterios habituales son:

1. **Proporción acumulada.** Retener los m primeros componentes que expliquen al menos una fracción prefijada, típicamente entre $70\,\%$ y $90\,\%$. Es simple, pero el umbral es arbitrario.
2. **Criterio de Kaiser** (Kaiser 1960). Con $\mathbf{R}$, retener los componentes con $l_k > 1$. La justificación es la Proposición 2.3: el eigenvalor promedio es 1, así que un componente con $l_k < 1$ explica menos varianza que *una sola* variable original estandarizada. Su debilidad es que ignora el error de muestreo: aun con variables independientes, los eigenvalores muestrales de $\mathbf{R}$ se dispersan alrededor de 1, y los primeros superan 1 por azar.

3. **Gráfica de sedimentación** (*scree plot*) (Cattell 1966). Graficar l_k contra k y retener los componentes anteriores al "codo", donde la curva se aplana. Es subjetivo cuando no hay un codo claro.

4. **Análisis paralelo** (Horn 1965). Corrige directamente el defecto del criterio de Kaiser: compara cada l_k con la distribución del k-ésimo eigenvalor de la matriz de correlaciones de datos *sin estructura* del mismo tamaño.

```
def analisis_paralelo(n, p, reps=5000, semilla=2026):
    """Media y percentil 95 de los eigenvalores de R bajo
       independencia."""
    rng = np.random.default_rng(semilla)
    sims = np.array([np.linalg.eigvalsh(np.corrcoef(rng.
       standard_normal((n, p)).T))[::-1]
                     for _ in range(reps)])
    return sims.mean(axis=0), np.percentile(sims, 95, axis=0)
# Se retiene el componente k si l_k supera el percentil 95 simulado
    .
```

Ejemplo 2.6 (Cuántos componentes en los seis países) Con $l = (1.809, 1.008, 0.183)$:

- Con un umbral de 80 % de varianza acumulada se retienen 2 componentes (93.9 %).
- El criterio de Kaiser retiene 2, aunque el segundo por un margen mínimo (1.008 contra 1).
- El análisis paralelo con $n = 6$, $p = 3$ y 5 000 réplicas da percentiles 95 de $(2.292, 1.200, 0.684)$. Ningún eigenvalor los supera. Con sólo seis observaciones, la estructura observada *no se distingue* de la que produciría el azar.

La lección es importante: los ejemplos pequeños sirven para entender los cálculos, pero no para concluir. Kaiser, aplicado mecánicamente, habría "encontrado" dos dimensiones.

2.6. Interpretación

Un componente se interpreta a partir de las variables con las que está más correlacionado (Proposición 2.3), atendiendo a los signos. Se le da un nombre sustantivo sólo si el patrón tiene sentido teórico.

Ejemplo 2.7 (Seis países: interpretación y puntuaciones) Las correlaciones componente–variable, $\gamma_{jk}\sqrt{l_k}$, son

	CP1	CP2	CP3
Mortalidad infantil	−0.953	0.014	0.302
Ingreso	0.903	0.321	0.286
Exportaciones	−0.291	0.951	−0.101
Suma de cuadrados ($= l_k$)	1.809	1.008	0.183

Cada fila tiene suma de cuadrados igual a 1; por ejemplo, $0.953^2 + 0.014^2 + 0.302^2 = 1.000$. El CP1 contrapone ingreso alto y mortalidad baja: es un eje de *desarrollo*. El CP2 está dominado por las exportaciones: es un eje de *apertura comercial*, casi independiente del desarrollo en esta muestra. Las puntuaciones son

	Canadá	Chile	Colombia	Perú	Bolivia	Guatemala
CP1	2.242	0.683	0.298	−0.151	−2.050	−1.022
CP2	0.592	1.024	−1.702	−0.354	1.095	−0.656

Por ejemplo, la puntuación de Canadá en el CP1 es $\boldsymbol{g}_1'\mathbf{z}_1 = -0.709(-1.176) + 0.671(2.078) - 0.216(-0.059) \approx 2.242$ (la diferencia en el último dígito se debe al redondeo de las cargas). Canadá encabeza el eje de desarrollo y Bolivia lo cierra; Bolivia y Chile son los más abiertos al comercio; Colombia, el menos abierto. La varianza de cada fila es exactamente l_k.

2.6.1. El biplot

El **biplot** (Gabriel 1971) representa en una misma gráfica a los individuos y a las variables. Partiendo de la aproximación de rango dos $\mathbf{Z} \approx \mathbf{U}_2\mathbf{D}_2\mathbf{V}_2'$, para $0 \le \alpha \le 1$ se factoriza

$$\mathbf{Z} \approx \underbrace{\left(\mathbf{U}_2\mathbf{D}_2^{\alpha}\right)}_{\text{individuos}} \underbrace{\left(\mathbf{V}_2\mathbf{D}_2^{1-\alpha}\right)'}_{\text{variables}}, \tag{2.5}$$

y se grafican las filas del primer factor como puntos y las del segundo como flechas desde el origen. Cada z_{ij} se aproxima por el producto interno entre el punto i y la flecha j. Las dos elecciones habituales son:

- $\alpha = 1$: los puntos son las puntuaciones $\mathbf{Y}_2 = \mathbf{U}_2\mathbf{D}_2$, y las distancias euclidianas entre puntos aproximan las distancias entre individuos. Las flechas son las cargas $\mathbf{V}_2$.

- $\alpha = 0$ (reescalado): los puntos son $\sqrt{n}\,\mathbf{U}_2$ y las flechas son $\mathbf{V}_2\mathbf{D}_2/\sqrt{n}$, cuyas coordenadas son las correlaciones componente–variable. Como $\frac{1}{n}\mathbf{Z}'\mathbf{Z} = \mathbf{R}$, los productos internos entre flechas aproximan las correlaciones entre variables, y el coseno del ángulo entre dos flechas aproxima su correlación.

2.6.2. Aplicación: 167 países, 9 indicadores

Aplicamos ahora PCA con $\mathbf{R}$ a la base completa (Kokkula 2020): $n = 167$ países y $p = 9$ indicadores (mortalidad infantil, exportaciones, gasto en salud, importaciones, ingreso, inflación, esperanza de vida, fecundidad y PIB per cápita). Los eigenvalores son

$$l = (4.136,\ 1.546,\ 1.170,\ 0.995,\ 0.661,\ 0.224,\ 0.113,\ 0.088,\ 0.067),$$

con proporciones acumuladas de 46.0 %, 63.1 %, 76.1 %, 87.2 % para $m = 1, \ldots, 4$. La Figura 2.1 los compara con el percentil 95 del análisis paralelo.

Los criterios no coinciden, y es útil verlo:

- El umbral de 80 % retiene 4 componentes.

- Kaiser retiene 3; el cuarto, con 0.995, queda fuera por cinco milésimas.

- El análisis paralelo retiene 2: $l_2 = 1.546 > 1.322$, pero $l_3 = 1.170 < 1.209$.

- La gráfica de sedimentación muestra un codo claro después del segundo componente.

Una solución de dos componentes, que explica el 63.1 %, es la mejor respaldada. Las correlaciones con los dos primeros componentes son:

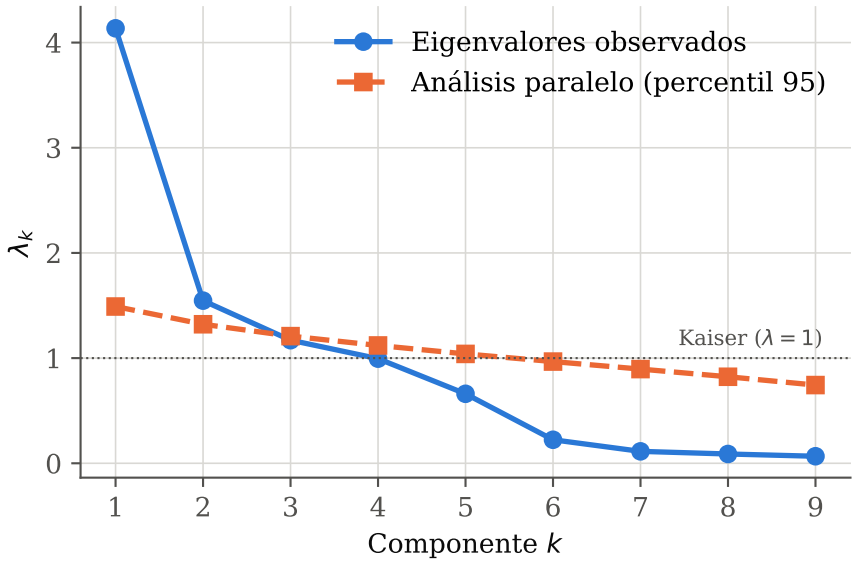


Figura 2.1: Gráfica de sedimentación y análisis paralelo (167 países, 9 indicadores, 5 000 réplicas). Elaboración propia con datos de Kokkula (2020).

	CP1	CP2		CP1	CP2
Esperanza de vida	0.866	−0.277	PIB per cápita	0.798	−0.057
Mort. infantil	−0.853	0.240	Exportaciones	0.577	0.762
Fecundidad	−0.821	0.193	Importaciones	0.328	0.835
Ingreso	0.810	0.028	Inflación	−0.393	−0.010
			Gasto en salud	0.307	−0.302

El patrón de los seis países se reproduce a escala mundial (Figura 2.2): el CP1 es un eje de desarrollo (esperanza de vida, ingreso y PIB per cápita contra mortalidad infantil y fecundidad) y el CP2 es un eje de apertura comercial (exportaciones e importaciones). En el CP1, los valores más bajos corresponden a Nigeria (−4.91), Haití (−4.41), República Centroafricana (−3.96), Chad (−3.56) y Níger (−3.45), y los más altos a Luxemburgo (6.92), Singapur (5.78), Qatar (4.24), Suiza (4.09) y Noruega (3.72).

Observación 2.2 (Un adelanto del capítulo de índices) Es tentador usar el CP1 como "índice de desarrollo". Antes hay que notar que las exportaciones cargan 0.577 en el CP1: Luxemburgo y Singapur, economías

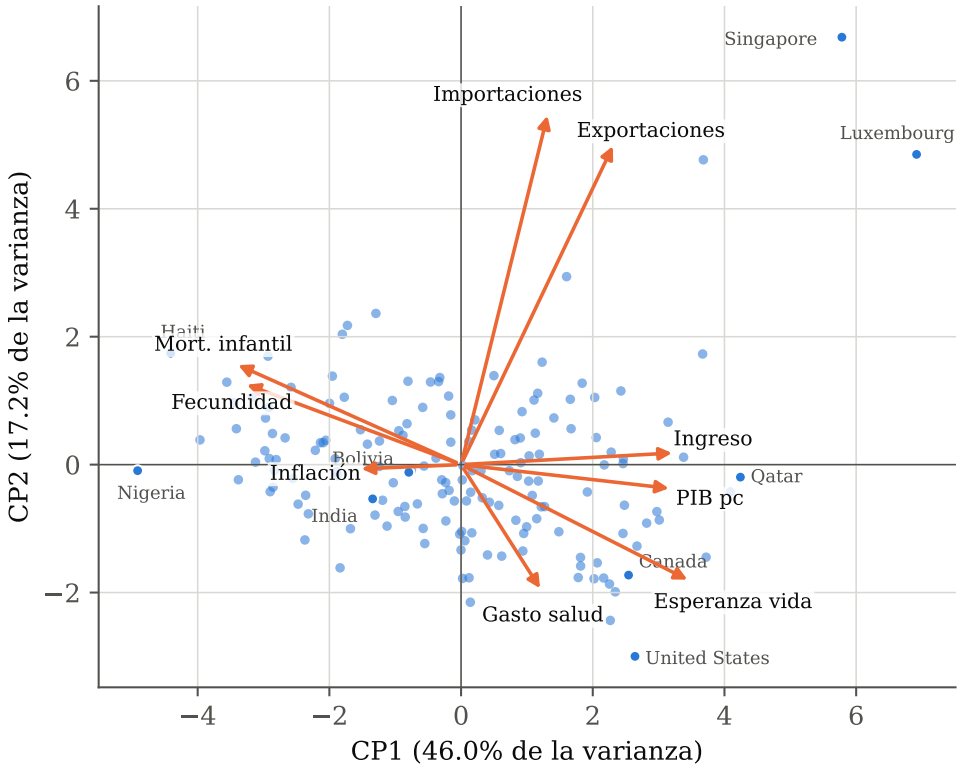


Figura 2.2: Biplot ($\alpha = 1$) de los dos primeros componentes. Puntos: puntuaciones de los 167 países (se etiquetan algunos). Flechas: cargas, reescaladas para hacerlas visibles. Elaboración propia con datos de Kokkula (2020).

extremadamente abiertas, quedan arriba en parte por eso, y no sólo por su nivel de vida. Las decisiones de qué variables incluir, cómo normalizarlas y cómo ponderarlas cambian el orden de los países. Este es el tema del Capítulo 4.

2.7. Inferencia sobre los eigenvalores

Teorema 2.7 (Anderson 1963) *Sea* $\mathbf{x}_1, \ldots, \mathbf{x}_n$ *una muestra aleatoria de* $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$*, donde* $\boldsymbol{\Sigma}$ *tiene eigenvalores distintos* $\lambda_1 > \cdots > \lambda_p > 0$*, y sean* $\hat{\lambda}_k$ *los eigenvalores de* $\mathbf{S}$*. Entonces, cuando* $n \to \infty$*,*

$$\sqrt{n}\,(\hat{\lambda}_k - \lambda_k) \xrightarrow{d} N(0,\, 2\lambda_k^2), \tag{2.6}$$

y los $\hat{\lambda}_k$ son asintóticamente independientes entre sí.

De aquí se obtiene un intervalo de confianza aproximado de nivel $1-\alpha$ (Johnson y Wichern 2007, Sec. 8.5):

$$\frac{\hat{\lambda}_k}{1+z_{\alpha/2}\sqrt{2/n}} \;\leq\; \lambda_k \;\leq\; \frac{\hat{\lambda}_k}{1-z_{\alpha/2}\sqrt{2/n}}. \tag{2.7}$$

Para la aplicación de 167 países, $z_{0.025}\sqrt{2/167} = 0.215$, y el intervalo del 95 % para λ_1 es $[\hat{\lambda}_1/1.215,\ \hat{\lambda}_1/0.785] = [3.41,\ 5.26]$. El resultado debe tomarse con cautela: el teorema supone normalidad y está formulado para $\mathbf{S}$, no para $\mathbf{R}$, y estos indicadores (ingreso, PIB, inflación) son muy asimétricos. Para $\mathbf{R}$ y datos no normales, la alternativa es el *bootstrap*: remuestrear países con reemplazo y recalcular l_1 muchas veces.

2.8. Alcances y limitaciones

- **Linealidad.** PCA sólo captura asociaciones lineales. Si la relación entre variables es curva, por ejemplo entre ingreso y esperanza de vida, una transformación logarítmica previa suele ayudar.

- **Sensibilidad a valores atípicos.** Como depende de $\mathbf{S}$ o $\mathbf{R}$, unas cuantas observaciones extremas pueden rotar los ejes. Conviene revisar distancias de Mahalanobis (Sección 1.6) y repetir el análisis sin los casos extremos.

- **Escala.** Los resultados dependen de la estandarización (Sección 2.2).

- **Interpretabilidad.** Cada componente es una combinación de *todas* las variables, lo que puede dificultar nombrarlo. El análisis factorial, con sus rotaciones, se diseñó en parte para resolver este problema.

- **PCA no es un modelo.** PCA es una transformación de los datos: no hay término de error ni hipótesis sobre cómo se generaron. El análisis factorial, en cambio, postula que las correlaciones se deben a un número pequeño de factores latentes más un error específico de cada variable. Esta diferencia, que se formaliza en el Capítulo 3, determina cuándo usar cada técnica.

PCA en las etapas de Hair. (1) El objetivo es resumir p variables en $m < p$ dimensiones. (2) Se eligen variables métricas, se decide entre $\mathbf{S}$ y $\mathbf{R}$ y se revisan los datos faltantes. (3) Se verifica que haya correlaciones suficientes (si $\mathbf{R} \approx \mathbf{I}$, no hay nada que resumir) y se revisan los atípicos. (4) Se calcula la descomposición y se elige m con varios criterios. (5) Se interpretan las correlaciones componente–variable y el biplot. (6) Se valida la estabilidad con submuestras o *bootstrap*.

2.9. Implementación en Python

```python
import numpy as np
import pandas as pd
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

df = pd.read_csv("Country-data.csv").set_index("country")
Z = StandardScaler().fit_transform(df) # estandariza con divisor n

pca = PCA().fit(Z)
l = pca.explained_variance_ * (len(Z) - 1) / len(Z) # sklearn
    divide entre n-1
G = pca.components_.T # columnas = vectores de cargas
Y = pca.transform(Z) # puntuaciones
corr = G * np.sqrt(l) # correlaciones componente-variable
print(pca.explained_variance_ratio_.cumsum())

# Lo mismo con la SVD
U, d, Vt = np.linalg.svd(Z, full_matrices=False)
assert np.allclose(d**2 / len(Z), l)
```

Note el ajuste en `explained_variance_`: `sklearn` reporta varianzas con divisor $n-1$, mientras que $\mathbf{R}$ y `StandardScaler` usan divisor n. Las proporciones explicadas no cambian. El cuaderno `02 PCA/PCA_Paises.ipynb` del repositorio reproduce todos los ejemplos del capítulo, con los seis países y con la aplicación de los 167 países, y el cuaderno `02 PCA/Principal_Component_Analysis.ipynb` desarrolla otro ejemplo.

2.10. Ejercicios

1. Demuestre que si $\mathbf{x}$ tiene componentes no correlacionados con varianzas distintas, los componentes principales son las propias variables, ordenadas por varianza. ¿Qué ocurre si todas las varianzas son iguales?

2. Sea $\mathbf{P}$ la matriz de correlaciones $p \times p$ con todas las correlaciones iguales a $\rho > 0$ (*equicorrelación*). Demuestre que $\lambda_1 = 1 + (p-1)\rho$ con $\boldsymbol{\gamma}_1 = p^{-1/2}\mathbf{1}_p$, y que los demás eigenvalores valen $1 - \rho$. Interprete: ¿qué proporción explica el primer componente cuando $p = 10$ y $\rho = 0.5$?

3. Demuestre que, para $p = 2$ y $\boldsymbol{\Sigma}$ arbitraria, la pendiente de la recta del primer componente es $(\lambda_1 - \sigma_{11})/\sigma_{12}$ y que, si $\sigma_{12} > 0$, siempre queda entre la pendiente de MCO de x_2 sobre x_1 y la recíproca de la de x_1 sobre x_2 (Ejemplo 2.4).

4. Verifique la identidad algebraica usada en la demostración del Lema 2.5.

5. Con los datos del Cuadro 2.1, calcule a mano $\boldsymbol{g}_2'\mathbf{z}_i$ para Colombia y compruebe el valor -1.702. Reconstruya la fila de Colombia en $\mathbf{Z}$ con uno y con dos componentes y calcule el error en cada caso.

6. Agregue Haití (208, 1 500, 15.3) a los seis países y repita el análisis. ¿Cómo cambian $\mathbf{R}$, los eigenvalores y la interpretación? Calcule la distancia de Mahalanobis de Haití y discuta qué haría con esa observación.

7. (Computacional) Repita la aplicación de los 167 países usando el logaritmo de ingreso, PIB per cápita y mortalidad infantil. ¿Cambia el número de componentes que sugiere el análisis paralelo? ¿Cambian los países extremos del CP1?

8. (Computacional) Construya un intervalo *bootstrap* del 95 % para l_1 en la aplicación (2 000 remuestras de países) y compárelo con el intervalo basado en el Teorema 2.7.

9. (Computacional) Demuestre numéricamente que el análisis paralelo es más conservador que Kaiser: simule $\mathbf{R}$ con $n = 50$ y $p = 10$ variables independientes 1 000 veces y reporte cuántos componentes retiene cada criterio en promedio.

3

Análisis Factorial

El análisis factorial o análisis de factores usa la correlación entre variables, o entre los reactivos de un cuestionario, para reducirlas a un número pequeño de dimensiones o **factores**. La matriz de correlaciones indica qué variables exhiben patrones similares, y esas variables se agrupan en factores.

En contraste con el análisis de componentes principales, el análisis factorial supone que la varianza de cada variable se separa en dos partes. La primera es la varianza *común*, compartida con las demás variables del análisis. La segunda es la varianza *específica* de la variable en cuestión. Los factores explican sólo la primera parte. Esta diferencia, que parece técnica, es conceptual: PCA es una transformación de los datos, mientras que el análisis factorial es un *modelo* que postula variables latentes no observables (“nivel socioeconómico”, “inteligencia general”, “satisfacción con el servicio”) como causa de las correlaciones observadas.

La técnica nace con Spearman (1904), quien observó que las calificaciones de niños en materias muy distintas estaban todas positivamente correlacionadas y propuso explicarlo con un único factor de “inteligencia general”. Thurstone (1947) la extendió a varios factores e introdujo la idea de *estructura simple*, base de las rotaciones. La formulación estadística moderna, con estimación por máxima verosimilitud y pruebas de bondad de ajuste, se debe a Lawley y Maxwell (1971) y Jöreskog (1967). El capítulo sigue a Johnson y Wichern (2007, Cap. 9) y Mardia, Kent y Bibby (1979, Cap. 9); los aspectos aplicados siguen a Hair et al. (2006, Cap. 3).

Datos de trabajo. Con los microdatos de la ENIGH 2024 (INEGI 2025) construimos seis indicadores para cada una de las $n = 32$ entidades federati-

vas, ponderando cada hogar con su factor de expansión:

1. x_1, `ing_pc`: logaritmo del ingreso corriente trimestral per cápita promedio de los hogares;
2. x_2, `edu_jefe`: escolaridad promedio del jefe del hogar, en la escala de 1 (sin instrucción) a 11 (posgrado) de la ENIGH;
3. x_3, `menores_sh`: proporción de menores de 12 años en la población;
4. x_4, `perceptores`: proporción de personas que perciben ingreso;
5. x_5, `mayores65_sh`: proporción de personas de 65 años o más;
6. x_6, `trab_sh`: proporción del ingreso corriente que proviene del trabajo.

La escolaridad es, en sentido estricto, una variable ordinal (Sección 1.2); su promedio estatal la trata como de intervalo, una aproximación habitual que conviene tener presente. El cuaderno del repositorio `03 Factor Analysis/04 Entidades ENIGH/Factorial_Entidades_ENIGH.ipynb` construye estos indicadores desde el microdato y los guarda en `enigh2024_entidades.csv`, redondeados a cuatro decimales; todas las cifras del capítulo se calculan con esos valores. La matriz de correlaciones es

$$\mathbf{R} = \begin{bmatrix} 1 & 0.909 & -0.668 & 0.545 & -0.164 & 0.170 \\ 0.909 & 1 & -0.669 & 0.499 & -0.201 & 0.274 \\ -0.668 & -0.669 & 1 & -0.711 & -0.351 & 0.137 \\ 0.545 & 0.499 & -0.711 & 1 & 0.363 & -0.362 \\ -0.164 & -0.201 & -0.351 & 0.363 & 1 & -0.773 \\ 0.170 & 0.274 & 0.137 & -0.362 & -0.773 & 1 \end{bmatrix}. \tag{3.1}$$

A simple vista se distinguen dos bloques: ingreso, escolaridad, menores y perceptores, por un lado, y mayores de 65 e ingreso laboral, por otro.

3.1. El modelo factorial ortogonal

Definición 3.1 *Un vector aleatorio $\mathbf{x} \in \mathbb{R}^p$ con media $\boldsymbol{\mu}$ sigue un **modelo factorial ortogonal con** m **factores** si*

$$\mathbf{x} - \boldsymbol{\mu} = \mathbf{L}\boldsymbol{f} + \boldsymbol{\varepsilon}, \tag{3.2}$$

*donde $\boldsymbol{f} \in \mathbb{R}^m$ es el vector de **factores comunes**, $\boldsymbol{\varepsilon} \in \mathbb{R}^p$ el de **factores específicos** (o errores), $\mathbf{L} \in \mathbb{R}^{p \times m}$ la matriz de **cargas factoriales**, y*

$$\mathbb{E}[\boldsymbol{f}] = \mathbf{0}, \quad \operatorname{Cov}(\boldsymbol{f}) = \mathbf{I}_m, \quad \mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0},$$
$$\operatorname{Cov}(\boldsymbol{\varepsilon}) = \boldsymbol{\Psi} = \operatorname{diag}(\psi_1, \ldots, \psi_p), \quad \operatorname{Cov}(\boldsymbol{f}, \boldsymbol{\varepsilon}) = \mathbf{0}.$$

Ni $\boldsymbol{f}$ ni $\boldsymbol{\varepsilon}$ se observan. La hipótesis crucial es que $\boldsymbol{\Psi}$ es *diagonal*: toda la covariación entre variables se debe a los factores comunes; lo que queda en cada variable es propio de ella.

Proposición 3.1 *Bajo el modelo* (3.2)*:*

1. $\boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}$*. En particular,* $\sigma_{jj} = h_j^2 + \psi_j$*, con* $h_j^2 = \sum_{k=1}^m \ell_{jk}^2$*, y* $\sigma_{jk} = \sum_{r=1}^m \ell_{jr}\ell_{kr}$ *para* $j \neq k$*.*

2. $\mathrm{Cov}(\mathbf{x}, \boldsymbol{f}) = \mathbf{L}$*: la carga* ℓ_{jk} *es la covarianza entre la variable* j *y el factor* k*.*

Demostración. (1) Como $\boldsymbol{f}$ y $\boldsymbol{\varepsilon}$ no están correlacionados, $\boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{L}\boldsymbol{f} + \boldsymbol{\varepsilon})(\mathbf{L}\boldsymbol{f}+\boldsymbol{\varepsilon})'] = \mathbf{L}\mathbb{E}[\boldsymbol{f}\boldsymbol{f}']\mathbf{L}'+\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'] = \mathbf{L}\mathbf{L}'+\boldsymbol{\Psi}$. (2) $\mathrm{Cov}(\mathbf{x}, \boldsymbol{f}) = \mathbb{E}[(\mathbf{L}\boldsymbol{f}+\boldsymbol{\varepsilon})\boldsymbol{f}'] = \mathbf{L}\mathbb{E}[\boldsymbol{f}\boldsymbol{f}'] = \mathbf{L}$. ■

Definición 3.2 h_j^2 *es la* ***comunalidad*** *de la variable* j*: la parte de su varianza explicada por los factores comunes.* ψ_j *es su* ***varianza específica*** *o* ***unicidad****.*

Si las variables están estandarizadas, $\boldsymbol{\Sigma} = \mathbf{P}$ (la matriz de correlaciones), $h_j^2 + \psi_j = 1$, y por la Proposición 3.1(2), $\ell_{jk} = \mathrm{Corr}(x_j, f_k)$: con variables estandarizadas y factores ortogonales, las cargas son correlaciones. Trabajaremos casi siempre en esta escala.

3.1.1. Conteo de parámetros e identificación

$\boldsymbol{\Sigma}$ tiene $p(p+1)/2$ elementos distintos. El modelo los explica con los pm elementos de $\mathbf{L}$ y los p de $\boldsymbol{\Psi}$, pero, como veremos en la Sección 3.4, $\mathbf{L}$ sólo está determinada salvo una rotación ortogonal, que tiene $m(m-1)/2$ grados de libertad. La diferencia

$$\nu = \frac{p(p+1)}{2} - \left[pm + p - \frac{m(m-1)}{2}\right] = \frac{(p-m)^2 - (p+m)}{2} \tag{3.3}$$

es el número de restricciones que el modelo impone sobre $\boldsymbol{\Sigma}$. Si $\nu < 0$, el modelo no está identificado; si $\nu = 0$, reproduce $\boldsymbol{\Sigma}$ exactamente (cuando existe una solución admisible); si $\nu > 0$, el modelo es una hipótesis contrastable. Con $p = 6$: $m = 1$ da $\nu = 9$, $m = 2$ da $\nu = 4$ y $m = 3$ da $\nu = 0$.

Ejemplo 3.1 (Un factor y tres variables: solución cerrada) Con $p = 3$ y $m = 1$, $\nu = 0$, y el modelo $\mathbf{P} = \boldsymbol{\ell}\boldsymbol{\ell}' + \boldsymbol{\Psi}$ da tres ecuaciones para las correlaciones: $r_{12} = \ell_1\ell_2$, $r_{13} = \ell_1\ell_3$ y $r_{23} = \ell_2\ell_3$. Resolviendo,

$$\ell_1^2 = \frac{r_{12}r_{13}}{r_{23}}, \qquad \ell_2^2 = \frac{r_{12}r_{23}}{r_{13}}, \qquad \ell_3^2 = \frac{r_{13}r_{23}}{r_{12}}.$$

Tomemos ingreso, escolaridad y proporción de menores, con $r_{12} = 0.909$, $r_{13} = -0.668$ y $r_{23} = -0.669$ (ecuación 3.1):

$$\ell_1^2 = \frac{0.909(-0.668)}{-0.669} = 0.908, \qquad \ell_2^2 = \frac{0.909(-0.669)}{-0.668} = 0.911,$$

$$\ell_3^2 = \frac{(-0.668)(-0.669)}{0.909} = 0.492.$$

Fijando el signo de ℓ_1 positivo, las cargas son $\boldsymbol{\ell} = (0.953,\ 0.954,\ -0.702)'$ y las unicidades $\boldsymbol{\psi} = (0.092,\ 0.089,\ 0.508)$. El factor es un nivel socioeconómico latente: el ingreso y la escolaridad lo reflejan casi perfectamente; la proporción de menores, en sentido inverso y con más ruido propio. Puede verificarse que $\boldsymbol{\ell}\boldsymbol{\ell}' + \boldsymbol{\Psi}$ reproduce exactamente las tres correlaciones.

Ejemplo 3.2 (Un caso de Heywood) Con las mismas fórmulas, supongamos ahora $r_{12} = 0.9$, $r_{13} = 0.7$ y $r_{23} = 0.6$. Entonces $\ell_1^2 = 0.9(0.7)/0.6 = 1.05$, y la unicidad sería $\psi_1 = 1 - 1.05 = -0.05 < 0$: una varianza negativa. No existe un modelo de un factor con varianzas específicas no negativas que reproduzca esa matriz. A estas soluciones impropias se les llama **casos de Heywood** (Heywood 1931). En la práctica aparecen con muestras pequeñas, con demasiados factores o con variables casi redundantes, y los programas las "resuelven" fijando ψ_j en un valor mínimo. Un caso de Heywood es una señal de alerta sobre el modelo, no un detalle numérico.

3.1.2. Análisis factorial y componentes principales

Si se toma $\boldsymbol{\Psi} = \mathbf{0}$ y $m = p$, la descomposición espectral $\mathbf{P} = \boldsymbol{\Gamma}\boldsymbol{\Lambda}\boldsymbol{\Gamma}' = (\boldsymbol{\Gamma}\boldsymbol{\Lambda}^{1/2})(\boldsymbol{\Gamma}\boldsymbol{\Lambda}^{1/2})'$ es un "modelo factorial" trivial con $\mathbf{L} = \boldsymbol{\Gamma}\boldsymbol{\Lambda}^{1/2}$. PCA busca reproducir *toda* la matriz $\mathbf{P}$, incluida su diagonal de unos; el análisis factorial busca reproducir sólo las correlaciones *fuera* de la diagonal, dejando que cada variable conserve una varianza propia ψ_j. Cuando las unicidades son pequeñas, ambas técnicas dan resultados parecidos; cuando son grandes, como en reactivos de cuestionarios con mucho error de medición, PCA sobrestima las cargas.

3.2. Adecuación de los datos

Antes de estimar conviene verificar que haya algo que factorizar: si las variables no están correlacionadas, no hay factores comunes.

Prueba de esfericidad de Bartlett. Contrasta $H_0 : \mathbf{P} = \mathbf{I}_p$ con el estadístico (Bartlett 1950)

$$\chi^2 = -\left(n - 1 - \frac{2p+5}{6}\right) \log |\mathbf{R}| \overset{H_0}{\sim} \chi^2_{p(p-1)/2}, \tag{3.4}$$

que supone normalidad. Como $|\mathbf{R}| = \prod_j l_j$ y $\sum_j l_j = p$, por la desigualdad entre medias aritmética y geométrica $|\mathbf{R}| \leq 1$, con igualdad sólo si $\mathbf{R} = \mathbf{I}_p$; mientras más correlacionadas las variables, menor $|\mathbf{R}|$ y mayor el estadístico. Con muestras grandes la prueba casi siempre rechaza, por lo que es una condición necesaria, no suficiente.

Medida de Kaiser–Meyer–Olkin. Si dos variables comparten un factor común, su correlación no debería desaparecer al controlar por las demás variables. Sea a_{jk} la correlación parcial entre x_j y x_k dadas todas las demás, que se obtiene de $\mathbf{R}^{-1}$ (Apéndice A, Ejercicio 3). La medida de adecuación muestral global y la de cada variable son (Kaiser 1974)

$$\text{KMO} = \frac{\sum_{j\neq k} r_{jk}^2}{\sum_{j\neq k} r_{jk}^2 + \sum_{j\neq k} a_{jk}^2}, \qquad \text{MSA}_j = \frac{\sum_{k\neq j} r_{jk}^2}{\sum_{k\neq j} r_{jk}^2 + \sum_{k\neq j} a_{jk}^2}. \tag{3.5}$$

Si las correlaciones parciales son pequeñas en relación con las simples, el KMO se acerca a 1. Kaiser (1974) propuso la escala: 0.90 o más, "maravilloso"; 0.80, "meritorio"; 0.70, "mediano"; 0.60, "mediocre"; 0.50, "miserable"; menos de 0.50, "inaceptable".

Ejemplo 3.3 (Adecuación de los indicadores estatales) Para la matriz (3.1), $|\mathbf{R}| = 0.0064$ y

$$\chi^2 = -\left(31 - \frac{17}{6}\right) \log(0.0064) = 142.2,$$

con 15 grados de libertad y $p < 10^{-20}$. Se rechaza contundentemente que las variables sean independientes. El KMO global es 0.657 ("mediocre"), y las MSA individuales son

Ingreso	Escolaridad	Menores	Perceptores	65+	Ingreso laboral
0.689	0.705	0.694	0.807	0.509	0.510

Las MSA de mayores de 65 e ingreso laboral son bajas por una razón instructiva: esas dos variables se correlacionan casi sólo entre sí. Su correlación simple es -0.773 y la parcial, dadas las otras cuatro, sigue siendo -0.692: su relación no "pasa" por las demás variables. Con sólo dos indicadores, un factor queda débilmente identificado. Seguiremos adelante con cautela, y con $n = 32$ y $p = 6$ (unas cinco observaciones por variable) estamos en el límite inferior de lo recomendable (Hair et al. 2006, Cap. 3).

3.3. Estimación

Dada $\mathbf{R}$ y un número de factores m, se busca $(\mathbf{L}, \boldsymbol{\Psi})$ tal que $\mathbf{R} \approx \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}$. Veremos tres métodos.

3.3.1. Método de componentes principales

Se toman las cargas de los primeros m componentes principales:

$$\hat{\mathbf{L}} = \left[\sqrt{l_1}\,\boldsymbol{g}_1, \ldots, \sqrt{l_m}\,\boldsymbol{g}_m\right], \qquad \hat{\psi}_j = 1 - \sum_{k=1}^{m} \hat{\ell}_{jk}^2. \tag{3.6}$$

Proposición 3.2 *Con el método de componentes principales, la matriz residual* $\mathbf{R} - \hat{\mathbf{L}}\hat{\mathbf{L}}' - \hat{\boldsymbol{\Psi}}$ *tiene diagonal cero y*

$$\left\|\mathbf{R} - \hat{\mathbf{L}}\hat{\mathbf{L}}' - \hat{\boldsymbol{\Psi}}\right\|_F^2 \leq l_{m+1}^2 + \cdots + l_p^2.$$

Demostración. La diagonal es cero por la definición de $\hat{\boldsymbol{\Psi}}$. Por el teorema espectral, $\mathbf{R} - \hat{\mathbf{L}}\hat{\mathbf{L}}' = \sum_{k>m} l_k \boldsymbol{g}_k \boldsymbol{g}_k'$, cuya norma de Frobenius al cuadrado es $\operatorname{tr}\left[\left(\sum_{k>m} l_k \boldsymbol{g}_k \boldsymbol{g}_k'\right)^2\right] = \sum_{k>m} l_k^2$, por la ortonormalidad de los $\boldsymbol{g}_k$. Restarle $\hat{\boldsymbol{\Psi}}$ sólo anula su diagonal, lo que no puede aumentar la suma de cuadrados de sus elementos. ■

El método es sencillo y siempre produce una solución, pero no es un estimador del modelo factorial en sentido estricto: no distingue entre varianza común y específica al extraer los factores.

3.3.2. Método de ejes principales

El método de ejes principales aplica la misma idea a la **matriz de correlaciones reducida** $\mathbf{R} - \boldsymbol{\Psi}$, cuya diagonal contiene comunalidades en lugar de unos:

1. Proponer comunalidades iniciales $h_j^{2(0)}$. La elección habitual es el coeficiente de determinación R_j^2 de la regresión de x_j sobre las demás variables, que puede calcularse como $R_j^2 = 1 - 1/[\mathbf{R}^{-1}]_{jj}$ y es una cota inferior de la comunalidad (Mardia, Kent y Bibby 1979).

2. En la iteración t, sustituir la diagonal de $\mathbf{R}$ por $h_j^{2(t)}$, calcular los m primeros eigenvalores y eigenvectores de esa matriz, y formar $\mathbf{L}^{(t)}$ como en el método de componentes.

3. Actualizar $h_j^{2(t+1)} = \sum_k (\ell_{jk}^{(t)})^2$ y repetir hasta que las comunalidades no cambien.

3.3.3. Máxima verosimilitud

Si $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi})$, la log-verosimilitud perfilada en $\boldsymbol{\mu} = \bar{\mathbf{x}}$ es, por la demostración del Teorema 1.9,

$$\ell(\mathbf{L}, \boldsymbol{\Psi}) = \text{cte} - \frac{n}{2}\left[\log|\boldsymbol{\Sigma}| + \operatorname{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S})\right], \qquad \boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}.$$

Maximizarla equivale a minimizar la **función de discrepancia**

$$F(\mathbf{L}, \boldsymbol{\Psi}) = \log|\boldsymbol{\Sigma}| + \operatorname{tr}(\boldsymbol{\Sigma}^{-1}\mathbf{S}) - \log|\mathbf{S}| - p, \tag{3.7}$$

que es no negativa y vale cero si y sólo si $\boldsymbol{\Sigma} = \mathbf{S}$ (Teorema 1.9). Para identificar $\mathbf{L}$ se impone que $\mathbf{L}'\boldsymbol{\Psi}^{-1}\mathbf{L}$ sea diagonal. Con esa restricción, las condiciones de primer orden implican que, para $\boldsymbol{\Psi}$ fija, la $\mathbf{L}$ óptima se obtiene de los eigenvectores de $\boldsymbol{\Psi}^{-1/2}\mathbf{S}\boldsymbol{\Psi}^{-1/2}$: si θ_k y $\boldsymbol{\omega}_k$ son sus m primeros eigenvalores y eigenvectores, $\mathbf{L} = \boldsymbol{\Psi}^{1/2}[\boldsymbol{\omega}_1\sqrt{\theta_1 - 1}, \ldots, \boldsymbol{\omega}_m\sqrt{\theta_m - 1}]$ (Lawley y Maxwell 1971). Esto reduce el problema a minimizar F sobre los p valores $\psi_j > 0$, lo que se hace numéricamente (Jöreskog 1967).

El estimador de máxima verosimilitud tiene dos ventajas. Primero, es *invariante a la escala*: las soluciones con $\mathbf{S}$ y con $\mathbf{R}$ son equivalentes, de modo que no hay que elegir entre ellas como en PCA. Segundo, permite contrastar el número de factores.

Teorema 3.3 (Prueba de razón de verosimilitudes) *Bajo normalidad y H_0: "m factores bastan", con $\hat{F}$ el mínimo de* (3.7)*,*

$$\left(n - 1 - \frac{2p+5}{6} - \frac{2m}{3}\right)\hat{F} \xrightarrow{d} \chi^2_\nu, \tag{3.8}$$

donde ν está dada por (3.3)*. El factor que multiplica a $\hat{F}$ es la corrección de Bartlett, que mejora la aproximación en muestras moderadas (Johnson y Wichern 2007, Cap. 9).*

Ejemplo 3.4 (Tres métodos con los indicadores estatales) Los eigenvalores de (3.1) son $(3.025, 2.123, 0.359, 0.296, 0.118, 0.080)$. Los dos primeros explican el 85.8 %; Kaiser y el análisis paralelo, cuyos percentiles 95 son $(1.907, 1.479, 1.195, \ldots)$, coinciden en $m = 2$ (Figura 3.1).

	Componentes			Ejes principales			Máx. verosimilitud		
	ℓ_{j1}	ℓ_{j2}	h_j^2	ℓ_{j1}	ℓ_{j2}	h_j^2	ℓ_{j1}	ℓ_{j2}	h_j^2
Ingreso	0.882	0.344	0.896	0.883	0.290	0.864	0.942	0.033	0.888
Escolar.	0.864	0.416	0.920	0.887	0.372	0.926	0.963	−0.020	0.929
Menores	−0.897	0.165	0.833	−0.846	0.206	0.758	−0.705	−0.513	0.760
Percep.	0.811	−0.345	0.777	0.728	−0.346	0.650	0.547	0.546	0.597
65+	0.175	−0.919	0.875	0.136	−0.911	0.848	−0.196	0.923	0.891
Ing. lab.	−0.081	0.917	0.848	−0.043	0.832	0.694	0.252	−0.776	0.666

Las comunalidades del método de componentes son las más altas, como se anticipó: trata toda la varianza como común. Las cargas sin rotar de los tres métodos difieren, pero esto no es importante, porque las cargas sólo están definidas salvo rotación (Sección 3.4); las comunalidades, en cambio, sí son comparables. Los ejes principales convergieron en 67 iteraciones partiendo de las $R_j^2 = (0.851, 0.860, 0.763, 0.621, 0.748, 0.698)$.

Para máxima verosimilitud, $\hat{F} = 0.3235$ y la prueba del Teorema 3.3 da:

- $m = 1$: $\chi^2 = 61.4$ con $\nu = 9$, $p < 10^{-9}$. Se rechaza: un solo factor no basta.
- $m = 2$: $\chi^2 = (31 - 17/6 - 4/3)(0.3235) = 8.68$ con $\nu = 4$, $p = 0.070$. No se rechaza al 5 %.

Con $m = 2$, el mayor residuo $|r_{jk} - \hat{\sigma}_{jk}|$ es 0.083, entre la proporción de menores y el ingreso laboral.

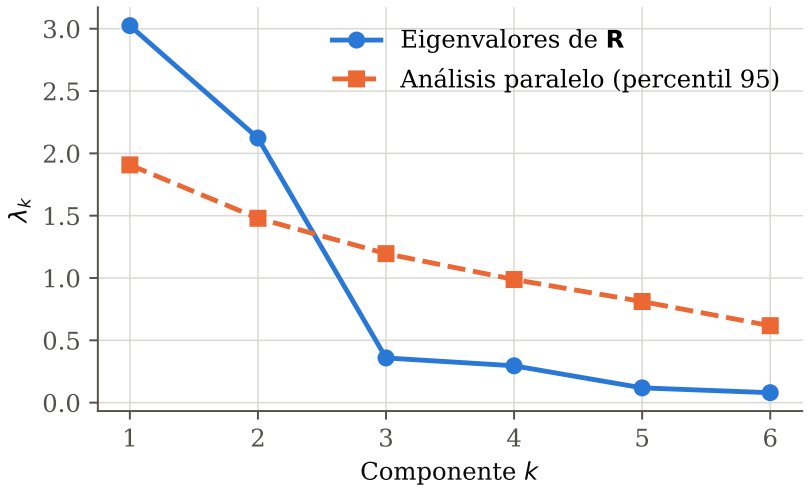


Figura 3.1: Eigenvalores de $\mathbf{R}$ y percentil 95 del análisis paralelo (32 entidades, 6 indicadores, 5 000 réplicas). Elaboración propia con datos de la ENIGH 2024 (INEGI 2025).

3.4. Rotación

Proposición 3.4 (Indeterminación rotacional) *Si* $(\mathbf{L}, \boldsymbol{f})$ *satisface el modelo* (3.2) *y* $\boldsymbol{T}$ *es una matriz ortogonal* $m \times m$*, entonces* $\mathbf{L}^* = \mathbf{L}\boldsymbol{T}$ *y* $\boldsymbol{f}^* = \boldsymbol{T}'\boldsymbol{f}$ *también lo satisfacen, con la misma* $\boldsymbol{\Psi}$ *y las mismas comunalidades.*

Demostración. $\mathbf{L}^*\boldsymbol{f}^* = \mathbf{L}\boldsymbol{T}\boldsymbol{T}'\boldsymbol{f} = \mathbf{L}\boldsymbol{f}$, de modo que (3.2) se cumple; además $\operatorname{Cov}(\boldsymbol{f}^*) = \boldsymbol{T}'\mathbf{I}_m\boldsymbol{T} = \mathbf{I}_m$ y $\mathbf{L}^*\mathbf{L}^{*\prime} = \mathbf{L}\boldsymbol{T}\boldsymbol{T}'\mathbf{L}' = \mathbf{L}\mathbf{L}'$. Las comunalidades son la diagonal de $\mathbf{L}\mathbf{L}'$, que no cambia. ■

Los datos no pueden distinguir entre $\mathbf{L}$ y $\mathbf{L}\boldsymbol{T}$. Lejos de ser un defecto, esta libertad se aprovecha para elegir la rotación que haga más *interpretables* los factores. Thurstone (1947) propuso buscar una **estructura simple**: que cada variable cargue fuerte en un solo factor y cerca de cero en los demás, y que cada factor tenga pocas variables con cargas grandes.

3.4.1. Rotación ortogonal: varimax

Kaiser (1958) tradujo la estructura simple en un criterio: maximizar la varianza de las cargas al cuadrado dentro de cada factor. Si las cargas al cuadrado de un factor son todas cercanas a 0 o a 1, su varianza es grande. Con las cargas normalizadas por la comunalidad, $\tilde{\ell}_{jk} = \ell^*_{jk}/h_j$ (*normalización de Kaiser*), el criterio es

$$V(\boldsymbol{T}) = \sum_{k=1}^{m} \left[\frac{1}{p} \sum_{j=1}^{p} \tilde{\ell}_{jk}^4 - \left(\frac{1}{p} \sum_{j=1}^{p} \tilde{\ell}_{jk}^2 \right)^2 \right], \qquad \mathbf{L}^* = \mathbf{L}\boldsymbol{T}, \tag{3.9}$$

que se maximiza sobre las matrices ortogonales $\boldsymbol{T}$ mediante un algoritmo iterativo basado en la SVD. Con $m = 2$, $\boldsymbol{T}$ es una rotación de ángulo θ:

$$\boldsymbol{T} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}.$$

Ejemplo 3.5 (Varimax con los indicadores estatales) Partiendo de las cargas de máxima verosimilitud, varimax encuentra $\theta = 14.9°$:

$$\boldsymbol{T} = \begin{bmatrix} 0.966 & -0.257 \\ 0.257 & 0.966 \end{bmatrix}.$$

Para el ingreso, $(0.942,\ 0.033)\,\boldsymbol{T} = (0.942{\cdot}0.966{+}0.033{\cdot}0.257,\ -0.942{\cdot}0.257{+}0.033 \cdot 0.966) = (0.918,\ -0.210)$, y su comunalidad sigue siendo $0.918^2 + 0.210^2 = 0.888$. Las cargas rotadas son:

	F1	F2	h_j^2
Ingreso pc (log)	**0.919**	−0.210	0.888
Escolaridad del jefe	**0.926**	−0.268	0.929
Prop. de menores	**−0.813**	−0.314	0.760
Prop. de perceptores	**0.669**	0.386	0.597
Prop. de 65 años o más	0.048	**0.943**	0.891
Prop. ingreso laboral	0.044	**−0.815**	0.666
Suma de cargas al cuadrado	2.814	1.917	4.731

El criterio varimax sube de 0.293 a 0.345. Antes de rotar, la proporción de menores y la de perceptores cargaban de forma parecida en ambos factores; después, cada variable tiene una carga dominante. La varianza común total, 4.731, no cambia: la rotación sólo la redistribuye entre factores, de $(2.714, 2.017)$ a $(2.814, 1.917)$. La Figura 3.2 muestra la rotación de los ejes.

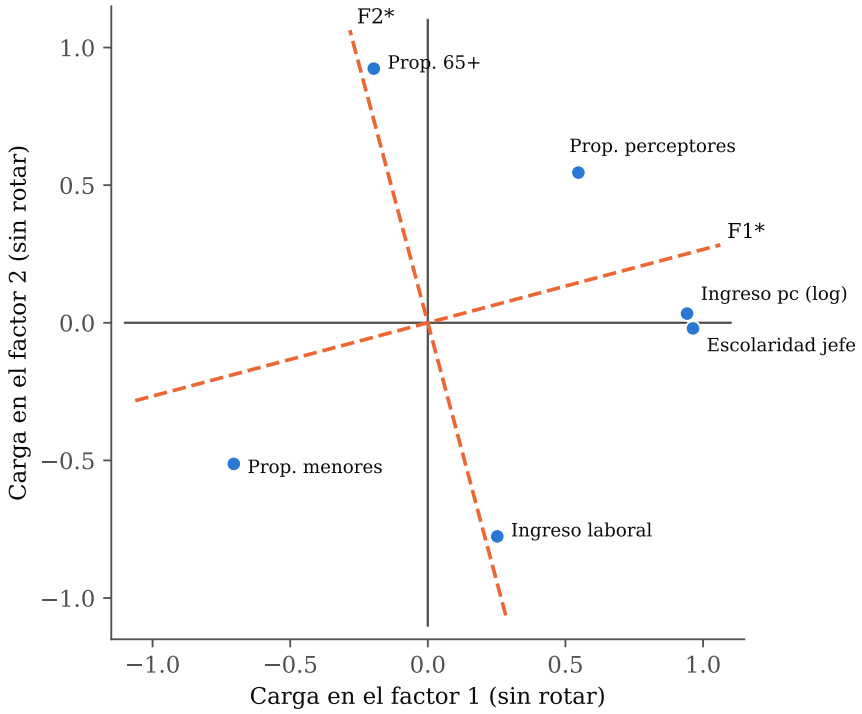


Figura 3.2: Cargas de máxima verosimilitud sin rotar (ejes sólidos) y ejes varimax $F1^*$, $F2^*$ (punteados), rotados 14.9°. Las cargas rotadas son las proyecciones de cada punto sobre los ejes punteados. Elaboración propia con datos de la ENIGH 2024.

3.4.2. Rotación oblicua: promax

Exigir factores no correlacionados puede ser artificial: es razonable que, digamos, el nivel socioeconómico y el envejecimiento de una entidad estén relacionados. Una **rotación oblicua** permite $\mathrm{Cov}(\boldsymbol{f}) = \boldsymbol{\Phi}$, una matriz de correlaciones no necesariamente identidad. Entonces el modelo implica $\boldsymbol{\Sigma} = \boldsymbol{\Lambda}\boldsymbol{\Phi}\boldsymbol{\Lambda}' + \boldsymbol{\Psi}$, y hay que distinguir dos matrices:

- la matriz **patrón** $\boldsymbol{\Lambda}$: los coeficientes de regresión de las variables sobre los factores, que se usan para interpretar;
- la matriz **estructura** $\boldsymbol{\Lambda}\boldsymbol{\Phi} = \mathrm{Cov}(\mathbf{x}, \boldsymbol{f})$: las correlaciones entre variables y factores.

Si $\boldsymbol{\Phi} = \mathbf{I}$, ambas coinciden. El método **promax** (Hendrickson y White 1964) parte de la solución varimax, eleva sus cargas a una potencia (típicamente 4, conservando el signo) para obtener una estructura simple "ideal", y busca por mínimos cuadrados la transformación oblicua que más se le acerca.

Ejemplo 3.6 (Promax con los indicadores estatales) La rotación promax da una correlación entre factores de $\phi_{12} = 0.155$, y cargas patrón muy parecidas a las de varimax; por ejemplo, $(0.951, -0.220)$ para el ingreso y $(-0.092, 0.954)$ para la población de 65 años o más. Con una correlación tan baja, la solución ortogonal es una simplificación aceptable, y la preferimos por ser más fácil de comunicar.

3.5. Interpretación

Un factor se nombra a partir de las variables con cargas altas, digamos $|\ell_{jk}| \geq 0.5$, atendiendo a sus signos. En la solución varimax del Ejemplo 3.5:

- **F1, nivel socioeconómico.** Mayor ingreso per cápita, mayor escolaridad del jefe, menos niños y más personas que perciben ingreso. Es el mismo eje de desarrollo que encontramos con PCA para los países (Sección 2.6), ahora entre entidades.
- **F2, envejecimiento.** Mayor proporción de adultos mayores y menor peso del trabajo en el ingreso, porque crecen las pensiones y transferencias.

La proporción de perceptores tiene una carga cruzada moderada en F2 (0.386): parte de los perceptores adicionales en entidades envejecidas son pensionados. Las cargas cruzadas no son un error; dicen algo sustantivo sobre la variable.

3.6. Puntuaciones factoriales

Para usar los factores en análisis posteriores, como un índice o una segmentación, hay que asignar a cada observación un valor estimado $\hat{\boldsymbol{f}}_i$. Como $\boldsymbol{f}$ no se observa y el modelo tiene más incógnitas $(m + p)$ que ecuaciones (p) por observación, los factores no pueden recuperarse exactamente; sólo pueden estimarse.

Proposición 3.5 (Método de regresión) *Si* $(\mathbf{z}, \boldsymbol{f})$ *es conjuntamente normal bajo el modelo con variables estandarizadas, entonces*

$$\mathbb{E}[\boldsymbol{f} \mid \mathbf{z}] = \mathbf{L}'\mathbf{P}^{-1}\mathbf{z}. \tag{3.10}$$

Las puntuaciones de ***regresión*** *son* $\hat{\boldsymbol{f}}_i = \hat{\mathbf{L}}'\mathbf{R}^{-1}\mathbf{z}_i$*, es decir,* $\hat{\boldsymbol{F}} = \mathbf{Z}\mathbf{R}^{-1}\hat{\mathbf{L}}$.

Demostración. El vector $(\boldsymbol{f}', \mathbf{z}')'$ tiene media cero y matriz de covarianzas $\begin{bmatrix} \mathbf{I}_m & \mathbf{L}' \\ \mathbf{L} & \mathbf{P} \end{bmatrix}$, por la Proposición 3.1. Por el Teorema 1.8(3), $\mathbb{E}[\boldsymbol{f} \mid \mathbf{z}] = \mathbf{L}'\mathbf{P}^{-1}\mathbf{z}$. ■

Sin normalidad, $\mathbf{L}'\mathbf{P}^{-1}\mathbf{z}$ sigue siendo el mejor predictor *lineal* de $\boldsymbol{f}$. Su covarianza es $\mathbf{L}'\mathbf{P}^{-1}\mathbf{L}$, cuyos elementos diagonales son menores que 1: las puntuaciones de regresión están "encogidas" hacia cero, como toda predicción.

Proposición 3.6 (Método de Bartlett) *Para* $\mathbf{L}$ *y* $\boldsymbol{\Psi}$ *dadas, el valor de* $\boldsymbol{f}$ *que minimiza la suma de cuadrados ponderada* $(\mathbf{z} - \mathbf{L}\boldsymbol{f})'\boldsymbol{\Psi}^{-1}(\mathbf{z} - \mathbf{L}\boldsymbol{f})$ *es*

$$\hat{\boldsymbol{f}} = (\mathbf{L}'\boldsymbol{\Psi}^{-1}\mathbf{L})^{-1}\mathbf{L}'\boldsymbol{\Psi}^{-1}\mathbf{z}. \tag{3.11}$$

Este estimador es insesgado condicionalmente en $\boldsymbol{f}$*:* $\mathbb{E}[\hat{\boldsymbol{f}} \mid \boldsymbol{f}] = \boldsymbol{f}$.

Demostración. Para cada observación, $\mathbf{z} = \mathbf{L}\boldsymbol{f} + \boldsymbol{\varepsilon}$ es un modelo lineal en el que $\mathbf{L}$ hace el papel de la matriz de regresores, $\boldsymbol{f}$ el de los coeficientes y $\mathrm{Cov}(\boldsymbol{\varepsilon}) = \boldsymbol{\Psi}$. El problema es exactamente el de mínimos cuadrados generalizados (MCG) del modelo de regresión lineal, con solución $(\mathbf{L}'\boldsymbol{\Psi}^{-1}\mathbf{L})^{-1}\mathbf{L}'\boldsymbol{\Psi}^{-1}\mathbf{z}$. Sustituyendo $\mathbf{z}$, $\hat{\boldsymbol{f}} = \boldsymbol{f} + (\mathbf{L}'\boldsymbol{\Psi}^{-1}\mathbf{L})^{-1}\mathbf{L}'\boldsymbol{\Psi}^{-1}\boldsymbol{\varepsilon}$, cuya esperanza condicional es $\boldsymbol{f}$. ■

Ejemplo 3.7 (Puntuaciones de las entidades) Con las cargas varimax, las puntuaciones de regresión de las entidades extremas son:

Nivel socioeconómico (F1)			Envejecimiento (F2)		
Entidad	F1	F2	Entidad	F1	F2
Ciudad de México	2.916	2.394	Ciudad de México	2.916	2.394
Nuevo León	1.080	−0.641	Veracruz	−0.788	1.700
Colima	0.892	0.383	Morelos	0.099	1.378
⋮			⋮		
Oaxaca	−1.669	1.025	Baja California Sur	0.873	−1.762
Guerrero	−1.731	0.563	Quintana Roo	0.665	−2.216
Chiapas	−2.480	−0.717			

Las varianzas de las puntuaciones de regresión son 0.958 y 0.923: exactamente la diagonal de $\hat{\mathbf{L}}'\mathbf{R}^{-1}\hat{\mathbf{L}}$, menores que 1 como predice la teoría. Las de Bartlett son 1.044 y 1.084, mayores que 1, porque incluyen el error de estimación. Los dos métodos ordenan a las entidades casi igual: la correlación entre ambas puntuaciones es 0.9999 para cada factor.

La Ciudad de México es extrema en los dos factores. Su distancia de Mahalanobis al cuadrado en los seis indicadores es 18.3, por encima del percentil 99 de una χ^2_6 (16.8). Antes de construir un índice con estos factores (Capítulo 4) hay que decidir si una observación así se trata igual que las demás.

3.7. Confiabilidad de una escala

Cuando un grupo de variables o reactivos se suma para formar una escala, como los cuatro indicadores de F1, conviene medir su **consistencia interna**. El coeficiente más usado es el alfa de Cronbach (1951). Para k reactivos $x_1, \dots, x_k$ con suma $S = \sum_j x_j$,

$$\alpha = \frac{k}{k-1}\left(1 - \frac{\sum_{j=1}^{k} \operatorname{Var}(x_j)}{\operatorname{Var}(S)}\right). \tag{3.12}$$

Si los reactivos están estandarizados con correlación promedio $\bar{r}$, entonces $\operatorname{Var}(x_j) = 1$ y $\operatorname{Var}(S) = k + k(k-1)\bar{r}$, y el alfa se reduce a

$$\alpha_{\text{est}} = \frac{k\bar{r}}{1 + (k-1)\bar{r}}. \tag{3.13}$$

El alfa crece con la correlación promedio y con el número de reactivos. Iguala la confiabilidad de la escala sólo si todos los reactivos tienen la misma carga en un único factor (reactivos *tau-equivalentes*); en general es una cota inferior. Una alternativa que usa directamente las cargas de un modelo de un factor es el omega de McDonald (1999),

$$\omega = \frac{\left(\sum_j \ell_j\right)^2}{\left(\sum_j \ell_j\right)^2 + \sum_j \psi_j}. \tag{3.14}$$

Como regla práctica, valores de 0.7 o más se consideran aceptables (Hair et al. 2006, Cap. 3).

Ejemplo 3.8 (Confiabilidad de la escala socioeconómica) Con los cuatro indicadores de F1 estandarizados, e invirtiendo el signo de la proporción de menores para que todos apunten en la misma dirección, la correlación promedio es $\bar{r} = 0.667$ y

$$\alpha_{\text{est}} = \frac{4(0.667)}{1 + 3(0.667)} = 0.889.$$

Un modelo de un factor por máxima verosimilitud para esos cuatro indicadores da cargas $(0.960, 0.944, 0.715, 0.574)$ y $\omega = 0.883$. Ambos coeficientes indican buena consistencia interna.

3.8. Un ejemplo de advertencia

El repositorio del curso incluye la base de predictores de divorcio de Yöntem et al. (2019): 170 parejas en Turquía respondieron 54 reactivos tipo Likert de 0 a 4, inspirados en la investigación de Gottman (1994), que en teoría miden constructos distintos. Hay reactivos de conocimiento de la pareja ("conozco las preocupaciones de mi pareja"), de desprecio en las discusiones ("puedo insultar a mi pareja durante nuestras discusiones") y de evasión ("prefiero quedarme callado que discutir"). 84 de las parejas se divorciaron.

Los indicadores de adecuación son espléndidos. El KMO es 0.964 ("maravilloso"), y los cuatro reactivos de desprecio tienen $\alpha = 0.98$. Sin embargo, el primer eigenvalor es 40.2 de 54 (el 74 % de la varianza), y las puntuaciones del primer factor tienen una correlación de 0.95 con la variable "se divorció". El "factor" es, en esencia, la diferencia entre los dos grupos de parejas: los divorciados puntúan alto en casi todos los reactivos y los no divorciados, bajo. Dentro del grupo de no divorciados, el alfa de los mismos cuatro reactivos de desprecio cae a 0.56, y uno de ellos tiene desviación estándar de apenas 0.18. Hay además un indicio de que la codificación de algunos reactivos está invertida respecto a su redacción: "conozco exactamente lo que le gusta a mi pareja" tiene media 2.65 entre los divorciados y 0.15 entre los no divorciados.

Las lecciones son tres. Primero, cuando la muestra mezcla poblaciones muy distintas, la variación *entre* grupos puede dominar la matriz de correlaciones y producir un factor que no es un constructo psicológico sino una etiqueta de grupo. Segundo, un KMO alto y un alfa alto son condiciones necesarias, no pruebas de validez. Tercero, siempre hay que revisar la codificación

de los datos y su documentación antes de interpretar.

3.9. El análisis factorial en las etapas de Hair

1. **Objetivo:** identificar dimensiones latentes, construir escalas, o reducir datos para análisis posteriores, como un índice o una segmentación.

2. **Diseño:** variables métricas (o reactivos ordinales con suficientes categorías), al menos cinco observaciones por variable, y varios indicadores (tres o más) por factor esperado.

3. **Supuestos:** correlaciones suficientes (Bartlett, KMO, MSA), ausencia de valores atípicos extremos y, para máxima verosimilitud, normalidad aproximada.

4. **Estimación:** método (máxima verosimilitud o ejes principales), número de factores (varios criterios) y rotación.

5. **Interpretación:** nombrar los factores con base en las cargas rotadas y en la teoría; revisar comunalidades y cargas cruzadas.

6. **Validación:** estabilidad con submuestras, confiabilidad (α, ω) y validez de criterio, es decir, si las puntuaciones se relacionan con variables externas como se espera.

3.10. Implementación en Python

El paquete `factor_analyzer` reproduce la funcionalidad habitual del análisis factorial, y `sklearn.decomposition.FactorAnalysis` estima por máxima verosimilitud con rotación varimax. Para que cada paso coincida con las fórmulas de este capítulo, el repositorio incluye el módulo `utils/factorial.py`, escrito directamente con `numpy` y `scipy`:

```
import sys
import pandas as pd
sys.path.insert(0, "utils")
import factorial as fa # utils/factorial.py

```

```
X = pd.read_csv("03 Factor Analysis/04 Entidades ENIGH/
    enigh2024_entidades.csv",
                index_col=0)
R, n, p = X.corr().values, *X.shape

print(fa.bartlett_esfericidad(R, n)) # (142.2, 15, ~1e-23)
print(fa.kmo(R)) # (0.657, MSA por variable)

L, psi, F = fa.fa_maxima_verosimilitud(R, m=2)
print(fa.prueba_ajuste_mv(F, n, p, m=2)) # (8.68, 4, 0.070)

Lv, T = fa.varimax(L) # cargas rotadas
patron, Phi = fa.promax(L) # rotacion oblicua

Z = ((X - X.mean()) / X.std(ddof=0)).values
F_reg = fa.puntuaciones_regresion(Z, R, Lv)
F_bar = fa.puntuaciones_bartlett(Z, Lv, psi)
```

Los resultados de máxima verosimilitud coinciden con los de `sklearn`, salvo el signo de los factores. El cuaderno `03 Factor Analysis/04 Entidades ENIGH/Factorial_Entidades_ENIGH.ipynb` del repositorio construye la base de datos de las entidades a partir del microdato y reproduce todos los ejemplos del capítulo; los demás cuadernos de `03 Factor Analysis/` desarrollan otras aplicaciones con la ENIGH y con la base de divorcio.

3.11. Ejercicios

1. Verifique la fórmula (3.3). ¿Cuál es el máximo número de factores que puede estimarse con $p = 6$ variables manteniendo $\nu \geq 0$? ¿Y con $p = 10$?

2. Para el modelo de un factor con $p = 3$, demuestre que las tres correlaciones deben tener producto positivo, $r_{12}r_{13}r_{23} > 0$, para que la solución sea real. Interprete.

3. Con los datos del Ejemplo 3.1, verifique numéricamente que $\boldsymbol{\ell}\boldsymbol{\ell}' + \boldsymbol{\Psi}$ reproduce las tres correlaciones. Repita con ingreso, escolaridad y perceptores. ¿Está cerca de un caso de Heywood?

4. Demuestre que $|\mathbf{R}| \leq 1$ para toda matriz de correlaciones, con igualdad si y sólo si $\mathbf{R} = \mathbf{I}$.

5. Demuestre que en el modelo con factores oblicuos, $\mathrm{Cov}(\mathbf{x}, \boldsymbol{f}) = \boldsymbol{\Lambda}\boldsymbol{\Phi}$.

6. Con las cargas varimax del Ejemplo 3.5, calcule a mano la puntuación de Bartlett de la Ciudad de México. Necesitará los valores estandarizados de sus seis indicadores y las unicidades $\hat{\psi}_j = 1 - h_j^2$.

7. Demuestre la fórmula del alfa estandarizado a partir de la definición general.

8. (Computacional) Repita el análisis de las entidades sin la Ciudad de México. ¿Cambian el número de factores, las cargas y la prueba de bondad de ajuste?

9. (Computacional) Con los 54 reactivos de la base de divorcio, compare la solución factorial con todas las parejas y sólo con las no divorciadas. ¿Aparecen los constructos de Gottman?

10. (Computacional) Con el microdato de la ENIGH a nivel de hogar, en lugar de entidad, estime un modelo de dos factores con los mismos seis indicadores (definidos para cada hogar). Compare las cargas con las del análisis estatal y discuta por qué pueden diferir (*falacia ecológica*).

4

Construcción de índices compuestos

Un **índice compuesto** resume en un solo número un fenómeno multidimensional que no puede medirse directamente: desarrollo humano, marginación, competitividad, calidad institucional. Los índices compuestos son, probablemente, la aplicación más visible del análisis multivariante en la política pública. El Índice de Desarrollo Humano del PNUD combina salud, educación e ingreso, y desde 2010 lo hace con una media geométrica (Programa de las Naciones Unidas para el Desarrollo 2010). El índice de marginación del CONAPO se construyó durante décadas como el primer componente principal de un conjunto de indicadores municipales y estatales de carencias; en sus ediciones recientes usa el método de distancia DP2.

Un índice es atractivo porque simplifica, y peligroso por la misma razón. Detrás de cada número hay una cadena de decisiones: qué indicadores incluir, cómo hacerlos comparables, cómo ponderarlos y cómo combinarlos. Cada decisión es discutible, y el orden final de las unidades puede cambiar con ellas. Este capítulo trata esas decisiones con el mismo rigor que los anteriores y sigue el marco del manual de la OCDE y el Centro Común de Investigación de la Comisión Europea (OECD y European Commission Joint Research Centre 2008), que es la referencia estándar. Cubre los contenidos procedimentales del curso de construcción de indicadores y cálculo de un índice agregado.

Datos de trabajo. Continuamos con las 32 entidades federativas y los indicadores de la ENIGH 2024 del Capítulo 3. El objetivo es un **índice estatal de condiciones socioeconómicas de los hogares**.

4.1. Marco conceptual y selección de indicadores

Un índice empieza por una definición del fenómeno, no por los datos disponibles. Aquí entendemos por condiciones socioeconómicas la capacidad de los hogares de una entidad para generar ingreso y acumular capital humano, con menor carga de dependencia. Los criterios para elegir indicadores son:

1. **Relevancia:** el indicador mide una dimensión del fenómeno según el marco conceptual.

2. **Polaridad definida:** debe estar claro si un valor alto es "mejor" o "peor".

3. **Calidad:** los datos son confiables, comparables entre unidades y oportunos.

4. **Estructura:** el análisis multivariante confirma que los indicadores comparten una dimensión común.

El análisis factorial del Capítulo 3 encontró dos factores: nivel socioeconómico y envejecimiento. El segundo no tiene una polaridad clara: una población más envejecida no es, por sí misma, mejor ni peor. Por eso el índice usa sólo los cuatro indicadores del primer factor, cuya consistencia interna ya verificamos ($\alpha = 0.889$, $\omega = 0.883$):

Indicador	Polaridad	Media	Desv. est.	Mín.	Máx.
Ingreso pc (log)	+	10.2066	0.2886	9.5003	10.7813
Escolaridad del jefe	+	6.2230	0.5471	5.0542	7.4345
Prop. de menores	−	0.1758	0.0202	0.1066	0.2210
Prop. de perceptores	+	0.6586	0.0381	0.5849	0.7961

Las desviaciones estándar usan divisor $n = 32$. La Ciudad de México tiene el máximo de ingreso, escolaridad y perceptores, y el mínimo de menores; Chiapas tiene el mínimo de ingreso y perceptores y el máximo de menores; Oaxaca, el mínimo de escolaridad.

4.2. Normalización

Los indicadores tienen unidades distintas: logaritmo de pesos, años codificados y proporciones. Para combinarlos hay que llevarlos a una escala común. Sea x_{ij} el valor del indicador j en la unidad i y $s_j \in \{+1, -1\}$ su polaridad. Los métodos principales son:

1. **Estandarización** (z): $y_{ij} = s_j \dfrac{x_{ij} - \bar{x}_j}{\sigma_j}$.

2. **Mín–máx**: $y_{ij} = \dfrac{x_{ij} - \min_k x_{kj}}{\max_k x_{kj} - \min_k x_{kj}} \in [0,1]$ si $s_j = +1$, y $1 - y_{ij}$ si $s_j = -1$.

3. **Rangos**: $y_{ij} = \text{rango}(s_j x_{ij})/n$.

4. **Distancia a una referencia**: $y_{ij} = x_{ij}/x_{0j}$, con x_{0j} una meta o el valor de una unidad de referencia.

Proposición 4.1 *Sea $\tilde{x}_{ij} = a_j + b_j x_{ij}$ con $b_j > 0$ un cambio de unidades del indicador j.*

1. *La estandarización y la normalización mín–máx son invariantes ante este cambio.*

2. *La normalización por rangos es invariante ante cualquier transformación estrictamente creciente de x_{ij}, no sólo las afines.*

3. *La normalización mín–máx de todas las unidades depende sólo de dos observaciones, la mínima y la máxima; la estandarización depende de todas.*

Demostración. (1) $\tilde{x}_{ij} - \bar{\tilde{x}}_j = b_j(x_{ij} - \bar{x}_j)$ y $\tilde{\sigma}_j = b_j \sigma_j$, de modo que el cociente no cambia; análogamente, $\tilde{x}_{ij} - \min_k \tilde{x}_{kj} = b_j(x_{ij} - \min_k x_{kj})$ y el rango máx $-$ mín también se multiplica por b_j. (2) Una función estrictamente creciente preserva el orden y, por tanto, los rangos. (3) Es inmediato de las fórmulas. ■

El inciso (1) dice que el índice no depende de las unidades: medir el ingreso en pesos o en miles de pesos da lo mismo. El inciso (2) conecta con las escalas de medición de la Sección 1.2: los rangos sólo usan información

ordinal y son robustos a valores extremos, a cambio de descartar las distancias entre unidades. El inciso (3) es la debilidad de la normalización mín–máx: una sola observación atípica fija la escala de todas las demás.

Ejemplo 4.1 (Estandarización a mano) Para Nuevo León, con los valores (10.6699, 6.8527, 0.1671, 0.6386):

$$y_{\text{NL},1} = \frac{10.6699 - 10.2066}{0.2886} = 1.605, \quad y_{\text{NL},2} = \frac{6.8527 - 6.2230}{0.5471} = 1.151,$$
$$y_{\text{NL},3} = -\frac{0.1671 - 0.1758}{0.0202} = 0.428, \quad y_{\text{NL},4} = \frac{0.6386 - 0.6586}{0.0381} = -0.525.$$

Nuevo León está muy por encima de la media en ingreso y escolaridad, ligeramente mejor en menores y por debajo en perceptores. Para la Ciudad de México los valores estandarizados son (1.991, 2.214, 3.423, 3.613): está a más de tres desviaciones estándar de la media en dos indicadores.

Ejemplo 4.2 (Un valor atípico fija la escala) Con la normalización mín–máx, la Ciudad de México recibe 1 en los cuatro indicadores. En perceptores, el valor normalizado de Nuevo León es $(0.6386 - 0.5849)/(0.7961 - 0.5849) = 0.254$. Si la Ciudad de México se excluye al calcular el máximo, que pasa a ser 0.7251 (Colima), el valor de Nuevo León sube a $(0.6386 - 0.5849)/(0.7251 - 0.5849) = 0.383$. Un solo dato cambió la escala de todas las entidades. En este caso, el orden final apenas cambia (Cuadro 4.1), pero no hay garantía de que así sea en general.

4.3. Ponderación

Un índice lineal es $I_i = \sum_j w_j y_{ij} = \boldsymbol{w}'\mathbf{y}_i$, con pesos $w_j \geq 0$ y $\sum_j w_j = 1$. Las opciones principales para elegir $\boldsymbol{w}$ son:

1. **Pesos iguales**, $w_j = 1/p$. Es la opción más común y la más transparente, pero no es "neutral": implica un juicio, a saber, que todas las dimensiones importan lo mismo.

2. **Pesos estadísticos**. Con un análisis factorial de un factor, los pesos proporcionales al cuadrado de las cargas, $w_j = \ell_j^2 / \sum_k \ell_k^2$, reflejan qué proporción de la varianza común aporta cada indicador (Nicoletti, Scarpetta y Boylaud 2000; OECD y European Commission Joint Research

Centre 2008). Con PCA, se usan los cuadrados del primer eigenvector, $w_j = g_{j1}^2$, que suman uno porque $\|\boldsymbol{g}_1\| = 1$.

3. **Pesos participativos**: obtenidos de expertos, de encuestas a la población o de un proceso de consulta.

4. **Beneficio de la duda** (Cherchye et al. 2007): cada unidad recibe los pesos que más la favorecen, sujetos a que ninguna otra unidad supere 1 con esos mismos pesos:

$$I_i^{\text{BoD}} = \max_{\boldsymbol{w} \geq \mathbf{0}} \ \boldsymbol{w}'\mathbf{y}_i \quad \text{sujeto a} \quad \boldsymbol{w}'\mathbf{y}_k \leq 1, \quad k = 1, \ldots, n. \tag{4.1}$$

   Es un programa lineal (análisis envolvente de datos con un solo insumo constante). Su lógica es política: ninguna unidad puede quejarse de que los pesos la perjudican.

Ejemplo 4.3 (Pesos estadísticos) El modelo de un factor del Capítulo 3 dio cargas $\boldsymbol{\ell} = (0.960,\ 0.944,\ 0.715,\ 0.574)$ para ingreso, escolaridad, menores (con polaridad invertida) y perceptores. Como $\sum_j \ell_j^2 = 0.922 + 0.891 + 0.511 + 0.329 = 2.653$, los pesos factoriales son

$$\boldsymbol{w}^{\text{AF}} = (0.348,\ 0.336,\ 0.193,\ 0.124).$$

El primer eigenvalor de la matriz de correlaciones de los cuatro indicadores es 3.009 (el 75.2 % de la varianza), y los pesos del primer componente son $\boldsymbol{w}^{\text{PCA}} = (0.275,\ 0.268,\ 0.256,\ 0.202)$, mucho más cercanos a los iguales. El análisis factorial concentra el peso en ingreso y escolaridad porque son los indicadores con menos varianza específica.

4.3.1. Pesos nominales e importancia efectiva

Los pesos no miden, por sí solos, la importancia de cada indicador en el índice: con indicadores correlacionados, la influencia efectiva de un indicador depende también de sus correlaciones con los demás (Paruolo, Saisana y Saltelli 2013).

Proposición 4.2 *Sean* $\mathbf{y}$ *indicadores estandarizados con matriz de correlaciones* $\mathbf{R}$ *e* $I = \boldsymbol{w}'\mathbf{y}$. *Entonces*

$$\text{Var}(I) = \boldsymbol{w}'\mathbf{R}\boldsymbol{w}, \qquad \text{Corr}(y_j, I) = \frac{(\mathbf{R}\boldsymbol{w})_j}{\sqrt{\boldsymbol{w}'\mathbf{R}\boldsymbol{w}}}. \tag{4.2}$$

Demostración. La primera igualdad es la Proposición 1.4. Para la segunda, $\mathrm{Cov}(y_j, I) = \mathbf{e}_j'\mathbf{R}\boldsymbol{w} = (\mathbf{R}\boldsymbol{w})_j$ y $\mathrm{Var}(y_j) = 1$. ■

La correlación al cuadrado, $\mathrm{Corr}^2(y_j, I)$, es la proporción de la varianza del índice que se explica por el indicador j por separado, y es una medida natural de su importancia efectiva.

Ejemplo 4.4 (Iguales en nombre, no en influencia) Con pesos iguales, los coeficientes $\mathrm{Corr}^2(y_j, I)$ son (0.812, 0.789, 0.774, 0.632): los perceptores influyen menos que los demás indicadores aunque tengan el mismo peso nominal, porque están menos correlacionados con el resto. Con los pesos factoriales, la diferencia se amplía a (0.905, 0.891, 0.683, 0.479). Quien desee que cada dimensión influya *lo mismo* en el índice tendría que resolver para $\boldsymbol{w}$ la ecuación $\mathrm{Corr}(y_j, I) = c$ para toda j, y obtendría pesos nominales desiguales.

4.4. Agregación

4.4.1. Agregación lineal y compensación

La agregación lineal $I_i = \sum_j w_j y_{ij}$ es **totalmente compensatoria**: un mal desempeño en un indicador puede compensarse con un buen desempeño en otro, a una tasa fija. La *tasa marginal de sustitución* entre los indicadores j y k es

$$\left.\frac{dy_k}{dy_j}\right|_{I \text{ constante}} = -\frac{\partial I/\partial y_j}{\partial I/\partial y_k} = -\frac{w_j}{w_k}, \tag{4.3}$$

igual para todas las unidades e independiente de sus niveles. Los pesos, por tanto, no son "importancias" sino *tasas de intercambio*, y como tales deben poder justificarse (Paruolo, Saisana y Saltelli 2013).

Ejemplo 4.5 (¿Qué se intercambia?) Con estandarización y pesos iguales, una desviación estándar de ingreso compensa exactamente una desviación estándar de perceptores. En unidades originales, 0.2886 en el logaritmo del ingreso equivale a multiplicar el ingreso per cápita por $e^{0.2886} = 1.335$. Así, un aumento del 33.5 % en el ingreso per cápita compensa, en el índice, una caída de 3.81 puntos porcentuales en la proporción de perceptores. Explicitar este intercambio permite discutir si es razonable; los pesos por sí solos lo esconden.

4.4.2. Agregación geométrica

Para indicadores positivos, la **media geométrica ponderada** es $G_i = \prod_j y_{ij}^{w_j}$, o bien $\log G_i = \sum_j w_j \log y_{ij}$.

Proposición 4.3 *Sean $y_{ij} > 0$ y $\boldsymbol{w}$ pesos que suman uno.*

1. *$G_i \le I_i = \sum_j w_j y_{ij}$, con igualdad si y sólo si todos los y_{ij} son iguales.*
2. *La tasa marginal de sustitución es $-\dfrac{w_j/y_{ij}}{w_k/y_{ik}}$: depende de los niveles. Un punto adicional en el indicador más rezagado vale más que en el más avanzado.*
3. *Si algún $y_{ij} \to 0$, entonces $G_i \to 0$ sin importar los demás indicadores.*

Demostración. (1) Como log es estrictamente cóncava, la desigualdad de Jensen da $\sum_j w_j \log y_{ij} \le \log \sum_j w_j y_{ij}$, con igualdad si y sólo si todos los y_{ij} coinciden; se exponencia. (2) $\partial G_i / \partial y_{ij} = G_i w_j / y_{ij}$, y el cociente de dos de estas derivadas da el resultado. (3) Es inmediato. ■

La agregación geométrica es, por tanto, **parcialmente compensatoria**: premia los perfiles balanceados y penaliza los desbalanceados. Por esta razón el PNUD la adoptó para el Índice de Desarrollo Humano (Programa de las Naciones Unidas para el Desarrollo 2010). Su costo es que requiere valores estrictamente positivos, y el resultado depende de cómo se elija el límite inferior de la escala.

Ejemplo 4.6 (Mismo promedio, distinto perfil) Llevemos la normalización mín–máx a la escala $[1, 100]$, mediante $1 + 99 y_{ij}$, para evitar ceros. Los perfiles de Nuevo León y Sonora son

	Ingreso	Escol.	Menores	Percep.	Aritm.	Geom.
Nuevo León	91.4	75.8	47.6	26.2	60.25	54.21
Sonora	73.7	70.7	43.0	53.4	60.17	58.78

Con la media aritmética, las dos entidades están empatadas en la práctica, con Nuevo León apenas adelante. Con la geométrica, Sonora queda claramente arriba: su perfil es más parejo, mientras que Nuevo León combina el segundo ingreso más alto del país con una proporción de perceptores por debajo de la media. Por ejemplo, $G_{\text{NL}} = (91.4 \times 75.8 \times 47.6 \times 26.2)^{1/4} = 54.2$. En

el orden nacional con normalización mín–máx, al pasar de la media aritmética a la geométrica, Nuevo León baja del lugar 5 al 7 y Sonora sube del 6 al 5.

4.5. Robustez: análisis de incertidumbre y sensibilidad

Como cada decisión metodológica es discutible, un índice responsable reporta cuánto cambian sus resultados cuando las decisiones cambian (Saisana, Saltelli y Tarantola 2005). Hay dos niveles de análisis.

Variantes deterministas. Se recalcula el índice con alternativas razonables para cada decisión, una a la vez, y se compara con el índice base. Una medida resumen es el *cambio absoluto medio de lugar*, $\bar{\Delta} = \frac{1}{n}\sum_i |\text{lugar}_i^{\text{base}} - \text{lugar}_i^{\text{variante}}|$.

Cuadro 4.1: Variantes del índice: correlación de Spearman con el índice base (estandarización, pesos iguales, agregación lineal) y cambio absoluto medio de lugar

Variante	Spearman	$\bar{\Delta}$
Estandarización, pesos factoriales	0.977	1.44
Estandarización, pesos de PCA	0.996	0.44
Mín–máx, pesos iguales	0.998	0.25
Mín–máx sin CDMX en la escala	0.997	0.31
Rangos, pesos iguales	0.988	0.94
Mín–máx, agregación geométrica	0.992	0.75

Todas las correlaciones superan 0.97: en lo agregado, el índice es robusto. Pero el promedio esconde movimientos individuales grandes: con pesos factoriales, Nuevo León sube del lugar 6 al 3 y Nayarit baja del 12 al 17; con agregación geométrica, Baja California baja del 10 al 14.

Análisis de incertidumbre por Monte Carlo. Se tratan las decisiones como aleatorias y se simulan muchas combinaciones. En cada una de $B = 10\,000$ réplicas:

1. se elige al azar la normalización: estandarización, mín–máx o rangos;
2. se generan pesos aleatorios $\boldsymbol{w} \sim \text{Dirichlet}(5, 5, 5, 5)$, centrados en los pesos iguales pero con variación apreciable (cada peso tiene media 0.25 y desviación estándar $\sqrt{5 \cdot 15/(20^2 \cdot 21)} = 0.09$);
3. se elige al azar la agregación: lineal o geométrica;
4. se calcula el índice y se registra el lugar de cada entidad.

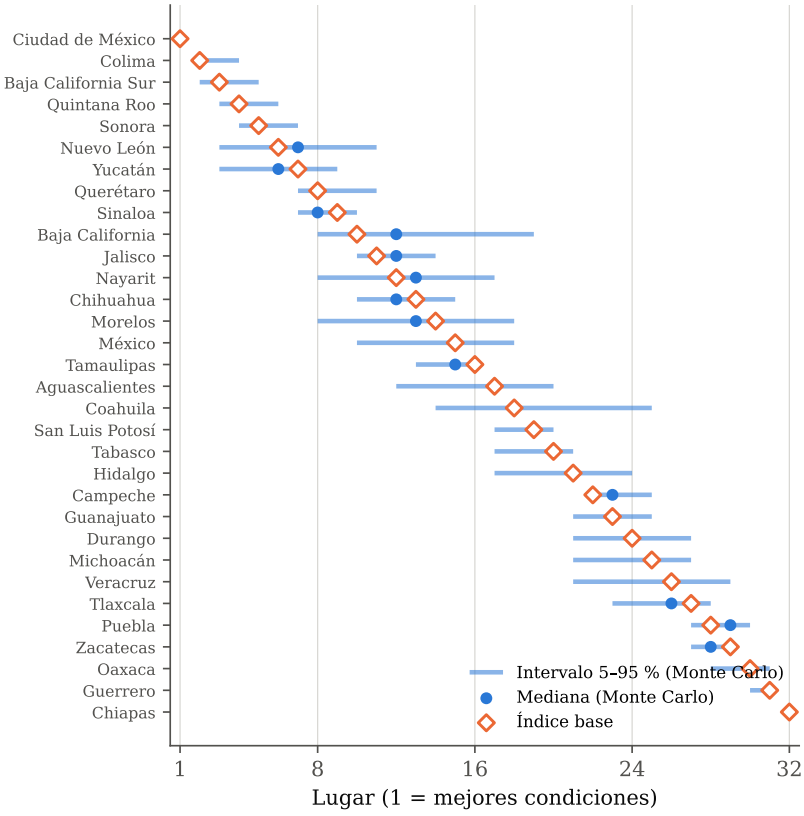


Figura 4.1: Lugar de cada entidad en el índice base (rombos) y distribución de su lugar en 10 000 combinaciones aleatorias de normalización, pesos y agregación: mediana (puntos) e intervalo del 5 % al 95 % (barras). Elaboración propia con datos de la ENIGH 2024.

La Figura 4.1 muestra el resultado. Los extremos son robustos: la Ciudad de México es primera y Chiapas última en todas las réplicas, y Guerrero y

Oaxaca ocupan los lugares 28 a 31. En la parte media, en cambio, la incertidumbre es grande: el intervalo de Baja California va del lugar 8 al 19, el de Coahuila del 14 al 25 y el de Nuevo León del 3 al 11. En promedio, una entidad se mueve 1.23 lugares respecto al índice base. La conclusión práctica es que *no* tiene sentido afirmar que una entidad de la mitad de la tabla "supera" a su vecina: las diferencias pequeñas de lugar no sobreviven a cambios razonables en la metodología. Es mejor comunicar grupos de entidades similares, que es precisamente lo que hace el análisis de conglomerados (Capítulo 5).

Ejemplo 4.7 (Beneficio de la duda) Resolviendo el programa lineal (4.1) con los indicadores mín–máx en $[1, 100]$, sólo la Ciudad de México alcanza el valor 1, porque domina a todas las entidades en los cuatro indicadores. Nuevo León queda segunda (0.914): el programa le asigna casi todo el peso al ingreso, su fortaleza, y prácticamente nada a los perceptores. Le siguen Baja California Sur (0.865) y Baja California (0.822); al final quedan Oaxaca (0.323), Guerrero (0.230) y Chiapas (0.021). La correlación de Spearman con el índice base es 0.919, la más baja de todas las variantes: dejar que cada unidad elija sus pesos es la decisión más influyente. En la práctica se acota el rango de los pesos para evitar que una unidad ignore por completo una dimensión.

4.6. Validación

Un índice es válido si se comporta como la teoría predice frente a variables que *no* entraron en su construcción (validez de criterio). Una regularidad empírica muy estable en economía es la **ley de Engel**: la proporción del gasto destinada a alimentos disminuye conforme aumenta el nivel de vida (Houthakker 1957). Si el índice mide condiciones socioeconómicas, debería correlacionarse negativamente con esa proporción.

Ejemplo 4.8 (Validación con la ley de Engel) Con la ENIGH 2024, la proporción del gasto monetario de los hogares destinada a alimentos va del 31.8 % (Coahuila) al 46.5 % (Chiapas). Su correlación con el índice base es -0.486 (Spearman: -0.452), con el signo esperado y una magnitud moderada. La relación no es perfecta, ni debería serlo: la proporción del gasto en alimentos también depende de precios relativos y patrones regionales de

consumo. Si la correlación hubiera sido positiva o nula, habría que revisar el índice.

Otras validaciones posibles son la comparación con índices oficiales, como el de marginación del CONAPO o la medición de pobreza, y la estabilidad en el tiempo con ediciones anteriores de la ENIGH.

4.7. El índice resultante

El Cuadro 4.2 presenta el índice base, construido con estandarización, pesos iguales y agregación lineal, por ser la combinación más transparente. Se acompaña del intervalo del Monte Carlo. Por construcción, el índice tiene media cero: valores positivos indican condiciones mejores que el promedio de las entidades.

Cuadro 4.2: Índice de condiciones socioeconómicas de los hogares por entidad federativa, ENIGH 2024

Entidad	Índice	Lugar	Interv. 5–95 %	Entidad	Índice	Lugar	Interv. 5–95 %
Ciudad de México	2.810	1	1–1	Coahuila	0.000	18	14–25
Colima	1.017	2	2–4	San Luis Potosí	−0.153	19	17–20
Baja California Sur	0.822	3	2–5	Tabasco	−0.182	20	17–21
Quintana Roo	0.752	4	3–6	Hidalgo	−0.276	21	17–24
Sonora	0.724	5	4–7	Campeche	−0.420	22	22–25
Nuevo León	0.665	6	3–11	Guanajuato	−0.427	23	21–25
Yucatán	0.641	7	3–9	Durango	−0.496	24	21–27
Querétaro	0.522	8	7–11	Michoacán	−0.536	25	21–27
Sinaloa	0.455	9	7–10	Veracruz	−0.588	26	21–29
Baja California	0.359	10	8–19	Tlaxcala	−0.588	27	23–28
Jalisco	0.262	11	10–14	Puebla	−0.803	28	27–30
Nayarit	0.259	12	8–17	Zacatecas	−0.810	29	27–29
Chihuahua	0.253	13	10–15	Oaxaca	−1.253	30	28–31
Morelos	0.251	14	8–18	Guerrero	−1.482	31	30–31
México	0.195	15	10–18	Chiapas	−2.177	32	32–32
Tamaulipas	0.135	16	13–16				
Aguascalientes	0.069	17	12–20				

4.8. Lista de verificación

El manual de la OCDE organiza la construcción de un índice en diez pasos (OECD y European Commission Joint Research Centre 2008), que se corresponden con las etapas de Hair (Sección 1.8):

1. **Marco teórico:** definir el fenómeno, sus dimensiones y la unidad de análisis.
2. **Selección de datos:** indicadores relevantes, de calidad y con polaridad clara.
3. **Imputación** de datos faltantes, documentando el método.
4. **Análisis multivariante:** verificar la estructura (PCA, análisis factorial, α).
5. **Normalización**, considerando valores atípicos y polaridad.
6. **Ponderación y agregación**, explicitando los intercambios que implican.
7. **Incertidumbre y sensibilidad.**
8. **Regreso a los datos:** descomponer el índice para ver qué indicadores explican el lugar de cada unidad.
9. **Vínculo con otros indicadores** (validación).
10. **Presentación:** comunicar el resultado con sus intervalos de incertidumbre.

Un índice publicado influye en decisiones de política y en la reputación de las unidades evaluadas. Por eso la transparencia no es opcional: los datos, el código y cada decisión deben ser públicos y reproducibles, y las limitaciones deben reportarse con la misma visibilidad que los resultados.

4.9. Implementación en Python

```
import numpy as np
import pandas as pd

X = pd.read_csv("03 Factor Analysis/04 Entidades ENIGH/
    enigh2024_entidades.csv",
                index_col=0)
V = ["ing_pc", "edu_jefe", "menores_sh", "perceptores"]
```

```
pol = np.array([1, 1, -1, 1]) # polaridad

Z = (X[V] - X[V].mean()) / X[V].std(ddof=0) * pol # estandarizacion
w = np.full(4, 0.25) # pesos iguales
indice = (Z @ w).sort_values(ascending=False)

# Importancia efectiva de cada indicador
R = Z.corr().values
print((R @ w) / np.sqrt(w @ R @ w)) # Corr(y_j, I)

# Agregacion geometrica sobre min-max en [1, 100]
M = (X[V] - X[V].min()) / (X[V].max() - X[V].min())
M.loc[:, pol < 0] = 1 - M.loc[:, pol < 0]
geo = np.exp(np.log(1 + 99 * M) @ w)
```

El cuaderno `04 Indices/01 Indice ENIGH/Indice_Compuesto_ENIGH.ipynb` del repositorio reproduce todas las variantes, el análisis Monte Carlo, el beneficio de la duda y la validación de este capítulo.

4.10. Ejercicios

1. Demuestre que la normalización por distancia a una referencia, $y_{ij} = x_{ij}/x_{0j}$, es invariante ante cambios de escala $\tilde{x} = bx$ con $b > 0$, pero no ante cambios de origen $\tilde{x} = a + bx$. ¿Para qué escala de medición es apropiada?

2. Demuestre que con pesos iguales y estandarización el índice lineal es proporcional a la suma de las puntuaciones z, y que su varianza es $\bar{r}(p-1)/p + 1/p$ veces la de un indicador, donde $\bar{r}$ es la correlación promedio.

3. Encuentre los pesos $\boldsymbol{w}$ para los cuales los cuatro indicadores tienen la misma correlación con el índice (Proposición 4.2). *Sugerencia:* la condición es $\mathbf{R}\boldsymbol{w} \propto \mathbf{1}$.

4. Con los datos del Ejemplo 4.6, ¿qué peso tendría que recibir la proporción de perceptores, repartiendo el resto por igual, para que Nuevo León y Sonora empaten con agregación geométrica?

5. Demuestre que en el programa (4.1) al menos una unidad obtiene $I^{\text{BoD}} = 1$, y que una unidad que domina a todas las demás en todos los indicadores obtiene el valor óptimo $I^{\text{BoD}} = 1$. ¿Es cierto que obtiene 1 con *cualquier* vector de pesos factible? Justifique.

6. (Computacional) Repita el análisis Monte Carlo agregando como fuente de incertidumbre la inclusión o exclusión de la proporción de perceptores. ¿Qué entidades se vuelven más inciertas?

7. (Computacional) Construya el índice con los hogares en lugar de las entidades: calcule los cuatro indicadores para cada hogar de la ENIGH, construya el índice a nivel hogar y promedie por entidad con el factor de expansión. ¿Coincide con el índice estatal? Discuta.

8. (Proyecto) Proponga un índice para otro fenómeno de su interés, con al menos cinco indicadores de fuentes públicas mexicanas (INEGI, CONEVAL, CONAPO, Banxico). Documente cada uno de los diez pasos de la Sección 4.8.

5

Análisis de Conglomerados

El término clúster se refiere a un grupo de individuos u objetos que convergen alrededor de cierto punto y son relativamente cercanos en su posición. En astronomía existen clústeres de estrellas; en química, clústeres de átomos. En economía, el término se refiere a técnicas que identifican grupos dentro del total de la población. Por ejemplo, las empresas que buscan analizar a sus clientes potenciales podrían dividir el total de consumidores en segmentos o clústeres.

El propósito del análisis de clúster, o de conglomerados, es identificar grupos homogéneos dentro de un conjunto de individuos u objetos heterogéneos. Un malentendido muy común es creer que existe un solo tipo de técnica de conglomerados. En realidad existen muchas, porque hay una amplia variedad de medidas de distancia y de algoritmos de agrupamiento que pueden usarse.

El agrupamiento (*clustering*) se refiere a un conjunto muy amplio de técnicas para encontrar subgrupos, o clústeres, en un conjunto de datos. El objetivo es encontrar una partición de los datos en grupos distintos de modo que las observaciones dentro de cada grupo sean bastante similares entre sí en algún sentido. Ese sentido de similitud suele ser una consideración específica del dominio, que debe establecerse con base en el conocimiento de los datos que se estudian.

En las bibliotecas organizamos los libros por categorías y subcategorías que responden a las necesidades de los usuarios, a menudo no definidas con claridad. En casa organizamos nuestras cosas en ropa, zapatos, utensilios de cocina y otros, por conveniencia. El agrupamiento tiene propósitos difíciles de caracterizar con una sola variable de resultado; por esa razón el aprendizaje supervisado no es aplicable al problema. Un buen ejemplo en el comercio es

la segmentación de mercado: con datos como el ingreso medio del hogar, la ocupación o la distancia al área urbana más cercana, se buscan subgrupos de personas que podrían ser más receptivas a una forma particular de publicidad, o más propensas a comprar un producto.

A diferencia de PCA, que busca una representación de baja dimensión de las observaciones que explique una buena fracción de la varianza, el agrupamiento busca subgrupos homogéneos entre las observaciones. Los dos métodos más utilizados son el agrupamiento **jerárquico** y el de **k-medias**. En k-medias se busca particionar las observaciones en un número de grupos especificado de antemano; en el agrupamiento jerárquico no se fija ese número, y el resultado es una representación en forma de árbol, llamada **dendrograma**, que muestra a la vez el agrupamiento obtenido para cada número posible de grupos (véase la Figura 5.4, más adelante).

El capítulo sigue a Everitt et al. (2011), Kaufman y Rousseeuw (1990), Johnson y Wichern (2007, Cap. 12), Hastie, Tibshirani y Friedman (2017, Sec. 14.3) y James et al. (2021, Sec. 12.4); los aspectos aplicados siguen el capítulo de análisis de conglomerados de Hair et al. (2006).

Datos de trabajo. Segmentaremos las 32 entidades federativas usando sus puntuaciones en los dos factores del Capítulo 3: F1, nivel socioeconómico, y F2, envejecimiento. Agrupar con puntuaciones factoriales, en lugar de con los seis indicadores originales, tiene dos ventajas: las variables de agrupamiento no están correlacionadas, de modo que ninguna dimensión se cuenta dos veces, y el resultado puede graficarse en el plano. Para los ejemplos a mano usaremos cinco entidades, con sus puntuaciones redondeadas a un decimal:

Entidad	F1	F2
Nuevo León (NL)	1.1	−0.6
Quintana Roo (QR)	0.7	−2.2
Veracruz (VER)	−0.8	1.7
Oaxaca (OAX)	−1.7	1.0
Chiapas (CHIS)	−2.5	−0.7

5.1. Medidas de distancia y de similitud

Todo método de conglomerados parte de una medida de qué tan distintos son dos objetos.

Definición 5.1 *Una función $d : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ es una* ***métrica*** *si para todos* $\mathbf{x}, \mathbf{y}, \mathbf{z}$*: (i)* $d(\mathbf{x}, \mathbf{y}) \geq 0$*, con igualdad si y sólo si* $\mathbf{x} = \mathbf{y}$*; (ii)* $d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x})$*; y (iii)* $d(\mathbf{x}, \mathbf{z}) \leq d(\mathbf{x}, \mathbf{y}) + d(\mathbf{y}, \mathbf{z})$ *(desigualdad del triángulo). Si sólo se cumplen (i) y (ii),* d *es una* ***disimilitud****.*

Sea $\mathbf{X} = \{x_{ij}\}$ la matriz de datos, con x_{ij} el valor de la variable j en el objeto i, y $\mathbf{x}_i = (x_{i1}, \ldots, x_{ip})'$. La clase más usada en el análisis de conglomerados es la de las distancias de **Minkowski**:

$$ {}_rd_{il} = \left[\sum_{j=1}^{p} |x_{ij} - x_{lj}|^r \right]^{1/r}, \qquad r \geq 1. \tag{5.1} $$

Para $r = 1$ se obtiene la distancia **Manhattan**, ${}_1d_{il} = \sum_j |x_{ij} - x_{lj}|$; para $r = 2$, la **euclidiana**, ${}_2d_{il} = \left[\sum_j (x_{ij} - x_{lj})^2\right]^{1/2}$; y cuando $r \to \infty$, la distancia del **máximo**, $\max_j |x_{ij} - x_{lj}|$. Las versiones ponderadas son

$$ {}_r\tilde{d}_{il} = \left[\sum_{j=1}^{p} w_j^r \, |x_{ij} - x_{lj}|^r \right]^{1/r}, \qquad r \geq 1, \tag{5.2} $$

donde w_j es una ponderación adecuada para la variable j. La desigualdad del triángulo para las distancias de Minkowski es la desigualdad de Minkowski, que requiere $r \geq 1$. Para usar estas medidas en el agrupamiento jerárquico conviene organizarlas en la **matriz de distancias** $\mathbf{D} = \{d_{il} : i, l = 1, \ldots, n\}$, simétrica y con diagonal cero.

Una lección que la experiencia ha mostrado es que las distancias deben basarse en unidades comparables. Si las variables están en unidades distintas, deben llevarse a una escala común, usualmente con la estandarización z; de lo contrario, la variable con los números más grandes domina la distancia (Ejemplo 1.7). Si además las variables están correlacionadas, la distancia euclidiana cuenta dos veces la información común; la distancia de **Mahalanobis** (Sección 1.5) o el uso de componentes o factores no correlacionados corrigen ese problema.

Datos mixtos: la distancia de Gower. Cuando hay variables métricas y categóricas, Gower (1971) propuso la similitud

$$ s_{il} = \frac{\sum_{j=1}^{p} \delta_{ilj} \, s_{ilj}}{\sum_{j=1}^{p} \delta_{ilj}}, \qquad d_{il} = 1 - s_{il}, \tag{5.3} $$

donde, para una variable métrica, $s_{ilj} = 1 - |x_{ij} - x_{lj}|/\text{rango}_j$; para una nominal, $s_{ilj} = 1$ si las categorías coinciden y 0 si no; y $\delta_{ilj} = 0$ si falta el dato j en alguno de los dos objetos, y 1 en otro caso. Cada variable contribuye con un valor en $[0, 1]$, lo que resuelve el problema de las unidades y permite datos faltantes.

Ejemplo 5.1 (Matriz de distancias) Con las cinco entidades de trabajo, la distancia euclidiana entre Nuevo León y Quintana Roo es $\sqrt{(1.1-0.7)^2 + (-0.6+2.2)^2} = \sqrt{0.16 + 2.56} = 1.65$. La matriz completa es

$$\mathbf{D} = \begin{bmatrix} 0 & 1.65 & 2.98 & 3.22 & 3.60 \\ 1.65 & 0 & 4.18 & 4.00 & 3.53 \\ 2.98 & 4.18 & 0 & 1.14 & 2.94 \\ 3.22 & 4.00 & 1.14 & 0 & 1.88 \\ 3.60 & 3.53 & 2.94 & 1.88 & 0 \end{bmatrix} \begin{matrix} \text{NL} \\ \text{QR} \\ \text{VER} \\ \text{OAX} \\ \text{CHIS} \end{matrix}$$

El par más cercano es Veracruz–Oaxaca (1.14) y el más lejano, Quintana Roo–Veracruz (4.18).

5.2. La descomposición de la dispersión

Los métodos de partición y el método de Ward se basan en una misma identidad, que extiende al caso multivariante la descomposición de la suma de cuadrados del análisis de varianza.

Lema 5.1 *Para un conjunto C de n_C puntos con media $\bar{\mathbf{x}}_C$ y cualquier $\boldsymbol{m} \in \mathbb{R}^p$,*

$$\sum_{i \in C} \|\mathbf{x}_i - \boldsymbol{m}\|^2 = \sum_{i \in C} \|\mathbf{x}_i - \bar{\mathbf{x}}_C\|^2 + n_C \|\bar{\mathbf{x}}_C - \boldsymbol{m}\|^2. \tag{5.4}$$

En particular, la media es el punto que minimiza la suma de distancias euclidianas al cuadrado.

Demostración. Escriba $\mathbf{x}_i - \boldsymbol{m} = (\mathbf{x}_i - \bar{\mathbf{x}}_C) + (\bar{\mathbf{x}}_C - \boldsymbol{m})$ y desarrolle el cuadrado. El término cruzado es $2(\bar{\mathbf{x}}_C - \boldsymbol{m})' \sum_{i \in C} (\mathbf{x}_i - \bar{\mathbf{x}}_C) = 0$, porque las desviaciones respecto a la media suman cero. ∎

Proposición 5.2 ($\boldsymbol{T} = \boldsymbol{W} + \boldsymbol{B}$) *Sea $\{C_1, \ldots, C_k\}$ una partición de los n objetos, con tamaños n_c, medias $\bar{\mathbf{x}}_c$ y media global $\bar{\mathbf{x}}$. Defínanse*

$$\boldsymbol{T} = \sum_{i=1}^{n} (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})', \qquad \boldsymbol{W} = \sum_{c=1}^{k} \sum_{i \in C_c} (\mathbf{x}_i - \bar{\mathbf{x}}_c)(\mathbf{x}_i - \bar{\mathbf{x}}_c)',$$

$$\boldsymbol{B} = \sum_{c=1}^{k} n_c (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})(\bar{\mathbf{x}}_c - \bar{\mathbf{x}})'.$$

Entonces $\boldsymbol{T} = \boldsymbol{W} + \boldsymbol{B}$ y, tomando trazas, $\operatorname{tr}(\boldsymbol{T}) = \operatorname{tr}(\boldsymbol{W}) + \operatorname{tr}(\boldsymbol{B})$.

Demostración. Para cada grupo, $\mathbf{x}_i - \bar{\mathbf{x}} = (\mathbf{x}_i - \bar{\mathbf{x}}_c) + (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})$. Al formar los productos exteriores y sumar sobre $i \in C_c$, los términos cruzados se anulan porque $\sum_{i \in C_c} (\mathbf{x}_i - \bar{\mathbf{x}}_c) = \mathbf{0}$. Sumando sobre c se obtiene la igualdad. ■

$\boldsymbol{T}$ es fija (n veces la matriz de covarianzas). Por lo tanto, cualquier partición que reduzca la dispersión *dentro* de los grupos, $W = \operatorname{tr}(\boldsymbol{W})$, aumenta en la misma cantidad la dispersión *entre* grupos, $B = \operatorname{tr}(\boldsymbol{B})$. Minimizar la heterogeneidad interna y maximizar la separación son el mismo problema.

5.3. Agrupamiento jerárquico

El agrupamiento jerárquico busca construir una jerarquía de grupos. Las estrategias pueden ser **aglomerativas**, de abajo hacia arriba: cada observación comienza en su propio grupo y los pares de grupos se fusionan a medida que se asciende en la jerarquía. También pueden ser **divisivas**, de arriba hacia abajo: todas las observaciones comienzan en un grupo y se dividen recursivamente. El agrupamiento divisivo con búsqueda exhaustiva tiene complejidad $O(2^n)$, por lo que en la práctica se usan heurísticas, como dividir cada grupo en dos con k-medias.

El agrupamiento aglomerativo produce una sucesión de particiones: la primera consta de n grupos de un solo miembro y la última, de un solo grupo con todas las unidades. El procedimiento general es:

1. Empezar con n grupos de un solo elemento y calcular su matriz de distancias.

2. Buscar en la matriz el par de grupos más cercanos, $d(C_p, C_q) = \min_{a \neq b} d(C_a, C_b)$, y fusionarlos en un nuevo grupo $C_p \cup C_q$.

3. Actualizar la matriz calculando las distancias entre el nuevo grupo y los demás.

4. Repetir los pasos 2 y 3 hasta que sólo quede un grupo.

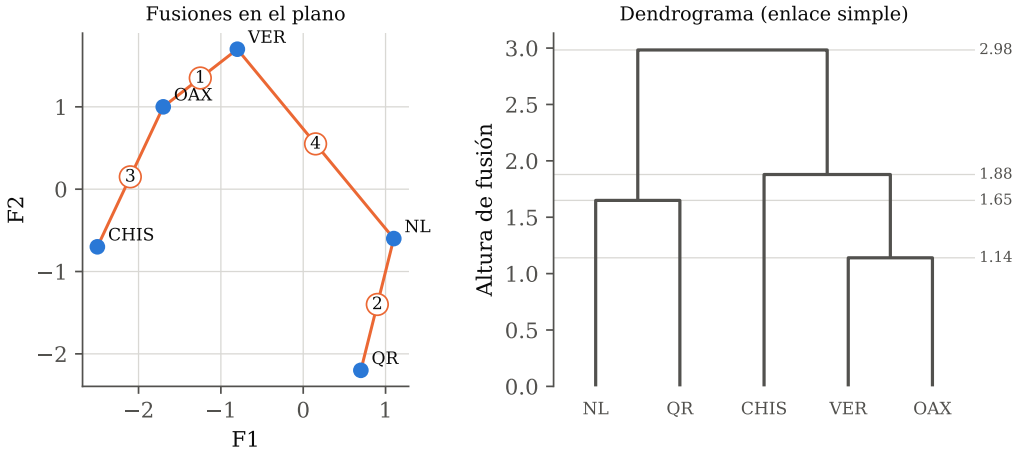


Figura 5.1: El algoritmo aglomerativo con enlace simple en el ejemplo de las cinco entidades (Ejemplo 5.2). Izquierda: orden de las fusiones en el plano. Derecha: dendrograma, con la altura de cada fusión. Elaboración propia.

5.3.1. Criterios de enlace

La fusión depende de cómo se defina la distancia entre dos grupos A y B:

- **Enlace simple**: $d(A, B) = \min\{d(\mathbf{a}, \mathbf{b}) : \mathbf{a} \in A, \mathbf{b} \in B\}$, la distancia entre las dos unidades más cercanas. Tiende a generar grupos alargados, lo que causa el efecto de *encadenamiento*: dos grupos muy distintos pueden quedar unidos por una cadena de puntos intermedios. Si los grupos están muy separados, funciona bien.

- **Enlace completo**: $d(A, B) = \max\{d(\mathbf{a}, \mathbf{b}) : \mathbf{a} \in A, \mathbf{b} \in B\}$, la distancia entre las dos unidades más lejanas. Evita el encadenamiento y produce grupos compactos, pero es sensible a valores atípicos.

- **Enlace promedio**: $d(A,B) = \frac{1}{|A||B|}\sum_{\mathbf{a}\in A}\sum_{\mathbf{b}\in B} d(\mathbf{a},\mathbf{b})$, el promedio de las distancias entre todos los pares. Busca un equilibrio entre los dos anteriores. Su variante **ponderada** (WPGMA) promedia las distancias de los dos grupos que se fusionaron sin tomar en cuenta su tamaño.
- **Enlace de centroides**: $d(A,B) = \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|$, la distancia entre las medias.
- **Método de Ward**, o de mínima varianza (Ward 1963): fusiona el par de grupos cuya unión aumenta menos la suma de cuadrados dentro de los grupos, $W = \mathrm{tr}(\boldsymbol{W})$.

Proposición 5.3 (Costo de una fusión de Ward) *Al fusionar los grupos A y B, la suma de cuadrados dentro de los grupos aumenta en*

$$\Delta(A,B) = \frac{n_A n_B}{n_A + n_B}\,\|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2. \tag{5.5}$$

Demostración. Sea $\boldsymbol{m}$ la media de $A\cup B$, que satisface $(n_A+n_B)\boldsymbol{m} = n_A\bar{\mathbf{x}}_A + n_B\bar{\mathbf{x}}_B$. Por el Lema 5.1 aplicado a cada grupo con el punto $\boldsymbol{m}$,

$$\begin{aligned}\Delta &= \sum_{i\in A\cup B}\|\mathbf{x}_i - \boldsymbol{m}\|^2 - \sum_{i\in A}\|\mathbf{x}_i - \bar{\mathbf{x}}_A\|^2 - \sum_{i\in B}\|\mathbf{x}_i - \bar{\mathbf{x}}_B\|^2\\ &= n_A\|\bar{\mathbf{x}}_A - \boldsymbol{m}\|^2 + n_B\|\bar{\mathbf{x}}_B - \boldsymbol{m}\|^2.\end{aligned}$$

Como $\bar{\mathbf{x}}_A - \boldsymbol{m} = \frac{n_B}{n_A+n_B}(\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B)$ y $\bar{\mathbf{x}}_B - \boldsymbol{m} = -\frac{n_A}{n_A+n_B}(\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B)$, se obtiene

$$\Delta = \frac{n_A n_B^2 + n_B n_A^2}{(n_A+n_B)^2}\|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2 = \frac{n_A n_B}{n_A+n_B}\|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2.$$

■

Ward favorece fusionar grupos cercanos *y* pequeños: el factor $n_A n_B/(n_A+n_B)$ es la media armónica de los tamaños, dividida entre dos. Por eso tiende a producir grupos de tamaño similar.

5.3.2. La fórmula de Lance y Williams

Todos los criterios anteriores pueden actualizarse sin volver a los datos originales, con una sola fórmula (Lance y Williams 1967). Si los grupos i y j se fusionan, la distancia del nuevo grupo a cualquier otro grupo k es

$$d(k, i\cup j) = \alpha_i\, d(k,i) + \alpha_j\, d(k,j) + \beta\, d(i,j) + \gamma\,|d(k,i) - d(k,j)|, \tag{5.6}$$

con los coeficientes del Cuadro 5.1. Para el enlace de centroides y el de Ward, d es la distancia euclidiana *al cuadrado*.

Cuadro 5.1: Coeficientes de la fórmula de Lance y Williams ($n_{ij} = n_i + n_j$, $n_{ijk} = n_i + n_j + n_k$)

Método	α_i	α_j	β	γ
Simple	$1/2$	$1/2$	0	$-1/2$
Completo	$1/2$	$1/2$	0	$1/2$
Promedio	n_i/n_{ij}	n_j/n_{ij}	0	0
Promedio ponderado	$1/2$	$1/2$	0	0
Centroide	n_i/n_{ij}	n_j/n_{ij}	$-n_i n_j/n_{ij}^2$	0
Ward	$(n_i + n_k)/n_{ijk}$	$(n_j + n_k)/n_{ijk}$	$-n_k/n_{ijk}$	0

Para el enlace simple, la fórmula da $\frac{1}{2}(a+b) - \frac{1}{2}|a-b| = \text{mín}(a,b)$, con $a = d(k,i)$ y $b = d(k,j)$, que es exactamente la distancia mínima; para el completo, $\frac{1}{2}(a+b) + \frac{1}{2}|a-b| = \text{máx}(a,b)$. Las demás filas se verifican de manera similar (Ejercicio 2).

Ejemplo 5.2 (Enlace simple, completo y Ward a mano) Con la matriz **D** del Ejemplo 5.1:

1. La menor distancia es VER–OAX = 1.14: se fusionan.
2. Con enlace simple, las distancias de NL, QR y CHIS al nuevo grupo {VER, OAX} son $\text{mín}(2.98, 3.22) = 2.98$, $\text{mín}(4.18, 4.00) = 4.00$ y $\text{mín}(2.94, 1.88) = 1.88$. La menor distancia en la matriz actualizada es NL–QR = 1.65: se fusionan.
3. Ahora CHIS está a 1.88 de {VER, OAX} y a $\text{mín}(3.60, 3.53) = 3.53$ de {NL, QR}: se une a {VER, OAX} a la altura 1.88.
4. Finalmente, los dos grupos se unen a la altura 2.98, la menor de las seis distancias entre sus miembros.

La Figura 5.1 muestra estas fusiones y el dendrograma resultante. Con enlace completo el orden de fusión es el mismo, pero las alturas cambian: CHIS se une a {VER, OAX} a $\text{máx}(2.94, 1.88) = 2.94$, y la fusión final ocurre a 4.18. Con Ward, los costos de fusión son $\Delta = 1.14^2/2 = 0.65$ para VER–OAX, $1.65^2/2 = 1.36$ para NL–QR y 3.84 para unir CHIS con {VER, OAX}.

La partición en dos grupos, {NL, QR} y {VER, OAX, CHIS}, tiene $W = 0.65 + 1.36 + 3.84 = 5.85$.

5.3.3. El dendrograma y la correlación cofenética

En el dendrograma, la altura a la que se unen dos objetos es su **distancia cofenética**. Cortar el árbol a una altura dada produce una partición. Una medida de qué tan fielmente el árbol representa las distancias originales es la **correlación cofenética**: la correlación entre las $n(n-1)/2$ distancias originales y las cofenéticas. Para el enlace simple, completo y promedio, las alturas de fusión son monótonas crecientes, de modo que el árbol es una *ultramétrica*: $d(\mathbf{x}, \mathbf{z}) \leq \max\{d(\mathbf{x}, \mathbf{y}), d(\mathbf{y}, \mathbf{z})\}$. El enlace de centroides, en cambio, puede producir *inversiones*: una fusión posterior a menor altura que una anterior.

5.4. Agrupamiento no jerárquico: k-medias

A diferencia del agrupamiento jerárquico, que genera una sucesión de particiones mediante fusiones o divisiones, el agrupamiento no jerárquico o por particiones asigna los objetos a k grupos sin ninguna estructura jerárquica. El proceso optimiza una función criterio, normalmente una medida de la variabilidad interna de los grupos.

El método de **k-medias** (MacQueen 1967), también llamado c-medias, busca la partición que minimiza la suma de distancias euclidianas al cuadrado de cada objeto al centroide de su grupo:

$$\min_{\boldsymbol{U}, \boldsymbol{h}_1, \ldots, \boldsymbol{h}_k} J(\boldsymbol{U}, \boldsymbol{h}) = \sum_{i=1}^{n} \sum_{c=1}^{k} u_{ic} \, \|\mathbf{x}_i - \boldsymbol{h}_c\|^2, \tag{5.7}$$

sujeto a $\sum_{c=1}^{k} u_{ic} = 1$ y $u_{ic} \in \{0, 1\}$, donde $u_{ic} = 1$ si el objeto i pertenece al grupo c y 0 en otro caso, y $\boldsymbol{h}_c$ es el centroide del grupo c. Por el Lema 5.1, el centroide óptimo de cada grupo es su media, y el valor mínimo de J para una partición dada es $W = \operatorname{tr}(\boldsymbol{W})$.

El problema (5.7) es combinatorio: el número de particiones de n objetos en k grupos crece aproximadamente como $k^n/k!$. Se resuelve con un procedimiento iterativo de tipo *hill-climbing*, el algoritmo de Lloyd:

1. Elegir k centroides iniciales, al azar o con base en algún conocimiento previo.

2. **Asignación:** asignar cada objeto al centroide más cercano.

3. **Actualización:** recalcular cada centroide como la media de los objetos asignados a él.

4. Repetir los pasos 2 y 3 hasta que las asignaciones no cambien.

Proposición 5.4 (Convergencia de k-medias) *Cada paso del algoritmo de Lloyd no aumenta J, y el algoritmo termina en un número finito de iteraciones.*

Demostración. Con los centroides fijos, el paso de asignación elige para cada i el c que minimiza $\|\mathbf{x}_i - \boldsymbol{h}_c\|^2$, así que no aumenta J. Con las asignaciones fijas, el paso de actualización minimiza $\sum_{i \in C_c} \|\mathbf{x}_i - \boldsymbol{h}_c\|^2$ para cada grupo, por el Lema 5.1, así que tampoco aumenta J. Por lo tanto, J es no creciente a lo largo de las iteraciones. Como hay un número finito de particiones y el algoritmo se detiene cuando la partición no cambia, nunca puede visitar dos veces la misma partición con J estrictamente menor; termina en un número finito de pasos. ■

La proposición garantiza la convergencia, pero sólo a un **óptimo local**: un punto fijo del algoritmo que no necesariamente minimiza J globalmente. El resultado depende de los centroides iniciales. La práctica estándar es repetir el algoritmo con muchos arranques y quedarse con la solución de menor J, e iniciar con **k-means++** (Arthur y Vassilvitskii 2007): el primer centroide se elige al azar y cada uno de los siguientes se elige con probabilidad proporcional al cuadrado de su distancia al centroide más cercano ya elegido. Esa siembra garantiza, en valor esperado, una solución a lo más $O(\log k)$ veces peor que la óptima. El algoritmo también es sensible a valores atípicos (las medias lo son) y puede producir grupos vacíos. Se supone que k es fijo; elegirlo es el tema de la Sección 5.6.

Ejemplo 5.3 (Dos arranques, dos óptimos locales) Apliquemos k-medias con $k = 2$ a las cinco entidades de trabajo.

Arranque A: centroides iniciales en NL $(1.1, -0.6)$ y QR $(0.7, -2.2)$. Con las distancias del Ejemplo 5.1, VER (2.98 contra 4.18) y OAX (3.22 contra 4.00) quedan con NL, y CHIS (3.60 contra 3.53) con QR. Los nuevos centroides son $(-0.47, 0.70)$ para {NL, VER, OAX} y $(-0.90, -1.45)$ para {QR, CHIS}. Con ellos, ninguna asignación cambia, y el algoritmo se detiene con $J = 13.11$.

Arranque B: centroides iniciales en VER y OAX. El algoritmo converge a {NL, VER} y {QR, OAX, CHIS}, con $J = 15.12$.

Ninguno de los dos es el óptimo global. Enumerando las 15 particiones en dos grupos, la mejor es {NL, QR} contra {VER, OAX, CHIS}, con $J = W = 5.85$, que es justamente la que encontró Ward en el Ejemplo 5.2. Para esa partición, con $\bar{\mathbf{x}} = (-0.64, -0.16)$, se verifica la Proposición 5.2: $T = 18.88$, $W = 5.85$ y $B = 2\|(0.90, -1.40) - \bar{\mathbf{x}}\|^2 + 3\|(-1.67, 0.67) - \bar{\mathbf{x}}\|^2 = 7.82 + 5.21 = 13.03$.

5.4.1. k-medoides

En el método de **k-medoides**, o c-medoides, cada grupo se representa por uno de sus propios objetos, el *medoide*, que sintetiza las características prototípicas del grupo. Se minimiza la suma de las disimilitudes de cada objeto a su medoide más cercano:

$$\text{mín} \sum_{i=1}^{n} \sum_{c=1}^{k} u_{ic}\, d(\mathbf{x}_i, \tilde{\mathbf{x}}_c), \qquad \sum_{c=1}^{k} u_{ic} = 1, \quad u_{ic} \in \{0, 1\}, \tag{5.8}$$

donde $\tilde{\mathbf{x}}_c$ es el medoide del grupo c, que debe ser uno de los objetos. A diferencia de k-medias, d puede ser cualquier disimilitud, no necesariamente la euclidiana al cuadrado, por ejemplo la de Gower o la Manhattan, lo que hace al método más robusto a valores atípicos y aplicable a datos no métricos. El algoritmo PAM de Kaufman y Rousseeuw (1990) tiene dos fases:

1. *Construcción*: selecciona secuencialmente k objetos "centralmente localizados" como medoides iniciales.

2. *Intercambio*: si la función objetivo puede reducirse intercambiando un medoide por un objeto no seleccionado, se realiza el intercambio. Esto se repite hasta que la función objetivo ya no pueda disminuir.

5.5. Agrupamiento basado en modelos: mezclas gaussianas

Los métodos anteriores son algorítmicos: no postulan un modelo de cómo se generaron los datos. El enfoque basado en modelos supone que cada observación proviene de uno de k grupos latentes, con probabilidades $\pi_1, \ldots, \pi_k$,

y que dentro del grupo c los datos son $N_p(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$ (Fraley y Raftery 2002). La densidad es una **mezcla**:

$$f(\mathbf{x}) = \sum_{c=1}^{k} \pi_c \, \phi(\mathbf{x}; \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c), \qquad \pi_c \geq 0, \quad \sum_c \pi_c = 1, \tag{5.9}$$

donde ϕ es la densidad normal multivariada (Sección 1.6). Los parámetros se estiman por máxima verosimilitud con el algoritmo **EM** (Dempster, Laird y Rubin 1977), que alterna dos pasos:

- **Paso E**: calcular la probabilidad posterior de que el objeto i pertenezca al grupo c,
$$\tau_{ic} = \frac{\pi_c \, \phi(\mathbf{x}_i; \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)}{\sum_{l=1}^{k} \pi_l \, \phi(\mathbf{x}_i; \boldsymbol{\mu}_l, \boldsymbol{\Sigma}_l)}.$$
- **Paso M**: actualizar los parámetros como promedios ponderados por τ_{ic}:
$$\pi_c = \frac{1}{n} \sum_i \tau_{ic}, \qquad \boldsymbol{\mu}_c = \frac{\sum_i \tau_{ic} \mathbf{x}_i}{\sum_i \tau_{ic}}, \qquad \boldsymbol{\Sigma}_c = \frac{\sum_i \tau_{ic} (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)'}{\sum_i \tau_{ic}}.$$

Cada iteración de EM no disminuye la verosimilitud (Dempster, Laird y Rubin 1977). A diferencia de k-medias, la asignación es *suave*: cada objeto tiene una probabilidad de pertenencia a cada grupo, lo que cuantifica la incertidumbre de la clasificación. Si todas las covarianzas son $\sigma^2 \mathbf{I}$ y las proporciones son iguales, cuando $\sigma^2 \to 0$ las τ_{ic} tienden a 0 o 1 según el centroide más cercano, y EM se reduce a k-medias: k-medias es un caso límite de una mezcla gaussiana esférica.

La ventaja principal de este enfoque es que el número de grupos y la forma de las covarianzas (esféricas, diagonales o generales) se eligen con un criterio de información, como el BIC (Schwarz 1978):

$$\mathrm{BIC} = -2 \log \hat{L} + q \log n, \tag{5.10}$$

donde q es el número de parámetros libres; se prefiere el modelo con menor BIC.

5.6. ¿Cuántos grupos? Validación

Todo algoritmo de conglomerados produce grupos, aunque los datos no tengan estructura de grupos. La validación responde dos preguntas: cuántos grupos hay y si la partición refleja algo real. En general, el número de grupos elegido depende del método de agrupamiento utilizado. Los criterios más usados son:

El codo. W_k siempre disminuye al aumentar k. Se busca el valor de k a partir del cual la disminución se vuelve marginal. Es informal y a menudo ambiguo.

Criterio de Calinski y Harabasz. Caliński y Harabasz (1974) sugieren elegir el k que maximiza

$$CH_k = \frac{\operatorname{tr}(\boldsymbol{B})/(k-1)}{\operatorname{tr}(\boldsymbol{W})/(n-k)}, \tag{5.11}$$

el análogo multivariante del estadístico F del análisis de varianza, con $\boldsymbol{B}$ y $\boldsymbol{W}$ como en la Proposición 5.2. Evaluarlo requiere conocer la pertenencia a los grupos.

Criterio de la silueta. Propuesto por Rousseeuw (1987). Considere un objeto i que pertenece al grupo p. Sea a_i su disimilitud promedio con los demás objetos del grupo p y, para cada otro grupo $q \neq p$, sea d_{iq} su disimilitud promedio con los objetos de q. Sea $b_i = \min_{q \neq p} d_{iq}$ la disimilitud con el grupo vecino más cercano. La silueta del objeto i es

$$S_i = \frac{b_i - a_i}{\max\{a_i,\, b_i\}} \in [-1, 1], \tag{5.12}$$

donde el denominador es un término de normalización; para un grupo de un solo objeto se define $S_i = 0$. Valores cercanos a 1 indican que el objeto está bien asignado; valores negativos, que estaría mejor en el grupo vecino. La silueta promedio, $\overline{S} = \frac{1}{n}\sum_i S_i$, se maximiza cuando la distancia dentro de los grupos es pequeña y la distancia entre grupos es grande. Kaufman y Rousseeuw (1990) propusieron la escala: 0.71 a 1.00, estructura fuerte; 0.51 a 0.70, razonable; 0.26 a 0.50, débil y posiblemente artificial; 0.25 o menos, sin estructura sustancial.

Estadístico gap. Tibshirani, Walther y Hastie (2001) comparan $\log W_k$ con su valor esperado bajo una distribución de referencia *sin* grupos (uniforme sobre la caja que contiene a los datos, alineada con sus componentes principales):

$$\mathrm{Gap}(k) = \mathbb{E}^*[\log W_k^*] - \log W_k, \tag{5.13}$$

donde $\mathbb{E}^*$ se estima con B conjuntos de datos simulados, cuyo error estándar s_k también se calcula. Se elige el menor k tal que $\mathrm{Gap}(k) \geq \mathrm{Gap}(k+1) - s_{k+1}$. A diferencia de los criterios anteriores, puede concluir que $k = 1$: que no hay evidencia de grupos.

Estabilidad. Una partición real debería reaparecer en submuestras de los datos. Se agrupan muestras *bootstrap* y se compara cada solución con la original mediante el **índice de Rand ajustado** (ARI) de Hubert y Arabie (1985). Si n_{ab} es el número de objetos en el grupo a de una partición y en el b de la otra, con totales marginales $n_{a\cdot}$ y $n_{\cdot b}$,

$$\mathrm{ARI} = \frac{\sum_{ab}\binom{n_{ab}}{2} - \left[\sum_a \binom{n_{a\cdot}}{2}\sum_b \binom{n_{\cdot b}}{2}\right]/\binom{n}{2}}{\frac{1}{2}\left[\sum_a \binom{n_{a\cdot}}{2} + \sum_b \binom{n_{\cdot b}}{2}\right] - \left[\sum_a \binom{n_{a\cdot}}{2}\sum_b \binom{n_{\cdot b}}{2}\right]/\binom{n}{2}}, \tag{5.14}$$

que vale 1 si las particiones coinciden y tiene valor esperado 0 si son independientes.

5.7. Aplicación: una tipología de las entidades federativas

5.7.1. Elección del número de grupos

k	W_k	Silueta	CH_k	Gap (s_k)	BIC (mezcla esférica)
1	60.17	–	–	0.643 (0.120)	188.1
2	39.65	0.322	15.5	0.431 (0.130)	165.9
3	25.18	0.351	20.2	0.366 (0.139)	173.3
4	16.90	0.358	23.9	0.340 (0.142)	**158.1**
5	12.67	0.366	25.3	0.304 (0.127)	165.3
6	9.80	0.365	26.7	0.315 (0.148)	167.0
7	7.11	0.397	31.1	0.387 (0.142)	168.4

Los criterios no coinciden, y es importante entender por qué:

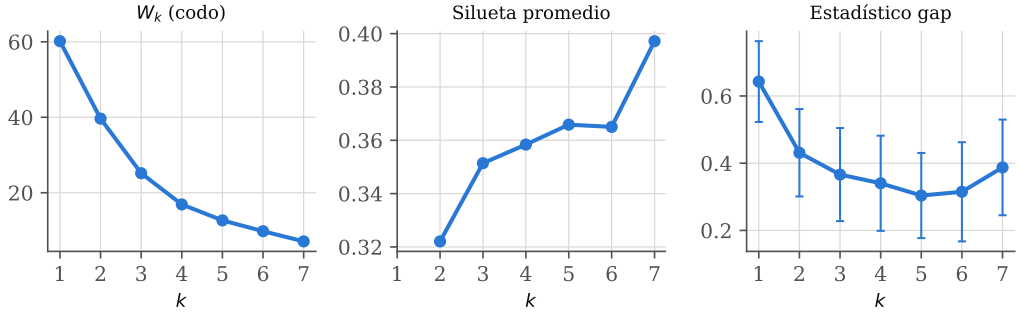


Figura 5.2: Criterios para elegir k con k-medias sobre las puntuaciones factoriales de las 32 entidades. El estadístico gap se muestra con barras de $\pm s_k$ (500 conjuntos de referencia). Elaboración propia con datos de la ENIGH 2024.

- W_k no muestra un codo claro (Figura 5.2), y la silueta y CH_k crecen con k sin alcanzar un máximo en el rango explorado.
- Las siluetas están entre 0.32 y 0.40: en la escala de Kaufman y Rousseeuw, una estructura *débil*.
- El estadístico gap es máximo en $k = 1$: frente a datos uniformes del mismo rango, no hay evidencia de grupos naturalmente separados.
- El BIC de la mezcla gaussiana esférica es mínimo en $k = 4$.

La conclusión honesta es que las 32 entidades no forman grupos bien separados: se distribuyen de manera más o menos continua en el plano factorial. Everitt et al. (2011) distinguen entre *descubrir* grupos naturales y *disecar* un conjunto continuo en partes útiles para describirlo o para tomar decisiones. Nuestro caso es el segundo. La segmentación sigue siendo útil, por ejemplo para diseñar políticas diferenciadas o para comunicar los resultados del índice del Capítulo 4 por grupos en lugar de lugares, pero sus fronteras son, en parte, convencionales. Elegimos $k = 4$, respaldado por el BIC y por la interpretabilidad de los grupos.

5.7.2. Los grupos y su perfil

La solución de k-medias con 100 arranques (Figura 5.3) es:

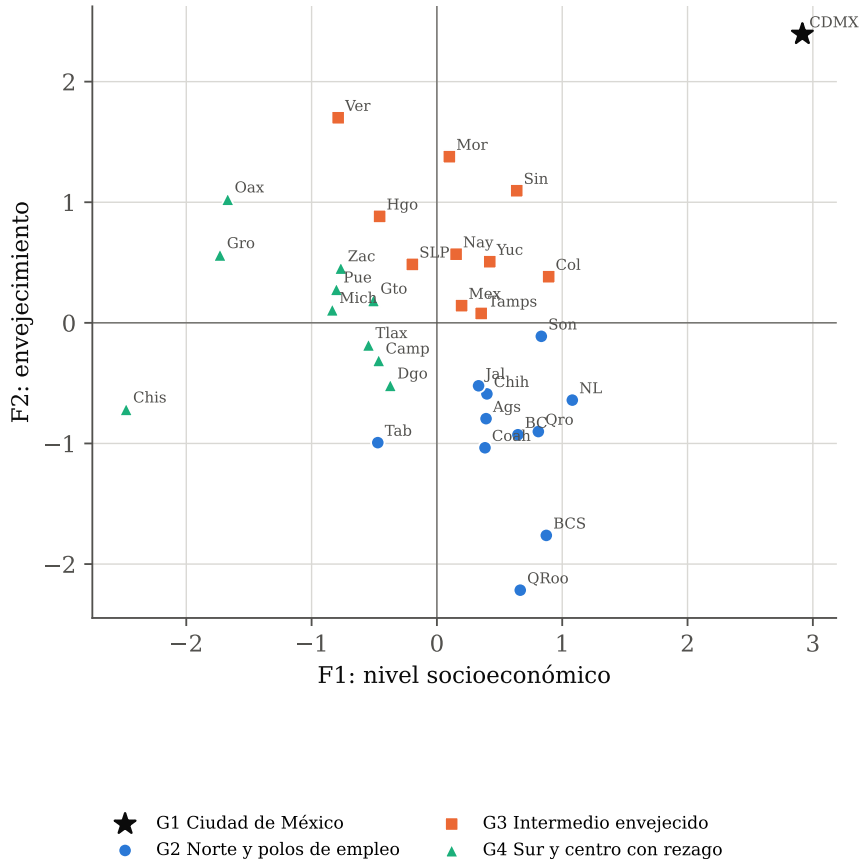


Figura 5.3: Tipología de las entidades con k-medias ($k = 4$) en el plano de los factores del Capítulo 3. Elaboración propia con datos de la ENIGH 2024.

- **G1, Ciudad de México** (1 entidad; centroide $(2.92, 2.39)$). Un caso aparte en ambos factores, como anticipamos en los Capítulos 3 y 4.
- **G2, Norte y polos de empleo** (11; centroide $(0.54, -0.95)$): Aguascalientes, Baja California, Baja California Sur, Chihuahua, Coahuila, Jalisco, Nuevo León, Querétaro, Quintana Roo, Sonora y Tabasco. Nivel socioeconómico por encima del promedio y población joven con alta dependencia del ingreso laboral.
- **G3, Intermedio envejecido** (10; centroide $(0.13, 0.72)$): Colima, Hidalgo, México, Morelos, Nayarit, San Luis Potosí, Sinaloa, Tamaulipas,

Veracruz y Yucatán. Nivel socioeconómico cercano al promedio y población más envejecida.

- **G4, Sur y centro con rezago** (10; centroide $(-1.02, 0.09)$): Campeche, Chiapas, Durango, Guanajuato, Guerrero, Michoacán, Oaxaca, Puebla, Tlaxcala y Zacatecas. Nivel socioeconómico claramente por debajo del promedio.

El **perfilado** describe los grupos con las variables originales, que son más fáciles de comunicar que las puntuaciones factoriales:

Grupo	Ingreso pc	Escol.	Menores	Percep.	65+	Ing. laboral
G1 CDMX	10.781	7.43	0.107	0.796	0.144	0.610
G2 Norte	10.436	6.64	0.174	0.655	0.084	0.682
G3 Intermedio	10.186	6.17	0.165	0.674	0.111	0.637
G4 Sur	9.918	5.69	0.195	0.633	0.100	0.652

En términos de la media de los logaritmos, el ingreso per cápita del G2 es $e^{10.436-9.918} = 1.68$ veces el del G4. La proporción de adultos de 65 años o más del G3 (11.1 %) supera en casi un tercio a la del G2 (8.4 %).

Observación 5.1 (Inferencia circular) Es tentador probar con un análisis de varianza que los grupos difieren en las variables de agrupamiento. Esa prueba no es válida: los grupos se construyeron precisamente para maximizar esas diferencias, de modo que el estadístico F será grande aun si los datos no tienen estructura de grupos. Las pruebas de diferencias sólo tienen sentido con variables que *no* se usaron para agrupar. Por ejemplo, el índice del Capítulo 4 promedia 0.39 en el G2, 0.19 en el G3 y -0.90 en el G4. Los rangos del G2 (-0.18 a 0.82) y del G3 (-0.59 a 1.02) se traslapan: los grupos difieren sobre todo en envejecimiento, una dimensión que el índice deliberadamente excluyó.

5.7.3. Validación

- **Calidad de la asignación.** La silueta promedio es 0.358; por grupo, 0.469 en el G2, 0.345 en el G3 y 0.286 en el G4. Ninguna entidad tiene silueta negativa.

- **Concordancia entre métodos.** El método de Ward cortado en cuatro grupos (Figura 5.4) coincide parcialmente con k-medias: ARI = 0.638. Ward manda a Sonora al grupo intermedio, y a Hidalgo, San Luis Potosí y Tabasco al grupo del sur. Precisamente esas entidades están en las fronteras entre grupos de la Figura 5.3.
- **Estabilidad.** En 500 muestras bootstrap, el ARI entre la partición original y la de cada remuestra promedia 0.59, con percentil 5 de 0.29: estabilidad moderada.
- **Fidelidad del árbol.** La correlación cofenética es 0.82 con enlace promedio, 0.80 con simple, 0.70 con completo y 0.49 con Ward. Ward no busca preservar las distancias sino minimizar W, por lo que su correlación cofenética suele ser menor.

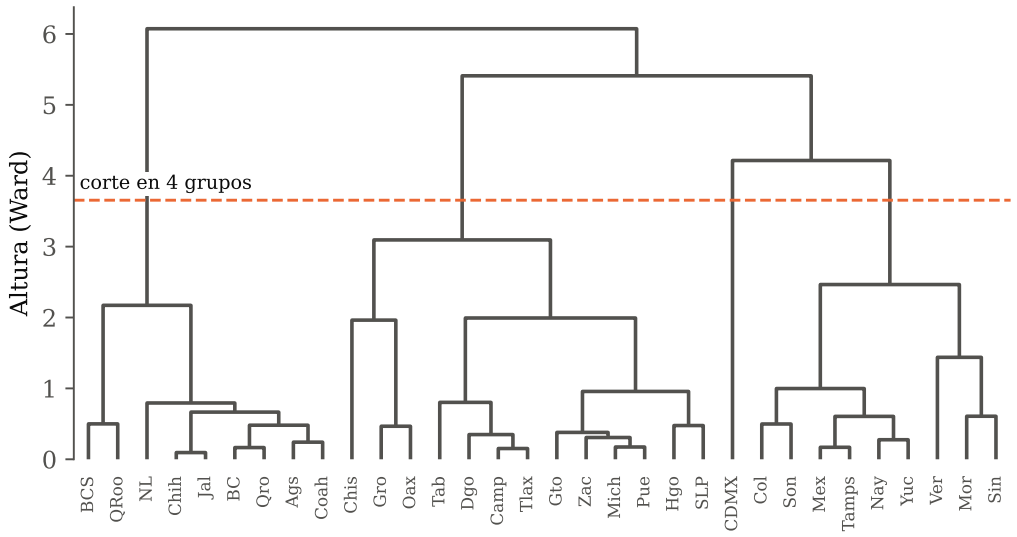


Figura 5.4: Dendrograma del método de Ward sobre las puntuaciones factoriales de las 32 entidades. Elaboración propia con datos de la ENIGH 2024.

5.8. k-medias con datos epidemiológicos

El cuaderno

del repositorio aplica k-medias a datos de defunciones por COVID-19 (`Defunciones_KM.csv`). Es un buen ejercicio para aplicar los criterios de validación de la Sección 5.6 a un problema distinto.

5.9. Agrupamiento de series de tiempo

Las observaciones de series de tiempo pueden agruparse directamente, o bien a partir de características extraídas de ellas. Las características se extraen en los dominios del tiempo, de la frecuencia y de las ondículas (*wavelets*). En el dominio del tiempo, se usan autocorrelaciones, autocorrelaciones parciales y correlaciones cruzadas. En el dominio de la frecuencia, el periodograma y las ordenadas espectrales y cepstrales. En el dominio de las ondículas, las transformadas discretas de ondículas, las varianzas de ondículas y las correlaciones de ondículas.

En muchos casos se usa el análisis de conglomerados tradicional, por ejemplo el jerárquico: primero se define una medida de distancia que capture las características dinámicas de las series y luego se aplica el algoritmo de agrupamiento con esa distancia. Además de las distancias de Minkowski aplicadas a las series como vectores, dos medidas son especialmente útiles:

- **Distancia basada en correlación**: $d(\mathbf{x}, \mathbf{y}) = \sqrt{2(1 - \rho_{xy})}$, donde ρ_{xy} es la correlación entre las series. Es la distancia euclidiana entre las series estandarizadas (salvo un factor $\sqrt{T}$), así que agrupa series con la misma *forma*, sin importar su nivel ni su escala.

- **Alineamiento temporal dinámico** (DTW) (Sakoe y Chiba 1978): permite que dos series se comparen con desfases o a velocidades distintas. Para series $x_1, \ldots, x_T$ y $y_1, \ldots, y_S$ se define recursivamente

  $$D(t, s) = |x_t - y_s| + \min\{D(t-1, s),\ D(t, s-1),\ D(t-1, s-1)\},$$

  con $D(0, 0) = 0$ y $D(t, 0) = D(0, s) = \infty$ para $t, s > 0$, y la distancia es $D(T, S)$. Se calcula con programación dinámica en $O(TS)$ operaciones.

El repositorio del curso incluye dos aplicaciones en la carpeta `06 Clustering Time Series/`:

- el agrupamiento de precios de acciones de la Bolsa Mexicana de Valores, en `02 Clustering/`, con el módulo `time_series_clustering_class.py`;

- el agrupamiento no supervisado de los precios marginales locales (PML) de los nodos del Sistema Eléctrico Nacional, en `03_Unsupervised_Clusteing_Time_Series/`.

Los precios marginales locales son publicados por el Centro Nacional de Control de Energía (CENACE).

5.10. El análisis de conglomerados en las etapas de Hair

1. **Objetivo:** descubrir grupos naturales (taxonomía), simplificar los datos para describirlos, o identificar relaciones entre objetos. Elegir con base teórica las variables de agrupamiento, que definen qué significa "parecerse".

2. **Diseño:** tratamiento de valores atípicos (pueden formar grupos de un elemento, como la Ciudad de México), medida de disimilitud, estandarización y, si hay variables correlacionadas, uso de factores o de la distancia de Mahalanobis.

3. **Supuestos:** representatividad de la muestra y ausencia de multicolinealidad fuerte entre las variables de agrupamiento.

4. **Estimación:** algoritmo (jerárquico, k-medias, mezclas) y número de grupos con varios criterios. Una estrategia común es usar Ward para explorar el número de grupos y k-medias para refinar la partición.

5. **Interpretación:** perfilar los grupos con sus centroides en las variables originales y darles nombre.

6. **Validación:** concordancia entre métodos, estabilidad, y validez de criterio con variables que no se usaron para agrupar.

5.11. Implementación en Python

```
import numpy as np
import pandas as pd
from scipy.cluster.hierarchy import linkage, fcluster, dendrogram,
    cophenet
from scipy.spatial.distance import pdist
from sklearn.cluster import KMeans
from sklearn.mixture import GaussianMixture
from sklearn.metrics import silhouette_score,
    calinski_harabasz_score, adjusted_rand_score

F = pd.read_csv("03 Factor Analysis/04 Entidades ENIGH/"
                "enigh2024_puntuaciones.csv", index_col=0) # F1, F2
Y = F.values

for k in range(2, 8): # elegir k
    lab = KMeans(k, n_init=50, random_state=0).fit_predict(Y)
    print(k, silhouette_score(Y, lab), calinski_harabasz_score(Y,
        lab))

km = KMeans(4, n_init=100, random_state=0).fit(Y) # k-medias (k-
    means++)
Z = linkage(Y, method="ward") # Ward
ward = fcluster(Z, 4, criterion="maxclust")
print(adjusted_rand_score(km.labels_, ward)) # concordancia
print(cophenet(Z, pdist(Y))[0]) # correlacion cofenetica

gmm = GaussianMixture(4, covariance_type="spherical", n_init=20).
    fit(Y)
print(gmm.bic(Y), gmm.predict_proba(Y)[:3]) # pertenencia suave
```

El cuaderno `05 Clustering/05 Tipologia Entidades/Tipologia_Entidades.ipynb` del repositorio reproduce los ejemplos a mano y todas las cifras de la aplicación, incluido el estadístico gap. Los demás cuadernos de `05 Clustering/` del repositorio desarrollan otras aplicaciones: distancias, la base Iris, segmentación de clientes y agrupamiento de países con PCA.

5.12. Ejercicios

1. Demuestre que la distancia de Minkowski con $0 < r < 1$ no satisface la desigualdad del triángulo. *Sugerencia:* use $\mathbf{x} = (0, 0)$, $\mathbf{y} = (1, 0)$ y $\mathbf{z} = (1, 1)$.

2. Verifique los coeficientes de Lance y Williams para el enlace promedio y para Ward (en distancias al cuadrado), usando la Proposición 5.3.

3. Con la matriz $\mathbf{D}$ del Ejemplo 5.1, construya el dendrograma con enlace promedio y calcule su correlación cofenética.

4. Demuestre que la distancia entre series estandarizadas (con media cero y $\sum_t x_t^2 = T$) es $\sqrt{2T(1 - \rho_{xy})}$.

5. En el Ejemplo 5.3, ¿desde qué pares de objetos como centroides iniciales converge k-medias al óptimo global? ¿Qué proporción de los 10 pares posibles es?

6. Demuestre que CH_k no está definido para $k = 1$ y que, para $k = n$, $\operatorname{tr}(\boldsymbol{W}) = 0$. ¿Qué implica para el uso de este criterio?

7. Calcule a mano el ARI entre las particiones {NL, QR} {VER, OAX, CHIS} y {NL, VER} {QR, OAX, CHIS}.

8. (Computacional) Repita la aplicación sin la Ciudad de México. ¿Cambia el número de grupos sugerido por los criterios? ¿Cambian los grupos?

9. (Computacional) Agrupe las entidades con los seis indicadores estandarizados en lugar de las puntuaciones factoriales. Compare con el ARI y explique las diferencias.

10. (Computacional) Use la base `marketing_campaign.csv` del repositorio, que tiene variables métricas y categóricas, para segmentar clientes con k-medoides y la distancia de Gower. Perfile los segmentos con variables que no usó para agrupar.

Bibliografía

[And63] T. W. Anderson. «Asymptotic Theory for Principal Component Analysis». En: *The Annals of Mathematical Statistics* 34.1 (1963), págs. 122-148.

[AV07] David Arthur y Sergei Vassilvitskii. «k-means++: The Advantages of Careful Seeding». En: *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*. 2007, págs. 1027-1035.

[Bar50] M. S. Bartlett. «Tests of Significance in Factor Analysis». En: *British Journal of Psychology, Statistical Section* 3.2 (1950), págs. 77-85.

[CH74] T. Caliński y J. Harabasz. «A Dendrite Method for Cluster Analysis». En: *Communications in Statistics* 3.1 (1974), págs. 1-27.

[Cat66] Raymond B. Cattell. «The Scree Test for the Number of Factors». En: *Multivariate Behavioral Research* 1.2 (1966), págs. 245-276.

[Che+07] Laurens Cherchye et al. «An Introduction to 'Benefit of the Doubt' Composite Indicators». En: *Social Indicators Research* 82.1 (2007), págs. 111-145.

[Cro51] Lee J. Cronbach. «Coefficient Alpha and the Internal Structure of Tests». En: *Psychometrika* 16.3 (1951), págs. 297-334.

[DLR77] A. P. Dempster, N. M. Laird y D. B. Rubin. «Maximum Likelihood from Incomplete Data via the EM Algorithm». En: *Journal of the Royal Statistical Society: Series B* 39.1 (1977), págs. 1-38.

[EY36] Carl Eckart y Gale Young. «The Approximation of One Matrix by Another of Lower Rank». En: *Psychometrika* 1.3 (1936), págs. 211-218.

[Eve+11] Brian S. Everitt et al. *Cluster Analysis*. 5.ª ed. Chichester: Wiley, 2011.

[Fan49] Ky Fan. «On a Theorem of Weyl Concerning Eigenvalues of Linear Transformations I». En: *Proceedings of the National Academy of Sciences* 35.11 (1949), págs. 652-655.

[FR02] Chris Fraley y Adrian E. Raftery. «Model-Based Clustering, Discriminant Analysis, and Density Estimation». En: *Journal of the American Statistical Association* 97.458 (2002), págs. 611-631.

[Gab71] K. Ruben Gabriel. «The Biplot Graphic Display of Matrices with Application to Principal Component Analysis». En: *Biometrika* 58.3 (1971), págs. 453-467.

[Got94] John M. Gottman. *What Predicts Divorce? The Relationship between Marital Processes and Marital Outcomes*. Hillsdale, NJ: Lawrence Erlbaum, 1994.

[Gow71] J. C. Gower. «A General Coefficient of Similarity and Some of Its Properties». En: *Biometrics* 27.4 (1971), págs. 857-871.

[Hai+06] Joseph F. Hair et al. *Multivariate Data Analysis*. Prentice Hall, 2006.

[HTF17] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning. Data Mining, Inference, and Prediction*. LLC: Springer, 2017.

[HW64] Alan E. Hendrickson y Paul O. White. «Promax: A Quick Method for Rotation to Oblique Simple Structure». En: *British Journal of Statistical Psychology* 17.1 (1964), págs. 65-70.

[Hey31] H. B. Heywood. «On Finite Sequences of Real Numbers». En: *Proceedings of the Royal Society of London. Series A* 134.824 (1931), págs. 486-501.

[Hor65] John L. Horn. «A Rationale and Test for the Number of Factors in Factor Analysis». En: *Psychometrika* 30.2 (1965), págs. 179-185.

[HJ13] Roger A. Horn y Charles R. Johnson. *Matrix Analysis*. 2.ª ed. Cambridge: Cambridge University Press, 2013.

[Hot33] Harold Hotelling. «Analysis of a Complex of Statistical Variables into Principal Components». En: *Journal of Educational Psychology* 24.6 (1933), págs. 417-441.

[Hou57] H. S. Houthakker. «An International Comparison of Household Expenditure Patterns, Commemorating the Centenary of Engel's Law». En: *Econometrica* 25.4 (1957), págs. 532-551.

[HA85] Lawrence Hubert y Phipps Arabie. «Comparing Partitions». En: *Journal of Classification* 2.1 (1985), págs. 193-218.

[INE25] INEGI. *Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH) 2024. Nueva serie.* Microdatos, tabla `concentradohogar`. Aguascalientes, 2025.

[Jam+21] Gareth James et al. *An Introduction to Statistical Learning with Applications in R.* 2.ª ed. New York: Springer, 2021.

[JW07] Richard A. Johnson y Dean W. Wichern. *Applied Multivariate Statistical Analysis.* 6.ª ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2007.

[Jol02] Ian T. Jolliffe. *Principal Component Analysis.* 2.ª ed. New York: Springer, 2002.

[Jör67] Karl G. Jöreskog. «Some Contributions to Maximum Likelihood Factor Analysis». En: *Psychometrika* 32.4 (1967), págs. 443-482.

[Kai58] Henry F. Kaiser. «The Varimax Criterion for Analytic Rotation in Factor Analysis». En: *Psychometrika* 23.3 (1958), págs. 187-200.

[Kai60] Henry F. Kaiser. «The Application of Electronic Computers to Factor Analysis». En: *Educational and Psychological Measurement* 20.1 (1960), págs. 141-151.

[Kai74] Henry F. Kaiser. «An Index of Factorial Simplicity». En: *Psychometrika* 39.1 (1974), págs. 31-36.

[KR90] Leonard Kaufman y Peter J. Rousseeuw. *Finding Groups in Data: An Introduction to Cluster Analysis.* New York: Wiley, 1990.

[Kok20] Rohan Kokkula. *Unsupervised Learning on Country Data*. Conjunto de datos publicado en Kaggle, preparado para el caso de la ONG HELP International; licencia MIT. Archivo `Country-data.csv` del repositorio del curso. 2020. URL: `https://www.kaggle.com/datasets/rohan0301/unsupervised-learning-on-country-data`.

[LW67] G. N. Lance y W. T. Williams. «A General Theory of Classificatory Sorting Strategies: 1. Hierarchical Systems». En: *The Computer Journal* 9.4 (1967), págs. 373-380.

[LM71] D. N. Lawley y A. E. Maxwell. *Factor Analysis as a Statistical Method*. 2.ª ed. London: Butterworths, 1971.

[LR19] Roderick J. A. Little y Donald B. Rubin. *Statistical Analysis with Missing Data*. 3.ª ed. Hoboken, NJ: Wiley, 2019.

[Mac67] James MacQueen. «Some Methods for Classification and Analysis of Multivariate Observations». En: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Vol. 1. University of California Press, 1967, págs. 281-297.

[Mah36] Prasanta Chandra Mahalanobis. «On the Generalised Distance in Statistics». En: *Proceedings of the National Institute of Sciences of India* 2.1 (1936), págs. 49-55.

[Mar70] Kanti V. Mardia. «Measures of Multivariate Skewness and Kurtosis with Applications». En: *Biometrika* 57.3 (1970), págs. 519-530.

[MKB79] Kanti V. Mardia, John T. Kent y John M. Bibby. *Multivariate Analysis*. London: Academic Press, 1979.

[McD99] Roderick P. McDonald. *Test Theory: A Unified Treatment*. Mahwah, NJ: Lawrence Erlbaum, 1999.

[NSB00] Giuseppe Nicoletti, Stefano Scarpetta y Olivier Boylaud. *Summary Indicators of Product Market Regulation with an Extension to Employment Protection Legislation*. Economics Department Working Paper 226. Paris: OECD, 2000.

[OE08] OECD y European Commission Joint Research Centre. *Handbook on Constructing Composite Indicators: Methodology and User Guide*. Paris: OECD Publishing, 2008.

[PSS13] Paolo Paruolo, Michaela Saisana y Andrea Saltelli. «Ratings and Rankings: Voodoo or Science?» En: *Journal of the Royal Statistical Society: Series A* 176.3 (2013), págs. 609-634.

[Pea01] Karl Pearson. «On Lines and Planes of Closest Fit to Systems of Points in Space». En: *Philosophical Magazine*. 6.ª ép. 2.11 (1901), págs. 559-572.

[Pro10] Programa de las Naciones Unidas para el Desarrollo. *Human Development Report 2010. The Real Wealth of Nations: Pathways to Human Development*. New York: Palgrave Macmillan, 2010.

[Rou87] Peter J. Rousseeuw. «Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis». En: *Journal of Computational and Applied Mathematics* 20 (1987), págs. 53-65.

[SST05] Michaela Saisana, Andrea Saltelli y Stefano Tarantola. «Uncertainty and Sensitivity Analysis Techniques as Tools for the Quality Assessment of Composite Indicators». En: *Journal of the Royal Statistical Society: Series A* 168.2 (2005), págs. 307-323.

[SC78] Hiroaki Sakoe y Seibi Chiba. «Dynamic Programming Algorithm Optimization for Spoken Word Recognition». En: *IEEE Transactions on Acoustics, Speech, and Signal Processing* 26.1 (1978), págs. 43-49.

[Sch78] Gideon Schwarz. «Estimating the Dimension of a Model». En: *The Annals of Statistics* 6.2 (1978), págs. 461-464.

[Spe04] Charles Spearman. «"General Intelligence," Objectively Determined and Measured». En: *The American Journal of Psychology* 15.2 (1904), págs. 201-292.

[Ste46] S. S. Stevens. «On the Theory of Scales of Measurement». En: *Science* 103.2684 (1946), págs. 677-680.

[Thu47] L. L. Thurstone. *Multiple-Factor Analysis*. Chicago: University of Chicago Press, 1947.

[TWH01] Robert Tibshirani, Guenther Walther y Trevor Hastie. «Estimating the Number of Clusters in a Data Set via the Gap Statistic». En: *Journal of the Royal Statistical Society: Series B* 63.2 (2001), págs. 411-423.

[Try39] Robert C. Tryon. *Cluster Analysis: Correlation Profile and Orthometric (Factor) Analysis for the Isolation of Unities in Mind and Personality*. Ann Arbor, MI: Edwards Brothers, 1939.

[War63] Joe H. Ward. «Hierarchical Grouping to Optimize an Objective Function». En: *Journal of the American Statistical Association* 58.301 (1963), págs. 236-244.

[Yön+19] Mustafa Kemal Yöntem et al. «Divorce Prediction Using Correlation Based Feature Selection and Artificial Neural Networks». En: *Nevşehir Hacı Bektaş Veli Üniversitesi SBE Dergisi* 9.1 (2019), págs. 259-273. URL: https://dergipark.org.tr/en/pub/nevsosbilen/article/549416.

Apéndice A

Resultados de álgebra matricial

Este apéndice reúne los resultados de álgebra lineal que se usan en la parte multivariante. Las demostraciones omitidas pueden consultarse en Mardia, Kent y Bibby (1979, Apéndice A) o en Johnson y Wichern (2007, Cap. 2).

A.1. Traza, determinante y rango

Para matrices de dimensiones compatibles:

1. $\text{tr}(\mathbf{A}+\mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B})$ y $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$. En consecuencia, la traza es invariante ante permutaciones cíclicas: $\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{CAB})$. En particular, para un vector $\mathbf{v}$, $\mathbf{v}'\mathbf{Av} = \text{tr}(\mathbf{Avv}')$.

2. $|\mathbf{AB}| = |\mathbf{A}||\mathbf{B}|$, $|\mathbf{A}'| = |\mathbf{A}|$, $|c\mathbf{A}| = c^p|\mathbf{A}|$ para $\mathbf{A}$ de orden p, y $|\mathbf{A}^{-1}| = |\mathbf{A}|^{-1}$.

3. $\text{rango}(\mathbf{A}) = \text{rango}(\mathbf{A}') = \text{rango}(\mathbf{A}'\mathbf{A})$ y

$$\text{rango}(\mathbf{AB}) \leq \text{mín}\{\text{rango}(\mathbf{A}), \text{rango}(\mathbf{B})\}.$$

Proposición A.1 (Matrices particionadas) *Sea* $\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$ *con* $\mathbf{A}_{22}$ *invertible, y sea* $\mathbf{A}_{11\cdot 2} = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$ *el* complemento de Schur *de* $\mathbf{A}_{22}$. *Entonces* $|\mathbf{A}| = |\mathbf{A}_{22}||\mathbf{A}_{11\cdot 2}|$ *y, si* $\mathbf{A}_{11\cdot 2}$ *es invertible,*

$$\mathbf{A}^{-1} = \begin{bmatrix} \mathbf{A}_{11\cdot 2}^{-1} & -\mathbf{A}_{11\cdot 2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ -\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11\cdot 2}^{-1} & \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{A}_{11\cdot 2}^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \end{bmatrix}.$$

Demostración. Se verifica directamente la factorización

$$\mathbf{A} = \begin{bmatrix} \mathbf{I} & \mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{A}_{11\cdot 2} & \mathbf{0} \\ \mathbf{0} & \mathbf{A}_{22} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{A}_{22}^{-1}\mathbf{A}_{21} & \mathbf{I} \end{bmatrix}.$$

Las matrices triangulares por bloques de los extremos tienen determinante 1, lo que da el determinante. Invirtiendo cada factor y multiplicando en orden inverso se obtiene $\mathbf{A}^{-1}$. ■

Un caso que se usa en el análisis factorial es el bloque $(1,1)$ de la inversa: si $\mathbf{A} = \boldsymbol{\Sigma}$, entonces $[\boldsymbol{\Sigma}^{-1}]_{11} = \boldsymbol{\Sigma}_{11\cdot 2}^{-1}$, que es la inversa de la covarianza condicional. De ahí que los elementos de $\boldsymbol{\Sigma}^{-1}$ codifiquen las correlaciones parciales (Ejercicio 3).

A.2. Formas cuadráticas y definitud

Definición A.1 *Una matriz simétrica* $\mathbf{A}$ *de orden* p *es* ***definida positiva*** *(*$\mathbf{A} \succ 0$*) si* $\mathbf{x}'\mathbf{A}\mathbf{x} > 0$ *para todo* $\mathbf{x} \neq \mathbf{0}$*, y* ***semidefinida positiva*** *(*$\mathbf{A} \succeq 0$*) si* $\mathbf{x}'\mathbf{A}\mathbf{x} \geq 0$ *para todo* $\mathbf{x}$*.*

Para $\mathbf{A}$ simétrica son equivalentes: (i) $\mathbf{A} \succ 0$; (ii) todos sus eigenvalores son positivos; (iii) $\mathbf{A} = \mathbf{B}'\mathbf{B}$ para alguna $\mathbf{B}$ invertible. La equivalencia de (i) y (ii) se sigue del teorema espectral; para (iii), tome $\mathbf{B} = \mathbf{A}^{1/2}$.

A.3. Eigenvalores y teorema espectral

Teorema A.2 (Teorema espectral) *Sea* $\mathbf{A}$ *una matriz real simétrica de orden* p*. Entonces existen una matriz ortogonal* $\boldsymbol{\Gamma} = [\boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_p]$ *(*$\boldsymbol{\Gamma}'\boldsymbol{\Gamma} = \boldsymbol{\Gamma}\boldsymbol{\Gamma}' = \mathbf{I}_p$*) y una matriz diagonal* $\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \ldots, \lambda_p)$ *con* $\lambda_j \in \mathbb{R}$ *tales que*

$$\mathbf{A} = \boldsymbol{\Gamma}\boldsymbol{\Lambda}\boldsymbol{\Gamma}' = \sum_{j=1}^{p} \lambda_j \boldsymbol{\gamma}_j \boldsymbol{\gamma}_j'. \tag{A.1}$$

Las columnas $\boldsymbol{\gamma}_j$ *son eigenvectores ortonormales y* $\mathbf{A}\boldsymbol{\gamma}_j = \lambda_j \boldsymbol{\gamma}_j$*.*

Esbozo de demostración. Eigenvalores reales: si $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$ con $\mathbf{v} \in \mathbb{C}^p$, $\mathbf{v} \neq \mathbf{0}$, entonces $\bar{\mathbf{v}}'\mathbf{A}\mathbf{v} = \lambda\|\mathbf{v}\|^2$; conjugando y usando que $\mathbf{A}$ es real y simétrica, $\bar{\mathbf{v}}'\mathbf{A}\mathbf{v} = \bar{\lambda}\|\mathbf{v}\|^2$, así que $\lambda = \bar{\lambda}$. *Ortogonalidad:* si $\mathbf{A}\mathbf{v}_1 = \lambda_1\mathbf{v}_1$, $\mathbf{A}\mathbf{v}_2 = \lambda_2\mathbf{v}_2$ con $\lambda_1 \neq \lambda_2$, entonces $\lambda_1\mathbf{v}_2'\mathbf{v}_1 = \mathbf{v}_2'\mathbf{A}\mathbf{v}_1 = \mathbf{v}_1'\mathbf{A}\mathbf{v}_2 = \lambda_2\mathbf{v}_1'\mathbf{v}_2$, y por tanto

$\mathbf{v}_1'\mathbf{v}_2 = 0$. *Diagonalización:* por inducción en p. Sea $\boldsymbol{\gamma}_1$ un eigenvector unitario; el complemento ortogonal $\boldsymbol{\gamma}_1^{\perp}$ es invariante bajo $\mathbf{A}$ (si $\boldsymbol{\gamma}_1'\mathbf{x} = 0$, entonces $\boldsymbol{\gamma}_1'\mathbf{A}\mathbf{x} = \lambda_1\boldsymbol{\gamma}_1'\mathbf{x} = 0$), y la restricción de $\mathbf{A}$ a ese subespacio de dimensión $p-1$ es simétrica, por lo que se aplica la hipótesis de inducción. ■

Corolario A.3 *Con la notación del Teorema A.2:*

1. $\operatorname{tr}(\mathbf{A}) = \sum_j \lambda_j$ *y* $|\mathbf{A}| = \prod_j \lambda_j$.
2. *Si* $\mathbf{A} \succeq 0$, *su* ***raíz cuadrada simétrica*** *es* $\mathbf{A}^{1/2} = \boldsymbol{\Gamma}\boldsymbol{\Lambda}^{1/2}\boldsymbol{\Gamma}'$, *que cumple* $\mathbf{A}^{1/2}\mathbf{A}^{1/2} = \mathbf{A}$. *Si* $\mathbf{A} \succ 0$, $\mathbf{A}^{-1} = \boldsymbol{\Gamma}\boldsymbol{\Lambda}^{-1}\boldsymbol{\Gamma}'$ *y* $\mathbf{A}^{-1/2} = \boldsymbol{\Gamma}\boldsymbol{\Lambda}^{-1/2}\boldsymbol{\Gamma}'$.
3. $\operatorname{rango}(\mathbf{A})$ *es el número de eigenvalores distintos de cero.*

A.4. Cociente de Rayleigh

El siguiente resultado es la base algebraica del análisis de componentes principales.

Teorema A.4 (Rayleigh–Ritz) *Sea* $\mathbf{A}$ *simétrica con eigenvalores* $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$ *y eigenvectores ortonormales* $\boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_p$. *Entonces*

$$\max_{\mathbf{x}\neq\mathbf{0}} \frac{\mathbf{x}'\mathbf{A}\mathbf{x}}{\mathbf{x}'\mathbf{x}} = \lambda_1, \qquad \min_{\mathbf{x}\neq\mathbf{0}} \frac{\mathbf{x}'\mathbf{A}\mathbf{x}}{\mathbf{x}'\mathbf{x}} = \lambda_p, \tag{A.2}$$

y los valores se alcanzan en $\mathbf{x} = \boldsymbol{\gamma}_1$ *y* $\mathbf{x} = \boldsymbol{\gamma}_p$, *respectivamente. Más aún, para* $k = 2, \ldots, p$,

$$\max\left\{ \frac{\mathbf{x}'\mathbf{A}\mathbf{x}}{\mathbf{x}'\mathbf{x}} : \mathbf{x} \neq \mathbf{0},\ \mathbf{x} \perp \boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_{k-1} \right\} = \lambda_k, \tag{A.3}$$

que se alcanza en $\mathbf{x} = \boldsymbol{\gamma}_k$.

Demostración. Escriba $\mathbf{x} = \boldsymbol{\Gamma}\mathbf{y}$, con $\mathbf{y} = \boldsymbol{\Gamma}'\mathbf{x}$; como $\boldsymbol{\Gamma}$ es ortogonal, $\mathbf{x}'\mathbf{x} = \mathbf{y}'\mathbf{y}$. Entonces

$$\frac{\mathbf{x}'\mathbf{A}\mathbf{x}}{\mathbf{x}'\mathbf{x}} = \frac{\mathbf{y}'\boldsymbol{\Lambda}\mathbf{y}}{\mathbf{y}'\mathbf{y}} = \frac{\sum_j \lambda_j y_j^2}{\sum_j y_j^2},$$

que es un promedio ponderado de los λ_j con pesos $y_j^2 / \sum_l y_l^2 \geq 0$ que suman uno. Ese promedio es a lo más λ_1 y al menos λ_p, y vale λ_1 cuando $\mathbf{y} = \mathbf{e}_1$, es decir, $\mathbf{x} = \boldsymbol{\gamma}_1$. La condición $\mathbf{x} \perp \boldsymbol{\gamma}_1, \ldots, \boldsymbol{\gamma}_{k-1}$ equivale a $y_1 = \cdots = y_{k-1} = 0$, y el mismo argumento da el máximo λ_k en $\mathbf{x} = \boldsymbol{\gamma}_k$. ■

A.5. Descomposición en valores singulares

Teorema A.5 (Descomposición en valores singulares, SVD) *Toda matriz real* $\mathbf{X}$ *de* $n \times p$ *y rango* r *puede escribirse como*

$$\mathbf{X} = \mathbf{U}\mathbf{D}\mathbf{V}' = \sum_{j=1}^{r} d_j \mathbf{u}_j \mathbf{v}_j', \tag{A.4}$$

donde $\mathbf{U} \in \mathbb{R}^{n\times r}$ *y* $\mathbf{V} \in \mathbb{R}^{p\times r}$ *tienen columnas ortonormales (*$\mathbf{U}'\mathbf{U} = \mathbf{V}'\mathbf{V} = \mathbf{I}_r$*) y* $\mathbf{D} = \operatorname{diag}(d_1, \ldots, d_r)$ *con* $d_1 \geq \cdots \geq d_r > 0$*, los* ***valores singulares****.*

Demostración. $\mathbf{X}'\mathbf{X}$ es simétrica semidefinida positiva de rango r; por el teorema espectral, $\mathbf{X}'\mathbf{X} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}'$, donde $\mathbf{V}$ contiene los eigenvectores con eigenvalores $\lambda_1 \geq \cdots \geq \lambda_r > 0$. Defina $d_j = \sqrt{\lambda_j}$ y $\mathbf{u}_j = \mathbf{X}\mathbf{v}_j/d_j$. Entonces $\mathbf{u}_j'\mathbf{u}_k = \mathbf{v}_j'\mathbf{X}'\mathbf{X}\mathbf{v}_k/(d_j d_k) = \lambda_k \mathbf{v}_j'\mathbf{v}_k/(d_j d_k) = \delta_{jk}$, y $\mathbf{X}\mathbf{v}_j = d_j\mathbf{u}_j$ para $j \leq r$, mientras que $\mathbf{X}\mathbf{v} = \mathbf{0}$ para todo $\mathbf{v}$ ortogonal a $\mathbf{v}_1, \ldots, \mathbf{v}_r$. Por lo tanto $\mathbf{X} = \mathbf{X}\sum_j \mathbf{v}_j\mathbf{v}_j' = \sum_j d_j \mathbf{u}_j \mathbf{v}_j'$. ■

La SVD y la descomposición espectral están ligadas: $\mathbf{X}'\mathbf{X} = \mathbf{V}\mathbf{D}^2\mathbf{V}'$ y $\mathbf{X}\mathbf{X}' = \mathbf{U}\mathbf{D}^2\mathbf{U}'$. Si $\mathbf{X}$ está centrada, los eigenvectores de $\mathbf{S} = \frac{1}{n}\mathbf{X}'\mathbf{X}$ son las columnas de $\mathbf{V}$ y sus eigenvalores son d_j^2/n. Numéricamente es preferible calcular componentes principales mediante la SVD de los datos que mediante la descomposición espectral de $\mathbf{S}$.

Teorema A.6 (Eckart–Young) *Sea* $\mathbf{X} = \sum_{j=1}^{r} d_j \mathbf{u}_j \mathbf{v}_j'$ *la SVD de* $\mathbf{X}$ *y, para* $k < r$*,* $\mathbf{X}_k = \sum_{j=1}^{k} d_j \mathbf{u}_j \mathbf{v}_j'$*. Entonces*

$$\min_{\operatorname{rango}(\mathbf{B})\leq k} \|\mathbf{X} - \mathbf{B}\|_F^2 = \|\mathbf{X} - \mathbf{X}_k\|_F^2 = \sum_{j=k+1}^{r} d_j^2, \tag{A.5}$$

donde $\|\mathbf{A}\|_F^2 = \operatorname{tr}(\mathbf{A}'\mathbf{A})$ *es la norma de Frobenius.*

El capítulo de componentes principales demuestra el caso particular en que $\mathbf{B}$ es la proyección de los datos sobre un subespacio de dimensión k (Teorema 2.6), que es el que justifica que los primeros k componentes dan la mejor aproximación de los datos; la demostración general usa las desigualdades de Weyl para valores singulares (Horn y Johnson 2013, Sec. 7.4).

A.6. Derivadas matriciales

Sea f una función escalar de un vector $\mathbf{x} \in \mathbb{R}^p$ o de una matriz $\mathbf{A}$. Se define $\partial f/\partial \mathbf{x}$ como el vector de derivadas parciales $(\partial f/\partial x_j)_j$, y análogamente $\partial f/\partial \mathbf{A} = (\partial f/\partial a_{jk})_{jk}$. Los resultados básicos son:

$$\frac{\partial\, \mathbf{a}'\mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}, \tag{A.6}$$

$$\frac{\partial\, \mathbf{x}'\mathbf{A}\mathbf{x}}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}')\mathbf{x} \;=\; 2\mathbf{A}\mathbf{x} \quad \text{si } \mathbf{A} = \mathbf{A}', \tag{A.7}$$

$$\frac{\partial\, \operatorname{tr}(\mathbf{A}\mathbf{B})}{\partial \mathbf{A}} = \mathbf{B}', \tag{A.8}$$

$$\frac{\partial\, \log|\mathbf{A}|}{\partial \mathbf{A}} = (\mathbf{A}')^{-1} \quad (|\mathbf{A}| > 0). \tag{A.9}$$

Ejemplo A.1 (Lagrange y el cociente de Rayleigh) Maximizar $\mathbf{x}'\mathbf{A}\mathbf{x}$ sujeto a $\mathbf{x}'\mathbf{x} = 1$ con $\mathbf{A}$ simétrica. El lagrangiano es $\mathcal{L} = \mathbf{x}'\mathbf{A}\mathbf{x} - \lambda(\mathbf{x}'\mathbf{x} - 1)$, y la condición de primer orden

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = 2\mathbf{A}\mathbf{x} - 2\lambda\mathbf{x} = \mathbf{0}$$

da $\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$: los puntos críticos son los eigenvectores. Como en ellos $\mathbf{x}'\mathbf{A}\mathbf{x} = \lambda\mathbf{x}'\mathbf{x} = \lambda$, el máximo es el mayor eigenvalor, lo que confirma el Teorema A.4.

A.7. Ejercicios

1. Demuestre que los eigenvalores de una matriz idempotente simétrica son 0 o 1 y que su rango es igual a su traza.

2. Demuestre que $\mathbf{A}\mathbf{B}$ y $\mathbf{B}\mathbf{A}$ tienen los mismos eigenvalores distintos de cero. Use este hecho para justificar que $\boldsymbol{\Sigma}^{-1}\mathbf{S}$ y $\mathbf{S}^{1/2}\boldsymbol{\Sigma}^{-1}\mathbf{S}^{1/2}$ tienen los mismos eigenvalores (Teorema 1.9).

3. Sea $\boldsymbol{\Sigma} \succ 0$ y $\boldsymbol{\Omega} = \boldsymbol{\Sigma}^{-1}$ con elementos ω_{jk}. Usando la Proposición A.1, demuestre que la correlación parcial entre x_j y x_k dadas las demás variables es $-\omega_{jk}/\sqrt{\omega_{jj}\omega_{kk}}$.

4. Calcule a mano la SVD de $\mathbf{X} = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ y verifique la relación entre sus valores singulares y los eigenvalores de $\mathbf{X}'\mathbf{X}$.

5. Demuestre la fórmula $\partial \log |\mathbf{A}| / \partial \mathbf{A} = (\mathbf{A}')^{-1}$ usando la expansión del determinante por cofactores.